LAB KIỂM TRA: Neural Network nâng cao cho bài toán dự đoán giá nhà (Regression)

Mục tiêu kiểm tra

Sinh viên phải chứng minh được năng lực:

- Thiết kế **MLP regression** đúng (output linear, loss/metrics đúng)
- **Preprocess tabular** chuẩn (numerical + categorical)
- Kiểm soát **overfitting** (regularization/early stopping)
- Đánh giá mô hình bằng **nhiều metric** và phân tích lỗi
- Có tư duy thí nghiệm (baseline → cải tiến → so sánh)

---

1) Dataset

California Housing (Hands-On ML) – housing.csv
`https://raw.githubusercontent.com/ageron/handson-ml/master/datasets/housing/housing.csv`

Target: `median_house_value`
Có categorical: `ocean_proximity`

---

2) Ràng buộc

- **Không được dùng mô hình cây** (RandomForest/XGBoost/CatBoost/LightGBM).
- Chỉ được dùng:
  - `scikit-learn` cho split + preprocess + metrics
  - `tensorflow/keras` cho neural network
- Bắt buộc có **validation set** hoặc **K-Fold** (tùy yêu cầu dưới).
- Mọi kết quả phải **tái lập**: đặt `random_state`/seed.

---

3) Nhiệm vụ bắt buộc (Core Tasks)

Task A — Load + EDA tối thiểu (10 điểm)

Sinh viên phải:

1. In `shape`, `info`, thống kê missing values

2. Vẽ histogram của target
3. Trả lời 2 câu:
    - Target có dấu hiệu bị "capped" không? (gợi ý: nhìn histogram)
    - Feature nào có tương quan mạnh nhất với target? (gợi ý: `median_income`)

✅ Yêu cầu nộp: đoạn nhận xét 5–7 dòng trong notebook.

Task B — Preprocessing chuẩn với ColumnTransformer (20 điểm)

Bắt buộc:

- Numeric → `StandardScaler`
- Categorical → `OneHotEncoder(handle_unknown="ignore")`
- Xử lý missing values cho `total_bedrooms` bằng **imputer** (SimpleImputer)

    Không xử lý missing → trừ điểm nặng.

✅ Yêu cầu: dùng `Pipeline` + `ColumnTransformer` rõ ràng.

Task C — Thiết kế baseline MLP (15 điểm)

Xây 1 mô hình baseline:

- Dense(64, relu) → Dense(32, relu) → Dense(1, linear)
- Optimizer: Adam
- Loss: MSE
- Metrics: MAE

Train có validation:

- `EarlyStopping(monitor="val_loss", patience=10, restore_best_weights=True)`

✅ Yêu cầu: ghi lại **RMSE/MAE/R^2** trên test.

---

4) Yêu cầu nâng cao (Advanced Requirements)

Task D — Log-transform target + hoàn nguyên (15 điểm)

Bắt buộc:

- Train mô hình trên `y_log = log1p(y)`
- Khi dự đoán, hoàn nguyên `y_pred = expm1(y_pred_log)`
- So sánh RMSE/MAE giữa:
  - mô hình train target gốc
  - mô hình train target log

✅ Yêu cầu: kết luận mô hình nào tốt hơn và *vì sao* (3–5 dòng).

Task E — Regularization để giảm overfitting (20 điểm)

Bắt buộc triển khai **ít nhất 2** trong các kỹ thuật sau:

1. `Dropout(0.1–0.3)`
2. L2 kernel regularizer (`tf.keras.regularizers.l2(1e-4~1e-3)`)
3. BatchNormalization
4. Learning rate schedule (ReduceLROnPlateau hoặc ExponentialDecay)

✅ Yêu cầu:

- Báo cáo 2 mô hình:
  - baseline (Task C)
  - improved (Task E)
- So sánh theo RMSE/MAE/R^2 + learning curve.

Task F — Tuning có kiểm soát (10 điểm)

Bắt buộc:

- Thử **ít nhất 4 cấu hình** (grid nhỏ) thay đổi 2 yếu tố:
  - số neuron (32/64/128)
  - số layer (2/3)
  - dropout rate
  - L2 strength
  - batch_size (32/64)
- Ghi kết quả vào **bảng** (markdown table) gồm:
  - cấu hình
  - best val_loss
  - test RMSE/MAE

✅ Yêu cầu: chọn “best config” và giải thích ngắn gọn.

---

5) Phân tích lỗi (Error Analysis) – bắt buộc (10 điểm)

Sinh viên phải:

- Vẽ scatter: `y_test` vs `y_pred` (trục x/y)
- Tính residual = `y_test - y_pred`, vẽ histogram residual
- Trả lời:
  - mô hình dự đoán kém nhất ở vùng giá cao hay giá thấp?
  - nêu 1 giả thuyết nguyên nhân (ví dụ: capped target, thiếu feature…)

---

6) Bonus (khó – cộng điểm)

Chọn 1 (tối đa +10):

1. Dùng **K-Fold CV** (3 folds) để chọn cấu hình (nhẹ)
2. Lưu model tốt nhất (`ModelCheckpoint`) + load lại để test
3. Thử custom loss: Huber loss và so sánh với MSE
4. Feature engineering: tạo `rooms_per_household`, `bedrooms_per_room`, `population_per_household` rồi so sánh

---

7) Rubric chấm điểm (100 + bonus)

- Task A (EDA + trả lời): 10
- Task B (Preprocess đúng, imputer + pipeline): 20
- Task C (Baseline + metrics chuẩn): 15
- Task D (log1p/expm1 đúng + so sánh): 15
- Task E (regularization ≥ 2 kỹ thuật + so sánh): 20
- Task F (tuning ≥ 4 configs + bảng kết quả): 10
- Error analysis (plots + nhận xét): 10
- Bonus: +0 đến +10

---

8) Lưu ý “bẫy”

- Nếu SV quên **expm1** khi hoàn nguyên → metric sẽ sai (trừ mạnh).

- Nếu SV fit scaler/encoder trên toàn bộ data trước khi split → **data leakage** (trừ mạnh).
- Nếu SV dùng test để chọn mô hình → trừ điểm.

---

9) Gợi ý khung notebook

Các section nên có:

1. Setup + Seed
2. Load data
3. EDA tối thiểu + câu hỏi
4. Split train/val/test
5. Preprocess pipeline (imputer + scaler + onehot)
6. Baseline model (C)
7. Log-target model (D)
8. Regularized model (E)
9. Tuning experiments (F) + bảng kết quả
10. Final evaluation on test
11. Error analysis
12. Kết luận