Các bài toán gợi ý trong **phân lớp (classification) và hồi quy (regression)**, ưu tiên các hướng vừa phù hợp học phần KDD/Data Mining, vừa có benchmark công khai, baseline rõ, và có khoảng trống nghiên cứu

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
1	**Foundation Models cho phân lớp dữ liệu bảng ít mẫu**	Classification	Tabular foundation model có thực sự vượt XGBoost/CatBoost khi dữ liệu chỉ có vài trăm–vài nghìn mẫu?	**TabPFN v2**, Nature 2025; **TabM**, ICLR 2025; các benchmark gần đây cho thấy landscape tabular đang thay đổi nhưng GBM vẫn là baseline bắt buộc. Nature	PMLBmini, OpenML, Adult, Bank Marketing, Student Performance
2	**Foundation Models cho hồi quy dữ liệu bảng**	Regression	Trong small/medium tabular regression, TabPFN có còn vượt	Nature 2025 đánh giá TabPFN trên **28 regression**	OpenML-CTR23, California Housing, Energy Efficiency,

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
			GBDT khi target noisy, skewed hoặc có outlier?	**datasets**; benchmark 2025 so sánh 20 model trên 111 dataset classification + regression. Nature	Concrete, Bike Sharing
3	**Phân lớp mất cân bằng bằng synthetic data**	Classification	Synthetic minority generation bằng diffusion/GAN có tốt hơn SMOTE không, và khi nào dữ liệu tổng hợp làm classifier tệ hơn?	AAAI 2025 đề xuất **overlap class** để cải thiện synthetic tabular data cho imbalanced classification; survey imbalanced learning tổng hợp long-tail, sampling, cost-sensitive và	Credit Card Fraud, Pima, Adult, Bank Marketing, IEEE Fraud

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				deep methods. AAAI Publications	
4	**Phân lớp đồng thời có class imbalance và label noise**	Classification	Khi minority class cũng có noisy labels, oversampling có khuếch đại noise không? Phương pháp nào cân bằng được recall của minority và robustness?	Systematic review 2025 về **imbalanced classification with label noise** cho thấy trade-off giữa minority preservation, noise robustness và cost; nghiên cứu **Robust long-tailed learning under label noise** tiếp tục	CIFAR-LT cho benchmark; Credit Fraud, medical diagnosis, intrusion datasets cho tabular

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				hướng này. ScienceDirect	
5	**Classification/Regression dưới missing values và feature shift** **1. Phạm vi đề tài nên khảo sát** **Đề tài có thể phát biểu rõ hơn như sau:** **Đánh giá và cải thiện độ bền vững của các mô hình classification/regression trên dữ liệu bảng khi cơ chế thiếu dữ liệu và tập feature tại thời điểm triển khai khác với lúc huấn luyện.** **Nên phân biệt bốn tình huống:** 1. **Missing values thông thường: một số ô dữ liệu bị thiếu.** 2. **Missingness shift: tỷ lệ hoặc cơ chế thiếu thay đổi từ train sang test, ví dụ train theo MCAR nhưng test theo MAR/MNAR.** 3. **Feature disappearance: một hoặc nhiều cột có trong training nhưng mất hoàn toàn khi triển khai.** 4. **Feature distribution/schema shift: feature còn tồn tại nhưng phân phối, đơn vị đo, encoding hoặc ý nghĩa thay đổi.** **TabFSBench là công trình nền tảng gần nhất với phần feature shift; kết quả cho thấy đa số mô hình tabular hiện tại suy giảm đáng kể, đặc biệt khi các feature bị mất là feature quan trọng.**	Cả hai	Model nào suy giảm ít nhất khi một feature bị thiếu, đổi distribution, đổi schema hoặc mất hoàn toàn lúc deployment?	**TabFSBench**, ICML 2025, là benchmark đầu tiên tập trung hệ thống vào tabular **feature shift**; nghiên cứu 2025 về data quality khảo sát 19 thuật toán trên classification, regression và clustering. Proceedings of Machine	OpenML datasets; healthcare, fraud, predictive maintenance

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				Learning Research	

2. Bảng khảo sát chi tiết 20 công trình

#	Công trình	Bài toán và phương pháp chính	Ưu điểm	Hạn chế	Khả năng cải tiến cho đồ án
1	TabFSBench — Cheng et al., ICML 2025	Benchmark bốn dạng feature shift; so sánh tree models, deep tabular models, LLM và tabular foundation models.	Sát nhất với đề tài; thiết kế shift có hệ thống; có benchmark công khai; chỉ ra quan hệ gần tuyến tính giữa importance của feature bị shift và mức suy giảm.	Chủ yếu là benchmark, chưa đưa ra một thuật toán khắc phục tổng quát; chưa khảo sát sâu missingness mechanism shift.	Mở rộng benchmark bằng MCAR→MAR, MCAR→MNAR; thêm calibration, uncertainty và robustness score; xây dựng phương pháp huấn luyện với feature-mask augmentation.
2	Prediction Models That Learn to Avoid Missing Values — Stempfle et	Thêm regularization để cây quyết định, RF, GBT và LASSO ít phụ thuộc	Xử lý trực tiếp test-time missingness; dễ giải thích; có nhiều biến thể cho model phổ	Cần biết hoặc ước lượng xác suất thiếu; có thể hy sinh accuracy	Học xác suất thiếu theo context; regularization phụ thuộc feature importance; kết hợp adversarial

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	al., ICML 2025	vào feature có khả năng thiếu.	biến; giữ performance cạnh tranh.	khi feature quan trọng nhưng hiếm khi thiếu; chưa trực tiếp xử lý feature distribution shift.	feature masking; mở rộng cho classification và regression chung.				
3	What to Expect of Classifiers? — Khosravi et al., IJCAI 2019	Tính kỳ vọng đầu ra của logistic regression theo phân phối của các feature chưa quan sát, thay vì điền một giá trị duy nhất.	Có cơ sở xác suất; tránh bias của mean imputation; tạo được "sufficient explanations".	Giới hạn chủ yếu ở logistic regression và cấu trúc naive Bayes; giả định phân phối có thể không đúng với dữ liệu phức tạp.	Thay naive Bayes bằng normalizing flow/VAE; mở rộng sang multiclass và regression; đánh giá dưới feature shift theo thời gian.				
4	Robust Prediction when Features are Missing	Kết hợp predictor "optimistic" và "conservativ	Tập trung đúng test-time missing features; có phân tích	Phạm vi mô hình tương đối hẹp; không xử lý nhiều	Xây dựng gating network chọn optimistic/conservative theo từng mẫu; mở rộng				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	— Liu et al., IEEE SPL 2020	e" để giảm sai số khi feature không quan sát có giá trị ngoại lai.	robustness; hiệu quả khi feature thiếu có heavy tail hoặc outlier.	missing patterns phức tạp; giả định toán học có thể khó thỏa mãn.	sang GBDT; đánh giá khi nhiều cột mất đồng thời.				
5	Near-optimal Rate of Consistency for Linear Models with Missing Values — Ayme et al., ICML 2022	Phân tích Bayes predictor theo missing pattern và xây dựng estimator có adaptive risk bounds.	Nền tảng lý thuyết mạnh; chỉ ra độ phức tạp tăng theo số pattern; có kết quả minimax.	Tập trung linear regression; khó triển khai trực tiếp trên dữ liệu categorical và phi tuyến lớn.	Dùng làm cơ sở xây dựng pattern clustering hoặc shared-parameter model; kiểm chứng giới hạn lý thuyết trên benchmark thực.				
6	Naive Imputation Implicitly Regularizes High-dimensional Linear Models —	Chứng minh zero imputation dưới MCAR có tác dụng gần giống ridge regularizati	Giải thích vì sao baseline đơn giản có thể hoạt động tốt; rẻ và dễ tái lập; có giá trị lý thuyết.	Chủ yếu MCAR, linear model và dữ liệu chiều cao; không đồng nghĩa	Kiểm tra hiện tượng implicit regularization dưới MAR/MNAR; đề xuất adaptive constant imputation theo				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Ayme et al., ICML 2023	on trong high-dimensional regression.		zero imputation luôn tốt trong MAR/MNAR.	từng feature và mức shift.				
	7 NeuMiss Networks — Le Morvan et al., NeurIPS 2020	Mạng neural dựa trên khai triển Neumann và phép nhân với missingness indicator; học trực tiếp từ dữ liệu thiếu.	Không cần mô hình riêng cho từng missing pattern; complexity không tăng theo $$2^d$$; có phân tích cho MAR và self-masking MNAR.	Lý thuyết dựa nhiều vào linear-Gaussian assumptions; kiến trúc chưa chắc cạnh tranh với GBDT trên mọi tabular dataset.	Kết hợp NeuMiss block với FT-Transformer/TabM; thêm mask-shift training; dùng như baseline direct prediction không qua imputation.				
	8 GAIN — Yoon et al., ICML 2018	GAN cho imputation; generator điền dữ liệu, discriminator xác định ô thật/được điền, có hint vector.	Baseline deep imputation kinh điển; mô hình hóa quan hệ phi tuyến; có code công khai.	GAN khó huấn luyện; có thể mode collapse; thiên về MCAR/MAR; imputation	Thêm downstream-aware loss; conditioning theo missing pattern; dùng Wasserstein loss; đánh giá robustness thay				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				RMSE tốt chưa chắc downstream tốt.	vì chỉ RMSE imputation.				
	9 MIWAE — Mattei & Frellsen, ICML 2019	Importance-weighted autoencoder học trực tiếp từ dữ liệu MAR; hỗ trợ single và multiple imputation.	Có likelihood rõ ràng; biểu diễn uncertainty tốt hơn single imputation; phù hợp dữ liệu liên tục/phức tạp.	Phụ thuộc giả định MAR; tốn chi phí Monte Carlo; tối ưu phức tạp; categorical mixed data cần thiết kế thêm.	Kết hợp predictor với multiple-imputation uncertainty; điều chỉnh latent model cho mixed-type tabular; kiểm tra train-MAR/test-MNAR.				
	10 not-MIWAE — Ipsen et al., ICLR 2021	Mở rộng MIWAE, mô hình hóa đồng thời phân phối dữ liệu và cơ chế missingness cho MNAR.	Xử lý MNAR có nguyên tắc; cho phép đưa prior về self-censoring; có code.	MNAR không identifiability nếu thiếu giả định; nhạy với specification của missingness model;	Sensitivity analysis với nhiều missingness models; ensemble cơ chế MNAR; kết hợp shift detector để phát hiện cơ chế test khác train.				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				training nặng.					
	11 VAEAC — Ivanov et al., ICLR 2019	Một conditional VAE có thể condition trên tập feature quan sát bất kỳ và sinh phần còn thiếu.	Phù hợp arbitrary feature subsets; hỗ trợ numerical và categorical; tạo multiple imputations.	Imputation có thể mờ hoặc sai dưới multimodal distributions; cần đủ dữ liệu để học mọi kiểu mask.	Huấn luyện mask theo feature importance thay vì ngẫu nhiên; thêm supervised loss; dùng ensemble samples để lượng hóa uncertainty.				
	12 HyperImpute — Jarrett et al., ICML 2022	Iterative imputation với tự động chọn model và hyperparameter riêng cho từng cột.	Mạnh trên dữ liệu tabular hỗn hợp; dễ dùng; thư viện mở; bảo vệ giá trị của iterative imputation trước các deep methods.	Chi phí AutoML cao; có nguy cơ leakage nếu imputation trước khi chia fold; tối ưu imputation không trực tiếp tối ưu downstream task.	Nested cross-validation chuẩn; chọn imputer theo validation downstream; cache và warm-start để giảm thời gian; shift-aware model selection.				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	13	MIRACLE — Kyono et al., NeurIPS 2021	Refinement framework khuyến khích imputation bảo toàn cấu trúc nhân quả và đồng thời học missingness mechanism.	Xét MCAR, MAR và MNAR; có thể cải thiện nhiều baseline imputer; diễn giải missingness theo causal graph.	Causal graph khó biết chính xác; sai cấu trúc nhân quả có thể gây bias; triển khai phức tạp.	Học causal graph có uncertainty; so sánh inferred graph với domain graph; đánh giá khi causal structure thay đổi ở test time.				
	14	GRAPE — You et al., NeurIPS 2020	Biểu diễn bảng thành bipartite graph giữa sample và feature; imputation là edge prediction, label prediction là node prediction.	Thống nhất imputation và supervised prediction; học được quan hệ phi tuyến; hỗ trợ downstream-aware representation.	Graph lớn gây tốn bộ nhớ; benchmark gốc chủ yếu MCAR; cấu trúc graph có thể che mất semantics của feature.	Graph mini-batching; embedding feature semantics; thêm mask-mechanism node; kiểm tra khả năng generalize khi cột mới xuất hiện hoặc biến mất.				
	15	MissForest — Stekhoven &	Iterative imputation bằng random	Baseline mạnh, dễ hiểu; xử lý nonlinear	Chậm khi số cột/số mẫu lớn; single	Dùng ExtraTrees/LightGBM để tăng tốc; multiple				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Bühlmann, Bioinformatics 2012	forest cho dữ liệu numerical và categorical.	interaction; có OOB imputation error; phù hợp mixed-type data.	imputation; kém đáng tin khi missing rate rất cao hoặc MNAR.	MissForest; feature-importance-weighted training; đánh giá dưới cột mất hoàn toàn.				
16	MICE — van Buuren & Groothuis-Oudshoorn, JSS 2011	Multiple imputation bằng chained equations; mỗi biến thiếu có một conditional model riêng.	Baseline thống kê chuẩn; hỗ trợ nhiều loại biến; phản ánh uncertainty qua nhiều bộ dữ liệu được điền; có diagnostics.	Phụ thuộc specification và thứ tự các conditional models; chậm; khó bảo đảm joint distribution hợp lệ; thường giả định MAR.	Dùng boosting cho conditional models; automatic predictor selection; downstream-aware pooling; kiểm tra robustness khi mechanism shift.				
17	MissDiff — Ouyang et al., ICML Workshop 2023/preprint	Diffusion model học trên dữ liệu bảng thiếu bằng masked denoising score	Có lập luận consistency; dùng cho cả imputation và synthetic data generation;	Trạng thái xuất bản yếu hơn các bài hội nghị chính; sampling chậm; thiết kế cho	Dùng latent diffusion; classifier-guided imputation; feature-shift conditioning; so sánh utility				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
		matching, tránh pipeline impute-then-generate.	hướng hiện đại.	categorical phức tạp; từng bị từ chối ở ICLR 2024.	downstream thay vì chỉ fidelity.				
	18 SAITS — Du et al., ESWA 2023	Self-attention cho imputation chuỗi thời gian đa biến, kết hợp hai diagonally-masked attention blocks.	Mô hình hóa temporal dependency và feature correlation; code mở; nhanh hơn nhiều mô hình recurrent.	Dành cho time series, không phải tabular tĩnh; attention có thể tốn bộ nhớ; không trực tiếp giải quyết column disappearance.	Dùng nếu dữ liệu đồ án là sensor/healthcare theo thời gian; thêm sensor-dropout training và domain/time shift evaluation.				
	19 Adaptive Optimization for Prediction with Missing Data — 2025	Xem pipeline impute-then-predict dưới góc độ tối ưu thích nghi giữa	Nhấn mạnh mục tiêu cuối là prediction thay vì chỉ tái tạo feature; thích hợp xây dựng	Phương pháp mới, độ phổ biến và số benchmark độc lập còn hạn chế; có thể tăng độ	So sánh “best imputation RMSE” với “best downstream score”; học imputer riêng theo				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
		imputer và predictor.	joint objective.	phức tạp huấn luyện.	classifier/regressor.				
	20 Mask-Conditional Conformal Prediction — 2026	Xây dựng prediction set/interval có coverage theo từng missing mask.	Đánh giá reliability thay vì chỉ accuracy/RMSE; phù hợp deployment có nhiều pattern thiếu; bổ sung tốt cho đề tài robustness.	Công trình rất mới; coverage theo mask có thể khó khi một pattern hiếm; prediction interval/set có thể rộng.	Gom nhóm các mask tương tự; adaptive calibration theo missing rate; báo cáo coverage–width trade-off dưới feature shift.				
	3. So sánh các hướng phương pháp								
	Nhóm	Đại diện	Điểm mạnh chung	Điểm yếu chung	Vai trò nên dùng trong đồ án				
	Imputation đơn giản	Mean/median, zero, missing indicator	Nhanh, dễ tái lập, baseline bắt buộc	Có thể tạo bias và làm mất uncertainty	Baseline thấp nhất				

#	Bài toán nghiên cứu					Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Imputation thống kê	MICE	Có multiple imputation và nền tảng thống kê	Chậm, phụ thuộc giả định MAR và specification	Baseline chuẩn				
	Tree-based imputation	MissForest, HyperImpute	Mạnh cho dữ liệu mixed-type và phi tuyến	Chi phí cao; không tối ưu trực tiếp label prediction	Baseline mạnh				
	Deep generative	GAIN, MIWAE, not-MIWAE, VAEAC, MissDiff	Học phân phối phức tạp; có thể sinh nhiều giá trị hợp lý	Khó huấn luyện; nhạy hyperparameter; cần nhiều dữ liệu	Nhóm mô hình hiện đại				
	Direct prediction	NeuMiss, MA-GBT, GRAPE	Không cần tách imputation khỏi prediction; có thể tối ưu trực tiếp downstream task	Ít implementation chuẩn; đôi khi phụ thuộc kiến trúc hoặc giả định	Nhóm quan trọng nhất để tạo đóng góp				
	Feature-shift robustness	TabFSBench, missing-feature robust prediction	Đánh đúng tình huống deployment	Lĩnh vực mới, chưa có phương pháp thống trị	Trục chính của đồ án				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Uncertainty **Multiple imputation, conformal prediction** **Cho biết khi nào dự đoán không đáng tin** **Tăng chi phí; coverage có thể suy giảm dưới shift** **Đóng góp bổ sung có giá trị**				
	4. Khoảng trống nghiên cứu có thể khai thác **Khoảng trống 1: Các nghiên cứu thường giả định train và test có cùng cơ chế thiếu** **Phần lớn phương pháp được huấn luyện và đánh giá với cùng một missing rate hoặc cùng MCAR mechanism. Trong thực tế:** • **train: MCAR 10%;** • **test: MAR 30%;** • **deployment: một cột mất hoàn toàn.** **Đây là missingness mechanism shift, chưa được benchmark đầy đủ.** **Khả năng đóng góp: thiết kế ma trận thí nghiệm train-mechanism × test-mechanism.**				
	Khoảng trống 2: Imputation accuracy không đồng nghĩa prediction accuracy				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Một imputer có RMSE thấp chưa chắc giữ được decision boundary hoặc ranking của mẫu. **Khả năng đóng góp: đánh giá song song:** • **NRMSE hoặc MAE của giá trị được điền;** • **Accuracy, macro-F1, AUROC cho classification;** • **RMSE, MAE, $$R^2$$ cho regression;** • **mức giảm hiệu năng so với dữ liệu đầy đủ.** **Có thể đề xuất task-aware imputation, trong đó loss gồm:** **$$ L = L*{\text{imputation}}*+\lambda L*{\text{prediction}}. $$**				
	Khoảng trống 3: Feature bị mất có mức quan trọng khác nhau **Randomly removing columns có thể tạo benchmark quá dễ. TabFSBench cho thấy mức giảm hiệu năng liên quan mạnh tới importance của tập feature bị shift.** **Khả năng đóng góp: tạo ba chính sách:** • **random feature removal;** • **loại feature quan trọng nhất;** • **loại nhóm feature tương quan hoặc cùng nguồn thu thập.**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Khoảng trống 4: Mô hình mạnh có thể không đáng tin **Accuracy/RMSE có thể vẫn chấp nhận được nhưng xác suất dự đoán bị overconfident.** **Khả năng đóng góp: thêm:** • **Expected Calibration Error;** • **Brier score;** • **Negative Log-Likelihood;** • **conformal coverage;** • **prediction-set size hoặc interval width.**				
	Khoảng trống 5: Chưa có phương pháp đơn giản đóng vai trò "universal baseline" **Các deep imputer thường phức tạp, trong khi zero imputation, missing indicators, CatBoost hoặc native missing routing có thể cạnh tranh tốt.** **Khả năng đóng góp: xây dựng một baseline đơn giản:** **Feature Mask Augmentation + Missing Indicator + Importance-aware Dropout + GBDT/MLP**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Nếu baseline đơn giản thắng các imputer phức tạp trong nhiều shift scenarios, đó vẫn là một kết quả đồ án tốt.				
	5. Đề xuất hướng đồ án khả thi nhất **Tên đề tài đề xuất** **Robust Classification and Regression under Missingness Mechanism Shift and Feature Disappearance** **Hoặc tiếng Việt:** **Đánh giá và cải thiện độ bền vững của mô hình phân lớp và hồi quy khi cơ chế thiếu dữ liệu và tập đặc trưng thay đổi tại thời điểm triển khai** **Câu hỏi nghiên cứu** • **RQ1: Thứ hạng của các mô hình có thay đổi khi tỷ lệ thiếu ở test khác train không?** • **RQ2: Mô hình nào bền vững nhất khi feature quan trọng bị mất hoàn toàn?** • **RQ3: Imputation quality có tương quan với downstream prediction quality không?** • **RQ4: Feature-mask augmentation có cải thiện robustness không?** • **RQ5: Calibration và uncertainty thay đổi như thế nào dưới missingness shift?**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Giả thuyết • **H1: Native-missing tree models suy giảm ít hơn impute-then-predict khi missing rate thay đổi vừa phải.** • **H2: Deep imputers chỉ vượt baseline đơn giản khi dữ liệu đủ lớn và quan hệ giữa các feature đủ mạnh.** • **H3: Huấn luyện với nhiều random masks cải thiện robustness với feature disappearance.** • **H4: Feature removal theo importance gây suy giảm lớn hơn đáng kể so với random removal ở cùng số cột.** • **H5: Model có accuracy tốt nhất chưa chắc có calibration tốt nhất.**				
	6. Thiết kế thực nghiệm **Dataset** **Nên chọn khoảng 6–10 dataset, cân bằng classification và regression.** **Classification:** • **Adult Income;** • **Bank Marketing;** • **Credit Approval;** • **Default of Credit Card Clients;** • **Heart Disease;** • **Diabetes;**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	• **Covertype.** **Regression:** • **California Housing;** • **Energy Efficiency;** • **Concrete Strength;** • **Bike Sharing;** • **Airfoil Self-Noise;** • **Wine Quality.** **Cơ chế tạo missing values** **Cơ chế** — **Cách mô phỏng** **MCAR** — **Xóa ngẫu nhiên từng ô độc lập** **MAR** — **Xác suất thiếu của feature $$X*j$$ phụ thuộc một feature quan sát $$X*k$$** **MNAR self-masking** — **Xác suất thiếu của $$X*j$$ phụ thuộc chính giá trị $$X*j$$** **Block missing** — **Xóa một nhóm giá trị liên tiếp hoặc nhóm feature** **Column disappearance** — **Xóa toàn bộ một hoặc nhiều cột ở test** **Importance-based removal** — **Xóa các cột có importance cao nhất** **Distribution shift** — **Dịch mean, scale, category frequency hoặc nhiễu đo của một số feature** **Combined shift** — **Đồng thời missingness shift và distribution shift**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Mức độ corruption • **Missing rate: 10%, 30%, 50%, 70%.** • **Số cột mất hoàn toàn: 1, 2, 3 và 25% số feature.** • **Distribution shift strength: nhẹ, vừa, mạnh.** **Mô hình dự đoán** • **Logistic/Linear Regression;** • **Random Forest;** • **XGBoost;** • **LightGBM;** • **CatBoost;** • **MLP;** • **FT-Transformer hoặc TabM;** • **NeuMiss;** • **MA-GBT nếu triển khai được.** **Phương pháp xử lý thiếu** • **Mean/mode;** • **Zero imputation;** • **Mean + missing indicators;** • **KNN Imputer;** • **MICE;** • **MissForest;** • **HyperImpute;** • **GAIN;**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	• **MIWAE hoặc VAEAC;** • **Native missing handling của CatBoost/LightGBM.** **Metric** **Classification** • **Accuracy;** • **macro-F1;** • **AUROC;** • **PR-AUC;** • **Brier score;** • **ECE.** **Regression** • **RMSE;** • **MAE;** • **$$R^2$$;** • **interval coverage;** • **interval width.** **Robustness** **Nên báo cáo thêm:** **$$**				

	\text{Relative Degradation} **\frac{S*{\text{clean}}-S*{\text{shift}}} {|S_{\text{clean}}|}. $$** **Với metric càng thấp càng tốt như RMSE:** **$$** **\text{Relative Increase}** **\frac{E*{\text{shift}}-E*{\text{clean}}} {E_{\text{clean}}}. $$** **Có thể lấy diện tích dưới đường cong hiệu năng theo missing rate làm Robustness AUC.**				
	7. Phương pháp cải tiến nên thử **Feature-mask augmentation** **Trong quá trình training, ngẫu nhiên mask một số feature:** **$$ \widetilde{x}=x\odot m, $$** **với $$m$$ là binary mask. Ghép mask vào input:** **$$ z=[\widetilde{x},m]. $$** **Điểm mới có thể là không chọn mask hoàn toàn ngẫu nhiên mà dùng:** **$$ P(mj=0)\propto \alpha qj+(1-\alpha)I_j, $$**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	trong đó: • **$$q_j$$: xác suất feature $$j$$ bị thiếu trong thực tế;** • **$$I_j$$: importance chuẩn hóa của feature;** • **$$\alpha$$: hệ số cân bằng giữa missing frequency và feature importance.** **Consistency regularization** **Yêu cầu dự đoán trên dữ liệu đầy đủ và dữ liệu bị mask không khác nhau quá lớn:** **$$** **L_{\text{cons}}** **D\big(f(x),f(x\odot m)\big). $$** **Loss tổng:** **$$ L=L*{\text{task}}+\lambda*1L*{\text{cons}}+\lambda*2L_{\text{mask}}. $$** **Ensemble theo missing pattern** • **phân cụm các missing masks;** • **huấn luyện một expert cho mỗi nhóm pattern;** • **dùng gating network chọn expert khi inference.**				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Cách này giảm vấn đề phải tạo $$2^d$$ mô hình riêng như phân tích trong các nghiên cứu lý thuyết về missing patterns.				
	8. Ablation study cần có **Ablation** — **Mục đích** **Không missing indicator** — **Kiểm tra mask có mang thông tin dự đoán hay không** **Random mask so với importance-aware mask** — **Đánh giá lợi ích của chiến lược mask** **Imputation loss đơn lẻ so với joint loss** — **Kiểm tra task-aware learning** **Train một missing rate so với nhiều missing rates** — **Kiểm tra khả năng generalize** **Train MCAR, test MAR/MNAR** — **Đo missingness mechanism shift** **Random feature removal so với top-important removal** — **Đo tác động của importance** **Không consistency loss** — **Xác định đóng góp của regularization** **Classification so với regression** — **Xác định phương pháp có tổng quát hay không**				
	9. Kết luận lựa chọn hướng				

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
	Hướng cân bằng tốt nhất giữa tính mới, khả năng triển khai và giá trị báo cáo là: **Xây dựng benchmark classification/regression dưới missingness shift và feature disappearance; sau đó đề xuất importance-aware feature-mask augmentation kết hợp consistency regularization.** **Đóng góp dự kiến:** **1. Một protocol đánh giá thống nhất cho MCAR, MAR, MNAR và mất toàn bộ cột.** **2. So sánh công bằng giữa imputation, native-missing models và direct-prediction models.** **3. Chỉ ra trường hợp imputation tốt nhưng prediction không tốt.** **4. Đề xuất một phương pháp mask augmentation đơn giản, dễ tái lập.** **5. Phân tích accuracy, robustness, calibration và chi phí tính toán.** **Đây là hướng phù hợp đồ án vì không bắt buộc phải xây dựng mô hình cực lớn, nhưng vẫn có khoảng trống rõ ràng, baseline mạnh và khả năng tạo đóng góp thực nghiệm tốt.**				
6	**Phân lớp có độ tin cậy: Calibration + Conformal Prediction**	Classification	Accuracy tốt nhưng confidence có đáng tin không? Calibration	ICML 2025 **On Temperature Scaling and Conformal**	Adult, Credit, medical classification, OpenML

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
			ảnh hưởng thế nào đến kích thước conformal prediction set và class-wise coverage?	**Prediction of Deep Classifiers** phân tích trực tiếp tương tác giữa calibration và CP; ACM CSUR 2025 tổng hợp conformal prediction hiện đại. Proceedings of Machine Learning Research	
7	**Hồi quy kèm khoảng dự đoán thay vì chỉ point prediction**	Regression	Hai model có RMSE giống nhau nhưng model nào tạo prediction interval hẹp và	PMLR 2025 **A Review and Comparative Analysis of**	California Housing, Energy, Concrete, Air Quality, giá dầu

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
			đúng coverage hơn?	**Univariate Conformal Regression Methods** thực nghiệm 8 nhóm conformal regression methods; ACM survey 2025 cung cấp góc nhìn tổng thể. Proceedings of Machine Learning Research	
8	**Phân lớp/hồi quy dưới Distribution Shift và OOD**	Cả hai	Một model tốt trên random split có còn tốt khi test data đến từ thời gian, bệnh viện, vùng địa	ACM CSUR 2025 tổng hợp recent OOD detection; benchmark	MIMIC/eICU, OpenML, finance/time-split datasets

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
			lý hay population khác?	2025 trên medical tabular data nhấn mạnh vấn đề overconfidence khi gặp OOD. DOI	
9	**Hồi quy chuỗi thời gian bằng Time-Series Foundation Models**	Regression / Forecasting	Zero-shot foundation models có thực sự vượt mô hình train riêng trên domain? Khi nào fine-tuning giúp hoặc làm giảm generalization?	**Chronos**; **TimesFM** – ICML 2024; **MOMENT** – ICML 2024. Chronos được benchmark trên 42 datasets, TimesFM dùng pretraining corpus rất lớn, MOMENT hỗ trợ nhiều time-	Monash Forecasting Archive, ETT, Electricity, Traffic, Weather, Brent/WTI

#	Bài toán nghiên cứu	Loại	Research Question gợi ý	Công trình mạnh/SOTA nên khảo sát	Dataset gợi ý
				series tasks. arXiv	
10	**Graph-based Classification/Regression và Graph Foundation Models**	Cả hai	Graph structure có giúp hơn tabular features? Foundation model có transfer được giữa các graph/domain không?	KDD 2025 survey **Graph Foundation Models: Challenges, Methods, and Open Questions** tổng hợp backbone, pretraining, adaptation và các vấn đề transferability, heterogeneity, structural alignment. DOI	OGB, Cora, Citeseer, PubMed, molecular property datasets

1. Tabular Foundation Models cho classification: hướng rất phù hợp học viên

Một đề tài cụ thể có thể là:

When do Tabular Foundation Models outperform Gradient-Boosted Trees in small-data classification?

Không nên chỉ so:

`TabPFN vs XGBoost → Accuracy.`

Nên thiết kế theo các trục:

- số mẫu: 100, 250, 500, 1.000, 5.000;
- imbalance ratio;
- number of features;
- categorical/numerical ratio;
- missing rate;
- label noise.

Baseline:

Logistic Regression → Random Forest → XGBoost → LightGBM → CatBoost → TabM → TabPFN.

TabPFN Nature 2025 báo cáo hiệu quả đặc biệt mạnh trong nhóm dữ liệu dưới khoảng 10.000 mẫu và 500 features, vì vậy một hướng paper tốt là tìm **điều kiện biên nơi ưu thế này biến mất**. Nature

---

2. Tabular Foundation Models cho regression

Research Question có thể sâu hơn:

Does the advantage of TabPFN persist under heteroscedastic noise and target outliers?

Tạo controlled corruption:

$$y' = y + \epsilon$$

với:

- Gaussian noise;
- heavy-tailed noise;
- outlier contamination;
- nonlinear noise.

Đánh giá:

- RMSE;
- MAE;
- R^2;
- runtime;
- sensitivity to noise.

Đây là hướng khá **dễ triển khai nhưng vẫn có thể tạo đóng góp thực nghiệm tốt**, vì landscape tabular hiện vẫn chưa có một phương pháp thống trị cho mọi kích thước và cấu trúc dataset. Benchmark 2025 trên 111 dataset cũng nhấn mạnh việc DL không mặc nhiên vượt GBM. ScienceDirect

---

3. Imbalanced Classification: nên đi xa hơn SMOTE

Không nên đặt đề tài đơn giản:

"So sánh SMOTE, ADASYN và Random Oversampling."

Hướng tốt hơn:

Can modern tabular generative models generate useful minority-class samples near the decision boundary?

Pipeline:

Original Data
→ SMOTE / ADASYN
→ CTGAN / TabDDPM
→ overlap-aware generation
→ XGBoost / CatBoost / TabPFN
→ minority performance.

Metric cần ưu tiên:

- PR-AUC;
- Recall minority;
- F1 minority;
- Balanced Accuracy;
- MCC.

AAAI 2025 cho thấy việc sinh synthetic minority data bản thân nó cũng gặp vấn đề: generative model thường sinh minority sample kém hơn majority, và paper đề xuất thêm một lớp overlap để giảm vấn đề này. AAAI Publications

---

4. Imbalance + Label Noise: tôi đánh giá có tiềm năng paper cao

Trong thực tế:

```
Minority class
+
Few samples
+
Wrong labels
```

là tình huống rất phổ biến.

RQ:

Does oversampling amplify mislabeled minority samples?

Có thể tạo:

$$NoiseRate \in \{0,5,10,20,30\backslash\%\}$$

và:

$$ImbalanceRatio \in \{1:5,1:10,1:20,1:50\}$$

Sau đó khảo sát surface:

$$Performance = f(Noise, Imbalance)$$

Điểm đóng góp không nhất thiết là model mới. Một **benchmark study được thiết kế tốt** cũng có giá trị.

---

5. Feature Shift: một hướng KDD rất đáng làm

Ví dụ hệ thống dự đoán sinh viên bỏ học được train với:

```
Age
Attendance
GPA
LMS_Login
Assignment
FamilyIncome
```

nhưng khi triển khai:

```
FamilyIncome
```

không còn thu thập được.

Hoặc measurement protocol của `Attendance` thay đổi.

Đây không chỉ là missing value thông thường mà là:

Feature Shift / Open-Environment Tabular Learning.

TabFSBench tại ICML 2025 được xây dựng chính để nghiên cứu bốn loại feature shift và cho thấy đây là một khoảng trống của tabular ML. Proceedings of Machine Learning Research

Một RQ tốt:

Which tabular models remain reliable when subsets of features disappear or change distribution at deployment time?

---

6. Classification: từ accuracy sang reliable prediction

Thay vì classifier trả:

```
Fraud
Probability = 0.97
```

hãy hỏi:

97% đó có thực sự có nghĩa là trong 100 trường hợp tương tự, khoảng 97 trường hợp đúng không?

Nghiên cứu:

Accuracy + Calibration + Conformal Prediction

Metric:

- Accuracy/F1/AUC;

- ECE;
- Brier score;
- coverage;
- prediction-set size;
- class-conditional coverage.

ICML 2025 chỉ ra Temperature Scaling có thể cải thiện một số khía cạnh coverage của conformal methods nhưng đồng thời ảnh hưởng tới prediction-set size, tạo ra một trade-off khá thú vị để nghiên cứu. Proceedings of Machine Learning Research

---

7. Regression: "RMSE tốt" chưa đủ

Ví dụ dự báo: $\hat{y} = 82.5$

không hữu ích bằng:

$$\hat{y} = 82.5, \quad PI = [79.1, 86.3]$$

nếu quyết định nghiệp vụ cần biết uncertainty.

Có thể so:

- Linear/Ridge;
- Random Forest;
- XGBoost;
- CatBoost;
- TabPFN;

sau đó bọc bằng:

- Split Conformal;
- CV+;

- Jackknife+;
- Conformalized Quantile Regression.

RQ:

Which combination of base regressor and conformal method gives the best coverage–interval-width trade-off?

Đây là hướng đặc biệt phù hợp với các bài toán **giá dầu, năng lượng, giá nhà, nhu cầu**. Proceedings of Machine Learning Research

---

8. Distribution Shift: nên thay random split bằng realistic split

Một lỗi rất phổ biến trong paper:

```
Random 80/20 split
```

trong khi hệ thống thực tế là:

```
Past → Future
Hospital A → Hospital B
Region A → Region B
Customer population 2025 → 2026
```

Nghiên cứu nên so:

$$Performance_{IID}$$

và:

$$Performance_{OOD}$$

Một câu hỏi mạnh:

Do rankings of SOTA classifiers remain unchanged under realistic distribution shifts?

Câu trả lời hoàn toàn có thể trở thành đóng góp paper mà không cần tạo architecture mới.

---

9. Time-Series Regression / Forecasting

Đây hiện là hướng rất sôi động.

Có thể so:

Classical

- ARIMA;
- ETS.

Machine Learning

- XGBoost;
- LightGBM.

Deep Learning

- LSTM;
- PatchTST.

Foundation Models

- Chronos;
- TimesFM;
- MOMENT.

Chronos báo cáo khả năng zero-shot cạnh tranh trên nhiều dataset chưa thấy khi huấn luyện; TimesFM cũng được thiết kế cho zero-shot forecasting; MOMENT mở rộng foundation-model paradigm sang nhiều time-series tasks. arXiv

Research Question tốt hơn "ai RMSE thấp nhất" là:

When does zero-shot forecasting beat domain-specific supervised learning?

---

10. Graph Classification/Regression

Ví dụ thay vì dự đoán fraud chỉ từ:

```
Amount
Time
Age
Device
```

hãy thêm graph:

```
Account → Device
Account → Account
Account → Merchant
```

RQ:

How much predictive information comes from relational structure beyond ordinary tabular features?

Có thể xây dựng ablation:

Tabular only
vs
Graph only

vs
Tabular + Graph

và đánh giá:

- node classification;
- graph classification;
- molecular property regression;
- risk prediction.

Graph Foundation Models hiện là hướng nghiên cứu mở mạnh; survey KDD 2025 liệt kê transferability, heterogeneity, structural alignment, scalability và evaluation là những vấn đề chưa giải quyết hoàn toàn. DOI