Phần 1

Tiêu đề

TabFSBench: Bộ tiêu chuẩn đánh giá dữ liệu bảng cho hiện tượng dịch chuyển đặc trưng trong môi trường mở [cheng25e | PDF]

Tóm tắt

Dữ liệu dạng bảng được sử dụng rộng rãi trong nhiều nhiệm vụ học máy. Nghiên cứu hiện nay về học máy trên dữ liệu bảng chủ yếu tập trung vào các môi trường đóng, trong khi các ứng dụng thực tế thường hoạt động trong môi trường mở, nơi xảy ra các hiện tượng dịch chuyển phân phối dữ liệu và dịch chuyển đặc trưng, dẫn đến sự suy giảm đáng kể hiệu năng của mô hình. Các nghiên cứu trước đây chủ yếu tập trung vào việc giảm thiểu tác động của dịch chuyển phân phối, trong khi dịch chuyển đặc trưng, một thách thức đặc thù và còn ít được khám phá của dữ liệu bảng, lại nhận được rất ít sự quan tâm.

Để giải quyết vấn đề này, bài báo thực hiện nghiên cứu toàn diện đầu tiên về dịch chuyển đặc trưng trong dữ liệu bảng và giới thiệu bộ tiêu chuẩn đánh giá dịch chuyển đặc trưng đầu tiên dành cho dữ liệu bảng mang tên **TabFSBench**.

TabFSBench đánh giá tác động của bốn kịch bản dịch chuyển đặc trưng khác nhau trên bốn nhóm mô hình dữ liệu bảng, trải rộng trên nhiều bộ dữ liệu khác nhau. Đồng thời, nghiên cứu cũng lần đầu tiên đánh giá hiệu năng của các mô hình ngôn ngữ lớn (LLM) và các LLM chuyên biệt cho dữ liệu bảng trong bộ tiêu chuẩn này.

Nghiên cứu đưa ra ba quan sát chính:

1. Phần lớn các mô hình dữ liệu bảng hiện có chỉ có khả năng thích ứng hạn chế trong các tình huống dịch chuyển đặc trưng.
2. Mức độ quan trọng của các đặc trưng bị dịch chuyển có mối quan hệ tuyến tính với mức suy giảm hiệu năng của mô hình.
3. Hiệu năng của mô hình trong môi trường đóng có tương quan với hiệu năng của mô hình trong các tình huống dịch chuyển đặc trưng.

Ngoài ra, bài báo cũng đề xuất các hướng nghiên cứu và khuyến nghị cho tương lai dựa trên các quan sát này. [cheng25e | PDF]

---

1. Giới thiệu

Dữ liệu dạng bảng (tabular data) là một dạng dữ liệu được tổ chức chặt chẽ dưới dạng hàng và cột, trong đó mỗi hàng đại diện cho một bản ghi và mỗi cột tương ứng với một đặc trưng. Dữ liệu bảng được ứng dụng rất rộng rãi trong thực tế.

Ví dụ:

- Trong lĩnh vực tài chính, dữ liệu bảng được sử dụng cho các bài toán đánh giá tín dụng và dự báo thị trường chứng khoán.
- Trong lĩnh vực y tế, dữ liệu bảng là nền tảng cho các ứng dụng như chẩn đoán bệnh và phát triển dược phẩm. [cheng25e | PDF]

Các mô hình học máy dành cho dữ liệu bảng hiện nay có thể được chia thành bốn nhóm chính:

1. Mô hình dựa trên cây quyết định (Tree-based Models).
2. Mô hình học sâu (Deep Learning Models).
3. Mô hình ngôn ngữ lớn (LLMs).
4. Các LLM chuyên biệt cho dữ liệu bảng (Tabular LLMs). [cheng25e | PDF]

Các mô hình này đã thể hiện hiệu quả rất cao trên nhiều nhiệm vụ dữ liệu bảng khác nhau. Tuy nhiên, hầu hết chúng được huấn luyện và đánh giá trong các môi trường đóng, nơi phân phối dữ liệu và tập đặc trưng luôn được duy trì nhất quán giữa giai đoạn huấn luyện và kiểm thử. [cheng25e | PDF]

Trong thực tế, các bài toán dữ liệu bảng thường diễn ra trong môi trường mở, nơi xuất hiện những thách thức đáng kể như:

- Dịch chuyển phân phối dữ liệu (Distribution Shift).
- Dịch chuyển đặc trưng (Feature Shift). [cheng25e | PDF]

Ví dụ, trong một hệ thống quản lý giao thông:

- Các sự kiện bất thường như thời tiết cực đoan có thể làm thay đổi phân phối dữ liệu lưu lượng giao thông.
- Việc một số thiết bị giám sát giao thông bị hỏng hoặc được thay thế bằng thiết bị mới có thể gây ra dịch chuyển đặc trưng. [cheng25e | PDF]

Những thay đổi động này làm tăng độ phức tạp và tính khó dự đoán của các bài toán học máy trong môi trường mở, từ đó đòi hỏi các mô hình phải có khả năng thích ứng và độ bền vững cao hơn. [cheng25e | PDF]

Do đó, các nghiên cứu gần đây ngày càng tập trung vào việc phát triển các mô hình học máy trên dữ liệu bảng có thể hoạt động hiệu quả trong môi trường mở. Nhiều công trình đã nghiên cứu sâu về hiện tượng dịch chuyển phân phối dữ liệu và đề xuất các giải pháp như thích nghi miền (Domain Adaptation) và khái quát hóa miền (Domain Generalization). Đồng thời, một số bộ chuẩn đánh giá như TableShift và Wild-Tab cũng đã được xây dựng để nghiên cứu vấn đề này. [cheng25e | PDF]

Tuy nhiên, dịch chuyển đặc trưng lại là một thách thức phổ biến khác nhưng chưa được nghiên cứu đầy đủ. Hiện tượng này xảy ra khi tập đặc trưng mà mô hình có thể sử dụng thay đổi theo thời gian hoặc không gian. Ví dụ, trong bài toán dự báo thời tiết, một số cảm biến quan trọng có thể ngừng hoạt động do hỏng hóc hoặc lão hóa, hoặc được thay thế bởi các cảm biến mới sau khi nâng cấp công nghệ. Điều này làm thay đổi đáng kể các đặc trưng đầu vào mà mô hình có thể sử dụng. [cheng25e | PDF]

Sự thay đổi này không chỉ phá vỡ tính nhất quán của dữ liệu đầu vào mà còn có thể làm suy giảm đáng kể hiệu năng và độ ổn định của mô hình. Mặc dù vậy, các nghiên cứu về dịch chuyển đặc trưng vẫn còn rất hạn chế và hiện chưa có nhiều bộ chuẩn chất lượng cao dành cho kịch bản này. [cheng25e | PDF]

Các đóng góp chính của bài báo

- Xây dựng bộ chuẩn TabFSBench dành cho các kịch bản dịch chuyển đặc trưng.
- Cung cấp các bộ dữ liệu công khai cho cả bài toán phân loại và hồi quy.
- Thiết kế bốn kịch bản dịch chuyển đặc trưng để đánh giá mô hình.
- Đánh giá bốn nhóm mô hình dữ liệu bảng khác nhau.
- Thực hiện đánh giá đầu tiên về LLM và Tabular LLM trong bối cảnh dịch chuyển đặc trưng.
- Xây dựng API phục vụ các nghiên cứu trong tương lai.
- Thực hiện nghiên cứu thực nghiệm quy mô lớn và rút ra các kết luận quan trọng về khả năng thích ứng của mô hình trong môi trường mở. [cheng25e | PDF]

Phần 2. Nhiệm vụ và Ký hiệu

2.1. Thiết lập bài toán

Một cách hình thức, mục tiêu của các bài toán dự đoán trên dữ liệu bảng là huấn luyện một mô hình học máy:

$$f: X \to Y$$

Trong đó:

- **X** là không gian đầu vào.
- **Y** là không gian đầu ra.

Tập các đặc trưng (features) trong dữ liệu đầu vào X được ký hiệu là **C**. [cheng25e | PDF]

2.2. Ký hiệu về dịch chuyển đặc trưng (Feature Shift)

Nhóm tác giả chia tập đặc trưng C thành hai tập:

- **Ctrain**: tập đặc trưng dùng trong giai đoạn huấn luyện.
- **Ctest**: tập đặc trưng dùng trong giai đoạn kiểm thử. [cheng25e | PDF]

Môi trường đóng (Closed Environment)

Trong môi trường đóng:

$$C_{train} = C_{test}$$

Nghĩa là tập đặc trưng ở giai đoạn huấn luyện và kiểm thử hoàn toàn giống nhau. [cheng25e | PDF]

Môi trường mở (Open Environment)

Trong môi trường mở:

- Tập đặc trưng huấn luyện vẫn được giữ nguyên.
- Tập đặc trưng kiểm thử có thể thay đổi.

Từ đó phát sinh hai loại thách thức:

1. **Distribution Shift** (Dịch chuyển phân phối)
2. **Feature Shift** (Dịch chuyển đặc trưng) [cheng25e | PDF]

Để minh họa, bài báo sử dụng ví dụ về hệ thống giám sát bệnh trên rừng, trong đó mỗi cảm biến được xem như một đặc trưng của dữ liệu. [cheng25e | PDF]

Dịch chuyển phân phối (Distribution Shift)

Giả sử:

- Một số cảm biến cũ ngừng hoạt động.
- Các cảm biến mới được lắp đặt thay thế.

Trong trường hợp này:

- Số lượng đặc trưng không đổi.
- Tên và cấu trúc đặc trưng vẫn giữ nguyên.

Tuy nhiên:

- Độ chính xác đo đạc của cảm biến có thể thay đổi.
- Phân phối dữ liệu thu được khác với trước đây.

Do đó:

$$C_{train} = C_{test}$$

nhưng phân phối dữ liệu giữa hai giai đoạn là khác nhau. Hiện tượng này được gọi là **dịch chuyển phân phối**. [cheng25e | PDF]

Mô hình vẫn có thể tạo ra dự đoán mà không cần xử lý bổ sung, nhưng hiệu năng thường bị suy giảm do:

- Covariate shift (dịch chuyển biến đầu vào)
- Concept shift (dịch chuyển khái niệm) [cheng25e | PDF]

Dịch chuyển đặc trưng (Feature Shift)

Dịch chuyển đặc trưng xảy ra khi:

$$C_{train} \neq C_{test}$$

Tức là tập đặc trưng có sẵn ở thời điểm kiểm thử khác với tập đặc trưng khi huấn luyện. [cheng25e | PDF]

Điều này có thể xảy ra do:

- Một số cảm biến bị hỏng.

- Một số cảm biến bị loại bỏ.
- Các cảm biến mới được bổ sung.
- Hệ thống thu thập dữ liệu được nâng cấp theo thời gian. [cheng25e | PDF]

Khác với distribution shift, feature shift gây ra vấn đề nghiêm trọng hơn vì:

- Mô hình được huấn luyện trên một tập đặc trưng.
- Khi triển khai lại nhận được một tập đặc trưng khác.

Do đó dữ liệu đầu vào không còn tương thích trực tiếp với mô hình. [cheng25e | PDF]

Bảng 1. Các bộ dữ liệu trong TabFSBench

Bộ chuẩn TabFSBench bao gồm các bộ dữ liệu cho cả bài toán **phân loại** và **hồi quy**. [cheng25e | PDF]

Phân loại nhị phân (Binary Classification)

Dataset	Số mẫu	Đặc trưng số	Đặc trưng phân loại	Số lớp
credit	1.000	7	13	2
electricity	45.312	8	0	2
heart	918	6	5	2
MiniBooNE	72.998	50	0	2

[cheng25e | PDF]

Phân loại nhiều lớp (Multi-Class Classification)

Dataset	Số mẫu	Đặc trưng số	Đặc trưng phân loại	Số lớp
Iris	150	4	0	3
penguins	345	4	2	3
eye_movements	10.936	27	0	4

jannis	83.733	54	0	4

[cheng25e | PDF]

Hồi quy (Regression)

Dataset	Số mẫu	Đặc trưng số	Đặc trưng phân loại
abalone	4.178	7	1
bike	10.886	6	3
concrete	1.031	8	0
laptop	1.275	8	14

[cheng25e | PDF]

Ý chính của Phần 2

Sau khi xác định khái niệm Feature Shift, nhóm tác giả muốn nghiên cứu câu hỏi:

Khi một số đặc trưng bị mất hoặc xuất hiện thêm trong giai đoạn kiểm thử, các mô hình dữ liệu bảng hiện nay sẽ bị ảnh hưởng như thế nào? [cheng25e | PDF]

Để trả lời câu hỏi đó, họ xây dựng **TabFSBench** với nhiều bộ dữ liệu, nhiều loại mô hình và nhiều kịch bản dịch chuyển đặc trưng khác nhau nhằm đánh giá mức độ suy giảm hiệu năng trong môi trường mở. [cheng25e | PDF]

Tiếp theo là **Phần 3: TabFSBench Benchmark**, nơi bài báo trình bày chi tiết 4 kịch bản Feature Shift (Single Shift, Most-Relevant Shift, Least-Relevant Shift và Random Shift). Đây là phần quan trọng nhất của bài báo.

Phần 3. TabFSBench Benchmark

Trong phần này, nhóm tác giả trình bày cấu trúc của bộ chuẩn **TabFSBench**, bao gồm các kịch bản dịch chuyển đặc trưng, phương pháp đánh giá và các mô hình được sử dụng để thử nghiệm. [cheng25e | PDF]

3.1. Các kịch bản dịch chuyển đặc trưng

Một trong những đóng góp quan trọng nhất của TabFSBench là thiết kế bốn kịch bản Feature Shift nhằm mô phỏng các tình huống thực tế mà mô hình có thể gặp phải sau khi được triển khai. [cheng25e | PDF]

1. Single Shift (Dịch chuyển đơn lẻ)

Trong kịch bản này:

- Chỉ một đặc trưng bị thay đổi giữa giai đoạn huấn luyện và kiểm thử.
- Đặc trưng đó có thể bị loại bỏ hoặc thay thế.
- Các đặc trưng còn lại được giữ nguyên. [cheng25e | PDF]

Mục tiêu

Đánh giá:

Mỗi đặc trưng riêng lẻ ảnh hưởng đến hiệu năng mô hình ở mức độ nào khi không còn xuất hiện trong dữ liệu kiểm thử. [cheng25e | PDF]

Ưu điểm của kịch bản này là cho phép phân tích chi tiết ảnh hưởng của từng đặc trưng đối với kết quả dự đoán. [cheng25e | PDF]

---

2. Most-Relevant Shift (Dịch chuyển đặc trưng quan trọng nhất)

Trong kịch bản này:

- Những đặc trưng được đánh giá là quan trọng nhất đối với mô hình sẽ bị loại bỏ khỏi dữ liệu kiểm thử. [cheng25e | PDF]

Các đặc trưng quan trọng được xác định thông qua các phương pháp đo Feature Importance. [cheng25e | PDF]

Mục tiêu

Mô phỏng các tình huống nghiêm trọng trong thực tế:

- Các cảm biến quan trọng bị hỏng.
- Các nguồn dữ liệu giá trị cao bị mất.
- Những biến dự báo mạnh nhất không còn khả dụng. [cheng25e | PDF]

Đây được xem là trường hợp bất lợi nhất đối với mô hình. [cheng25e | PDF]

---

3. Least-Relevant Shift (Dịch chuyển đặc trưng ít quan trọng nhất)

Ngược lại với Most-Relevant Shift:

- Các đặc trưng ít quan trọng nhất bị loại bỏ khỏi tập dữ liệu kiểm thử. [cheng25e | PDF]

Mục tiêu

Đánh giá:

Nếu mô hình mất đi các đặc trưng gần như không đóng góp vào dự đoán thì hiệu năng sẽ bị ảnh hưởng bao nhiêu. [cheng25e | PDF]

Kịch bản này giúp xác định liệu mô hình có đang phụ thuộc quá mức vào các đặc trưng ít ý nghĩa hay không. [cheng25e | PDF]

---

4. Random Shift (Dịch chuyển ngẫu nhiên)

Trong trường hợp này:

- Các đặc trưng bị loại bỏ một cách ngẫu nhiên.
- Không xét tới mức độ quan trọng của đặc trưng. [cheng25e | PDF]

Mục tiêu

Mô phỏng các tình huống ngoài thực tế như:

- Lỗi thu thập dữ liệu xảy ra bất ngờ.
- Hệ thống cảm biến hoạt động không ổn định.
- Một số nguồn dữ liệu bị mất không theo quy luật. [cheng25e | PDF]

Đây là kịch bản phản ánh môi trường vận hành thực tế nhất. [cheng25e | PDF]

3.2. Các nhóm mô hình được đánh giá

TabFSBench đánh giá bốn nhóm mô hình dữ liệu bảng phổ biến. [cheng25e | PDF]

Nhóm 1: Tree-based Models

Các mô hình dựa trên cây quyết định:

- XGBoost

- LightGBM
- CatBoost
- Random Forest và các biến thể khác. [cheng25e | PDF]

Đặc điểm

Ưu điểm:

- Hiệu quả cao trên dữ liệu bảng.
- Chi phí huấn luyện thấp.
- Dễ giải thích. [cheng25e | PDF]

Nhược điểm:

- Thường giả định cấu trúc đặc trưng không thay đổi sau huấn luyện. [cheng25e | PDF]

Nhóm 2: Deep Learning Models

Các kiến trúc học sâu dành cho dữ liệu bảng. [cheng25e | PDF]

Ví dụ:

- TabPFN
- FT-Transformer
- TabTransformer
- MLP và các kiến trúc tương tự. [cheng25e | PDF]

Đặc điểm

Ưu điểm:

- Khả năng trích xuất biểu diễn phức tạp.

Nhược điểm:

- Rất nhạy cảm với sự thay đổi đầu vào. [cheng25e | PDF]

Nhóm 3: Large Language Models (LLMs)

Các LLM đa năng được áp dụng cho dữ liệu bảng. [cheng25e | PDF]

Ví dụ:

- Llama
- GPT và các mô hình tương tự. [cheng25e | PDF]

Mục tiêu đánh giá

Nhóm tác giả muốn kiểm tra:

Liệu khả năng suy luận tổng quát của LLM có giúp chúng thích ứng tốt hơn với Feature Shift hay không. [cheng25e | PDF]

Nhóm 4: Tabular LLMs

Đây là các mô hình ngôn ngữ lớn được thiết kế riêng cho dữ liệu bảng. [cheng25e | PDF]

Các mô hình này kết hợp:

- Biểu diễn dữ liệu bảng.
- Khả năng suy luận của LLM.
- Kiến thức từ dữ liệu dạng bảng. [cheng25e | PDF]

Mục tiêu là tạo ra những hệ thống vừa hiểu dữ liệu bảng vừa duy trì được khả năng thích ứng trong môi trường mở. [cheng25e | PDF]

3.3. Phương pháp đánh giá

Đối với mỗi bộ dữ liệu:

1. Mô hình được huấn luyện trong môi trường đóng.
2. Sau đó được đánh giá trong nhiều mức độ Feature Shift khác nhau.
3. Hiệu năng được ghi nhận và so sánh. [cheng25e | PDF]

Nhóm tác giả quan tâm tới:

- Mức suy giảm hiệu năng.
- Khả năng chịu lỗi khi mất đặc trưng.
- Độ ổn định của mô hình trong môi trường mở. [cheng25e | PDF]

Ý nghĩa của Phần 3

Phần này đặt nền tảng cho toàn bộ nghiên cứu:

- Xây dựng bốn loại Feature Shift có hệ thống.
- Đánh giá hàng loạt mô hình dưới cùng điều kiện.
- Cho phép so sánh trực tiếp khả năng chống chịu Feature Shift giữa các phương pháp khác nhau. [cheng25e | PDF]

Đây là phần quan trọng nhất của TabFSBench vì tất cả các kết quả thực nghiệm ở các phần sau đều được xây dựng trên bốn kịch bản dịch chuyển đặc trưng nêu trên. [cheng25e | PDF]

Tiếp theo là **Phần 4: Experiments (Thực nghiệm)**, nơi bài báo trình bày kết quả chi tiết và ba phát hiện chính của nghiên cứu.

Phần 4. Thực nghiệm (Experiments)

Đây là phần trọng tâm của bài báo, nơi nhóm tác giả sử dụng TabFSBench để đánh giá khả năng chống chịu Feature Shift của nhiều loại mô hình dữ liệu bảng khác nhau. Kết quả thực nghiệm dẫn tới ba phát hiện quan trọng của nghiên cứu. [cheng25e | PDF]

4.1. Câu hỏi nghiên cứu

Nhóm tác giả tập trung trả lời các câu hỏi chính sau:

RQ1: Các mô hình dữ liệu bảng hiện nay hoạt động như thế nào khi xảy ra Feature Shift? [cheng25e | PDF]

RQ2: Mức độ quan trọng của đặc trưng bị mất ảnh hưởng như thế nào đến sự suy giảm hiệu năng của mô hình? [cheng25e | PDF]

RQ3: Hiệu năng trong môi trường đóng có liên quan như thế nào đến hiệu năng trong môi trường xảy ra Feature Shift? [cheng25e | PDF]

4.2. Quan sát 1:

Phần lớn mô hình có khả năng thích ứng hạn chế với Feature Shift

Kết quả cho thấy khi các đặc trưng thay đổi giữa giai đoạn huấn luyện và kiểm thử, hầu hết các mô hình đều bị suy giảm hiệu năng đáng kể. [cheng25e | PDF]

Nguyên nhân

Trong quá trình huấn luyện:

- Mô hình học các mối quan hệ giữa đặc trưng và nhãn.
- Mô hình giả định rằng các đặc trưng đó sẽ tiếp tục tồn tại khi triển khai thực tế. [cheng25e | PDF]

Khi một số đặc trưng biến mất:

- Cấu trúc đầu vào thay đổi.
- Thông tin mà mô hình phụ thuộc không còn đầy đủ.
- Khả năng dự đoán bị ảnh hưởng rõ rệt. [cheng25e | PDF]

Mô hình nào chịu đựng tốt hơn?

Kết quả chỉ ra rằng:

Mô hình cây quyết định

Các mô hình như:

- XGBoost
- LightGBM
- CatBoost

thường suy giảm đáng kể khi mất các đặc trưng quan trọng. [cheng25e | PDF]

Mô hình học sâu

Các mô hình học sâu cũng gặp khó khăn khi tập đặc trưng thay đổi, đặc biệt khi các đặc trưng bị mất có vai trò lớn trong quá trình học biểu diễn. [cheng25e | PDF]

LLM và Tabular LLM

Một kết quả đáng chú ý là:

Các mô hình ngôn ngữ lớn chuyên biệt cho dữ liệu bảng (Tabular LLMs) cho thấy tiềm năng thích nghi tốt hơn trong một số kịch bản Feature Shift. [cheng25e | PDF]

Nhóm tác giả cho rằng nguyên nhân có thể đến từ:

- Khả năng suy luận của LLM.
- Kiến thức được học từ quy mô dữ liệu lớn.
- Khả năng tận dụng mối liên hệ giữa các đặc trưng còn lại. [cheng25e | PDF]

Kết luận của Quan sát 1

Đa số mô hình dữ liệu bảng hiện tại chưa thực sự mạnh trong môi trường mở có dịch chuyển đặc trưng. Tabular LLM là hướng nghiên cứu đầy tiềm năng cho tương lai. [cheng25e | PDF]

4.3. Quan sát 2:

Độ quan trọng của đặc trưng bị mất tỷ lệ tuyến tính với mức suy giảm hiệu năng

Đây là phát hiện quan trọng nhất của bài báo. [cheng25e | PDF]

Nhóm tác giả nhận thấy rằng:

Khi các đặc trưng có mức độ quan trọng cao bị loại bỏ khỏi dữ liệu kiểm thử thì hiệu năng mô hình giảm mạnh hơn rất nhiều so với khi loại bỏ các đặc trưng ít quan trọng. [cheng25e | PDF]

Mối quan hệ tuyến tính

Qua nhiều bộ dữ liệu và nhiều loại mô hình khác nhau, nghiên cứu quan sát thấy:

- Độ quan trọng của đặc trưng càng lớn.
- Mức sụt giảm hiệu năng càng cao.

Mối quan hệ này gần như tuyến tính. [cheng25e | PDF]

Nói cách khác:

Nếu đặc trưng A quan trọng gấp đôi đặc trưng B thì việc mất A thường gây tổn thất hiệu năng lớn hơn đáng kể so với việc mất B. [cheng25e | PDF]

Ý nghĩa

Phát hiện này cho thấy:

Không phải mọi Feature Shift đều nguy hiểm như nhau. [cheng25e | PDF]

Mối đe dọa thực sự nằm ở việc mất:

- Các đặc trưng cốt lõi.
- Các cảm biến quan trọng.
- Các biến có tương quan mạnh với nhãn dự đoán. [cheng25e | PDF]

Hướng nghiên cứu tương lai

Nhóm tác giả đề xuất:

Các thuật toán trong tương lai nên:

- Theo dõi tầm quan trọng của đặc trưng.
- Bảo vệ các đặc trưng quan trọng.
- Thiết kế cơ chế dự phòng khi các đặc trưng quan trọng bị mất. [cheng25e | PDF]

4.4. Quan sát 3:

Hiệu năng môi trường đóng có tương quan với hiệu năng trong Feature Shift

Một câu hỏi quan trọng là:

Nếu một mô hình đạt kết quả rất cao trong môi trường đóng thì nó có hoạt động tốt trong môi trường mở hay không? [cheng25e | PDF]

Kết quả nghiên cứu cho thấy:

Có sự tương quan đáng kể giữa:

- Hiệu năng trong môi trường đóng.
- Hiệu năng trong môi trường xảy ra Feature Shift. [cheng25e | PDF]

Điều này có nghĩa gì?

Những mô hình có kết quả tốt hơn trên dữ liệu chuẩn thường cũng có xu hướng đạt kết quả tốt hơn khi xảy ra Feature Shift. [cheng25e | PDF]

Tuy nhiên:

Điều đó không có nghĩa là chúng miễn nhiễm với Feature Shift. [cheng25e | PDF]

Ngay cả những mô hình mạnh nhất vẫn xuất hiện hiện tượng suy giảm hiệu năng khi mất các đặc trưng quan trọng. [cheng25e | PDF]

Ý nghĩa nghiên cứu

Quan sát này gợi ý rằng:

Việc cải thiện hiệu năng trong môi trường đóng vẫn có giá trị đối với môi trường mở.

Tuy nhiên, điều đó là chưa đủ. Các nhà nghiên cứu vẫn cần:

- Tăng cường khả năng chống chịu Feature Shift.
- Thiết kế mô hình mạnh hơn trước thay đổi đặc trưng.
- Hiểu rõ hơn mối liên hệ giữa hai loại môi trường này. [cheng25e | PDF]

Tổng kết Phần 4

Sau hàng loạt thực nghiệm trên nhiều bộ dữ liệu và nhiều loại mô hình khác nhau, bài báo đưa ra ba kết luận chính:

1. Phần lớn mô hình hiện nay chưa thích ứng tốt với Feature Shift. [cheng25e | PDF]
2. Mức suy giảm hiệu năng có quan hệ tuyến tính với độ quan trọng của đặc trưng bị mất. [cheng25e | PDF]
3. Hiệu năng trong môi trường đóng có tương quan với hiệu năng trong môi trường xảy ra Feature Shift. [cheng25e | PDF]

Ba kết luận này tạo cơ sở cho các hướng nghiên cứu tiếp theo nhằm xây dựng những mô hình dữ liệu bảng mạnh mẽ hơn trong môi trường mở. [cheng25e | PDF]

Tiếp theo là **Phần 5: Conclusions and Future Work (Kết luận và Hướng nghiên cứu tương lai)**, phần cuối cùng của bài báo.

Phần 5. Kết luận và Hướng nghiên cứu tương lai

5.1. Kết luận

Trong bài báo này, các tác giả giới thiệu **TabFSBench**, bộ chuẩn đầu tiên được xây dựng dành riêng cho việc nghiên cứu hiện tượng **dịch chuyển đặc trưng (Feature Shift)** trong dữ liệu dạng bảng. Bộ chuẩn này cho phép đánh giá một cách hệ thống khả năng thích ứng của các mô hình học máy trong môi trường mở, nơi tập đặc trưng có thể thay đổi theo thời gian hoặc theo điều kiện vận hành thực tế. [cheng25e | PDF]

Thông qua việc đánh giá trên nhiều bộ dữ liệu thuộc các bài toán phân loại và hồi quy, cùng với nhiều loại mô hình khác nhau, nghiên cứu đã làm rõ những khó khăn mà các mô hình hiện nay gặp phải khi xuất hiện Feature Shift. [cheng25e | PDF]

Các kết quả thực nghiệm cho thấy:

- Phần lớn các mô hình dữ liệu bảng hiện nay hoạt động tốt trong môi trường đóng nhưng gặp khó khăn đáng kể khi tập đặc trưng thay đổi. [cheng25e | PDF]
- Mức độ quan trọng của đặc trưng bị mất có ảnh hưởng trực tiếp đến sự suy giảm hiệu năng của mô hình. [cheng25e | PDF]
- Hiệu năng trong môi trường đóng có mối liên hệ với hiệu năng trong môi trường xảy ra Feature Shift. [cheng25e | PDF]
- Các Tabular LLM cho thấy tiềm năng trở thành hướng tiếp cận khả thi nhằm giải quyết thách thức Feature Shift trong tương lai. [cheng25e | PDF]

Nghiên cứu nhấn mạnh rằng Feature Shift là một vấn đề quan trọng nhưng còn ít được quan tâm trong cộng đồng nghiên cứu học máy trên dữ liệu bảng. Việc hiểu rõ và giải quyết thách thức này sẽ giúp tạo ra các hệ thống AI ổn định và đáng tin cậy hơn trong các ứng dụng thực tế. [cheng25e | PDF]

5.2. Hướng nghiên cứu tương lai

Dựa trên các quan sát thực nghiệm, nhóm tác giả đề xuất một số hướng nghiên cứu tiếp theo.

1. Phát triển Tabular LLM mạnh hơn

Kết quả nghiên cứu cho thấy các Tabular LLM có tiềm năng thích ứng với Feature Shift tốt hơn nhiều mô hình truyền thống. Vì vậy, một hướng đi quan trọng là:

- Thiết kế các kiến trúc Tabular LLM chuyên biệt hơn.
- Kết hợp tri thức miền với dữ liệu bảng.

- Nâng cao khả năng suy luận khi một phần thông tin đầu vào bị thiếu. [cheng25e | PDF]

Tác giả đặc biệt đề cập đến khả năng xây dựng các cơ chế **huấn luyện tinh chỉnh nhiều cấp độ (multi-level fine-tuning)** nhằm tăng cường khả năng suy luận trên dữ liệu bảng của các mô hình ngôn ngữ lớn. [cheng25e | PDF]

---

2. Tối ưu hóa dựa trên độ quan trọng của đặc trưng

Do phát hiện được mối quan hệ gần tuyến tính giữa:

- Độ quan trọng của đặc trưng.
- Mức suy giảm hiệu năng.

nên các nghiên cứu tương lai có thể tập trung vào việc xây dựng các thuật toán:

- Nhận biết các đặc trưng quan trọng.
- Bảo vệ các đặc trưng quan trọng trước rủi ro bị mất.
- Tự động điều chỉnh mô hình khi các đặc trưng quan trọng thay đổi. [cheng25e | PDF]

Tác giả cho rằng các thuật toán hướng bởi Feature Importance có thể giúp cải thiện đáng kể độ bền vững của hệ thống trong môi trường mở. [cheng25e | PDF]

---

3. Nghiên cứu lý thuyết về môi trường đóng và môi trường mở

Một câu hỏi vẫn chưa có lời giải rõ ràng là:

Tại sao hiệu năng trong môi trường đóng lại có tương quan với hiệu năng khi xảy ra Feature Shift? [cheng25e | PDF]

Do đó, tác giả cho rằng cần:

- Phân tích lý thuyết sâu hơn về mối liên hệ này.
- Xây dựng các mô hình toán học mô tả Feature Shift.
- Tìm hiểu điều kiện giúp mô hình duy trì hiệu năng khi đặc trưng thay đổi. [cheng25e | PDF]

---

4. Tăng cường độ vững chắc của mô hình trong môi trường mở

Mục tiêu cuối cùng là phát triển các mô hình dữ liệu bảng có khả năng:

- Hoạt động ổn định khi dữ liệu thay đổi.
- Chịu được việc mất hoặc xuất hiện thêm đặc trưng.
- Thích ứng với các điều kiện thực tế phức tạp. [cheng25e | PDF]

Theo tác giả, đây là một hướng nghiên cứu quan trọng và có ý nghĩa lớn đối với các hệ thống AI triển khai trong thực tế như:

- Tài chính.
- Y tế.
- Giao thông thông minh.
- Dự báo thời tiết.
- Giám sát công nghiệp. [cheng25e | PDF]

Tóm tắt toàn bộ bài báo

Sau khi dịch toàn bộ các phần chính, nội dung cốt lõi của bài báo có thể tóm tắt như sau:

Vấn đề nghiên cứu: Các mô hình dữ liệu bảng hiện nay được đánh giá chủ yếu trong môi trường đóng, trong khi thực tế thường xảy ra hiện tượng mất hoặc thay đổi đặc trưng (Feature Shift). [cheng25e | PDF]

Đóng góp chính: Đề xuất bộ chuẩn **TabFSBench** để đánh giá khả năng chống chịu Feature Shift trên dữ liệu bảng. [cheng25e | PDF]

Kết quả quan trọng:

1. Hầu hết mô hình hiện tại chưa đủ mạnh trước Feature Shift. [cheng25e | PDF]
2. Đặc trưng càng quan trọng thì việc mất đặc trưng đó càng gây suy giảm hiệu năng lớn. [cheng25e | PDF]
3. Hiệu năng môi trường đóng có tương quan với hiệu năng trong môi trường mở. [cheng25e | PDF]
4. Tabular LLM là một hướng nghiên cứu rất hứa hẹn. [cheng25e | PDF]

Thông điệp chính của bài báo:

Khi triển khai AI trong thực tế, việc dữ liệu thay đổi không chỉ là thay đổi phân phối mà còn có thể là thay đổi chính các đặc trưng đầu vào. Các mô hình tương lai cần được thiết kế để thích ứng với Feature Shift nếu muốn hoạt động ổn định trong môi trường mở.

Tóm tắt bài báo trong 5 ý

1. **Bài báo giới thiệu TabFSBench**, bộ benchmark đầu tiên được thiết kế chuyên biệt để đánh giá tác động của hiện tượng **Feature Shift** (thay đổi tập đặc trưng giữa giai đoạn huấn luyện và kiểm thử) trên dữ liệu dạng bảng. [cheng25e | PDF]

1. **TabFSBench xây dựng 4 kịch bản Feature Shift** gồm: Single Shift, Most-Relevant Shift, Least-Relevant Shift và Random Shift nhằm mô phỏng các tình huống thực tế khi cảm biến hoặc nguồn dữ liệu bị mất, thay thế hoặc thay đổi. [cheng25e | PDF]

2. **Nghiên cứu đánh giá nhiều loại mô hình dữ liệu bảng**, bao gồm mô hình cây quyết định, mô hình học sâu, LLM và Tabular LLM trên nhiều bộ dữ liệu phân loại và hồi quy khác nhau. [cheng25e | PDF]

3. **Kết quả cho thấy phần lớn mô hình hiện nay không đủ mạnh trước Feature Shift**. Khi các đặc trưng quan trọng bị mất, hiệu năng giảm đáng kể. Trong số các phương pháp được thử nghiệm, Tabular LLM thể hiện tiềm năng thích ứng tốt hơn trong một số trường hợp. [cheng25e | PDF]

4. **Hai phát hiện quan trọng nhất của bài báo là:** (i) mức suy giảm hiệu năng có quan hệ gần tuyến tính với độ quan trọng của đặc trưng bị mất; và (ii) mô hình đạt kết quả tốt trong môi trường đóng thường cũng hoạt động tốt hơn trong môi trường có Feature Shift, dù vẫn bị ảnh hưởng bởi sự thay đổi đặc trưng. [cheng25e | PDF]

Thông điệp chính: Khi triển khai AI trong thực tế, không chỉ cần xử lý *distribution shift* mà còn phải giải quyết *feature shift*. Đây là một thách thức quan trọng nhưng còn ít được nghiên cứu, và Tabular LLM được xem là hướng đầy hứa hẹn để xây dựng các hệ thống dữ liệu bảng bền vững hơn trong môi trường mở. [cheng25e | PDF]

Giải thích TabFSBench bằng ví dụ

Hãy tưởng tượng bạn đang xây dựng một mô hình AI để **dự đoán giá nhà**.

Trước khi triển khai (Huấn luyện)

Bạn có 5 đặc trưng:

Đặc trưng	Ý nghĩa

Diện tích	m^2
Số phòng ngủ	số lượng
Vị trí	trung tâm/ngoại thành
Tuổi ngôi nhà	năm sử dụng
Khoảng cách đến trường học	km

Mô hình được huấn luyện với đầy đủ 5 đặc trưng này.

Trường hợp 1: Không có Feature Shift

Khi triển khai thực tế, dữ liệu đầu vào vẫn có đủ 5 đặc trưng trên.

Diện tích = 100

Phòng ngủ = 3

Vị trí = Trung tâm

Tuổi nhà = 5

Khoảng cách trường = 1 km

Đây là **môi trường đóng (Closed Environment)**.

Mô hình hoạt động đúng như lúc được huấn luyện.

Trường hợp 2: Có Feature Shift

Một ngày nào đó, hệ thống thu thập dữ liệu gặp lỗi.

Thông tin "Khoảng cách đến trường học" không còn được ghi nhận.

Dữ liệu mới trở thành:

Diện tích = 100

Phòng ngủ = 3

Vị trí = Trung tâm

Tuổi nhà = 5

Mô hình đã được huấn luyện với 5 cột nhưng giờ chỉ còn 4 cột.

Đây chính là:

Feature Shift = tập đặc trưng khi kiểm thử khác với tập đặc trưng khi huấn luyện.

TabFSBench làm gì?

TabFSBench giống như một "phòng thí nghiệm kiểm tra độ bền".

Nó đặt ra câu hỏi:

Nếu một hoặc nhiều đặc trưng biến mất thì mô hình sẽ suy giảm bao nhiêu?

Thay vì chỉ đo độ chính xác thông thường, TabFSBench cố tình làm mất các đặc trưng rồi đánh giá lại mô hình.

Ví dụ về 4 kịch bản trong TabFSBench

1. Single Shift

Mất **1 đặc trưng duy nhất**.

Ví dụ:

Bỏ: Khoảng cách trường học

Mục tiêu:

Đo xem đặc trưng đó quan trọng đến mức nào.

---

2. Most-Relevant Shift

Xóa đặc trưng quan trọng nhất.

Giả sử phân tích cho thấy:

Vị trí = quan trọng nhất

TabFSBench sẽ loại bỏ:

Vị trí ❌

và kiểm tra hiệu năng.

Nếu độ chính xác giảm từ:

95% → 70%

thì chứng tỏ mô hình phụ thuộc rất nhiều vào đặc trưng "Vị trí".

---

3. Least-Relevant Shift

Xóa đặc trưng ít quan trọng nhất.

Ví dụ:

Tuổi nhà ❌

Nếu độ chính xác chỉ giảm:

95% → 94%

thì có thể kết luận đặc trưng này gần như không ảnh hưởng nhiều đến mô hình.

---

4. Random Shift

Xóa đặc trưng ngẫu nhiên.

Ví dụ:

Lần 1:

Diện tích ❌

Lần 2:

Số phòng ngủ ❌

Lần 3:

Vị trí ❌

Tuổi nhà ❌

Kịch bản này mô phỏng thực tế nhất vì ngoài đời lỗi dữ liệu thường xảy ra ngẫu nhiên.

Tại sao TabFSBench quan trọng?

Trong các bài báo truyền thống, người ta thường đánh giá mô hình như sau:

Train → Test

với cùng tập đặc trưng.

Do đó mô hình đạt 95% độ chính xác.

Nhưng thực tế triển khai có thể như:

Train:

A, B, C, D, E

Test:

A, B, D

Một số cột bị mất vì:

- Cảm biến hỏng
- API ngừng hoạt động
- Dữ liệu không được nhập
- Hệ thống nâng cấp làm thay đổi cấu trúc dữ liệu

Khi đó độ chính xác có thể giảm từ:

95% → 60%

TabFSBench được tạo ra để đo chính xác mức suy giảm này.

Ý tưởng cốt lõi của bài báo

Có thể tóm gọn trong một câu:

TabFSBench kiểm tra xem mô hình dữ liệu bảng có còn hoạt động tốt hay không khi một phần thông tin đầu vào bị mất hoặc thay đổi.

Và kết luận lớn nhất của bài báo là:

Phần lớn mô hình hiện nay rất nhạy cảm với Feature Shift, đặc biệt khi mất các đặc trưng quan trọng; trong khi các Tabular LLM cho thấy tiềm năng chống chịu tốt hơn trong một số trường hợp. [cheng25e | PDF]