CMP1020 - Học sâu

BÀI 2: HỒI QUY TUYẾN TÍNH VÀ HỒI QUY LOGISTIC

Giảng viên: TS. Bùi Danh Hường

MỤC TIÊU BÀI HỌC

- Phân biệt được bài toán Hồi quy (Regression) và bài toán Phân lớp (Classification).
- Hiểu và cài đặt được thuật toán Gradient Descent.
- Mô tả, huấn luyện và đánh giá được mô hình Hồi quy tuyến tính.
- Mô tả, huấn luyện và đánh giá được mô hình Hồi quy Logistic.

CẤU TRÚC BÀI HỌC

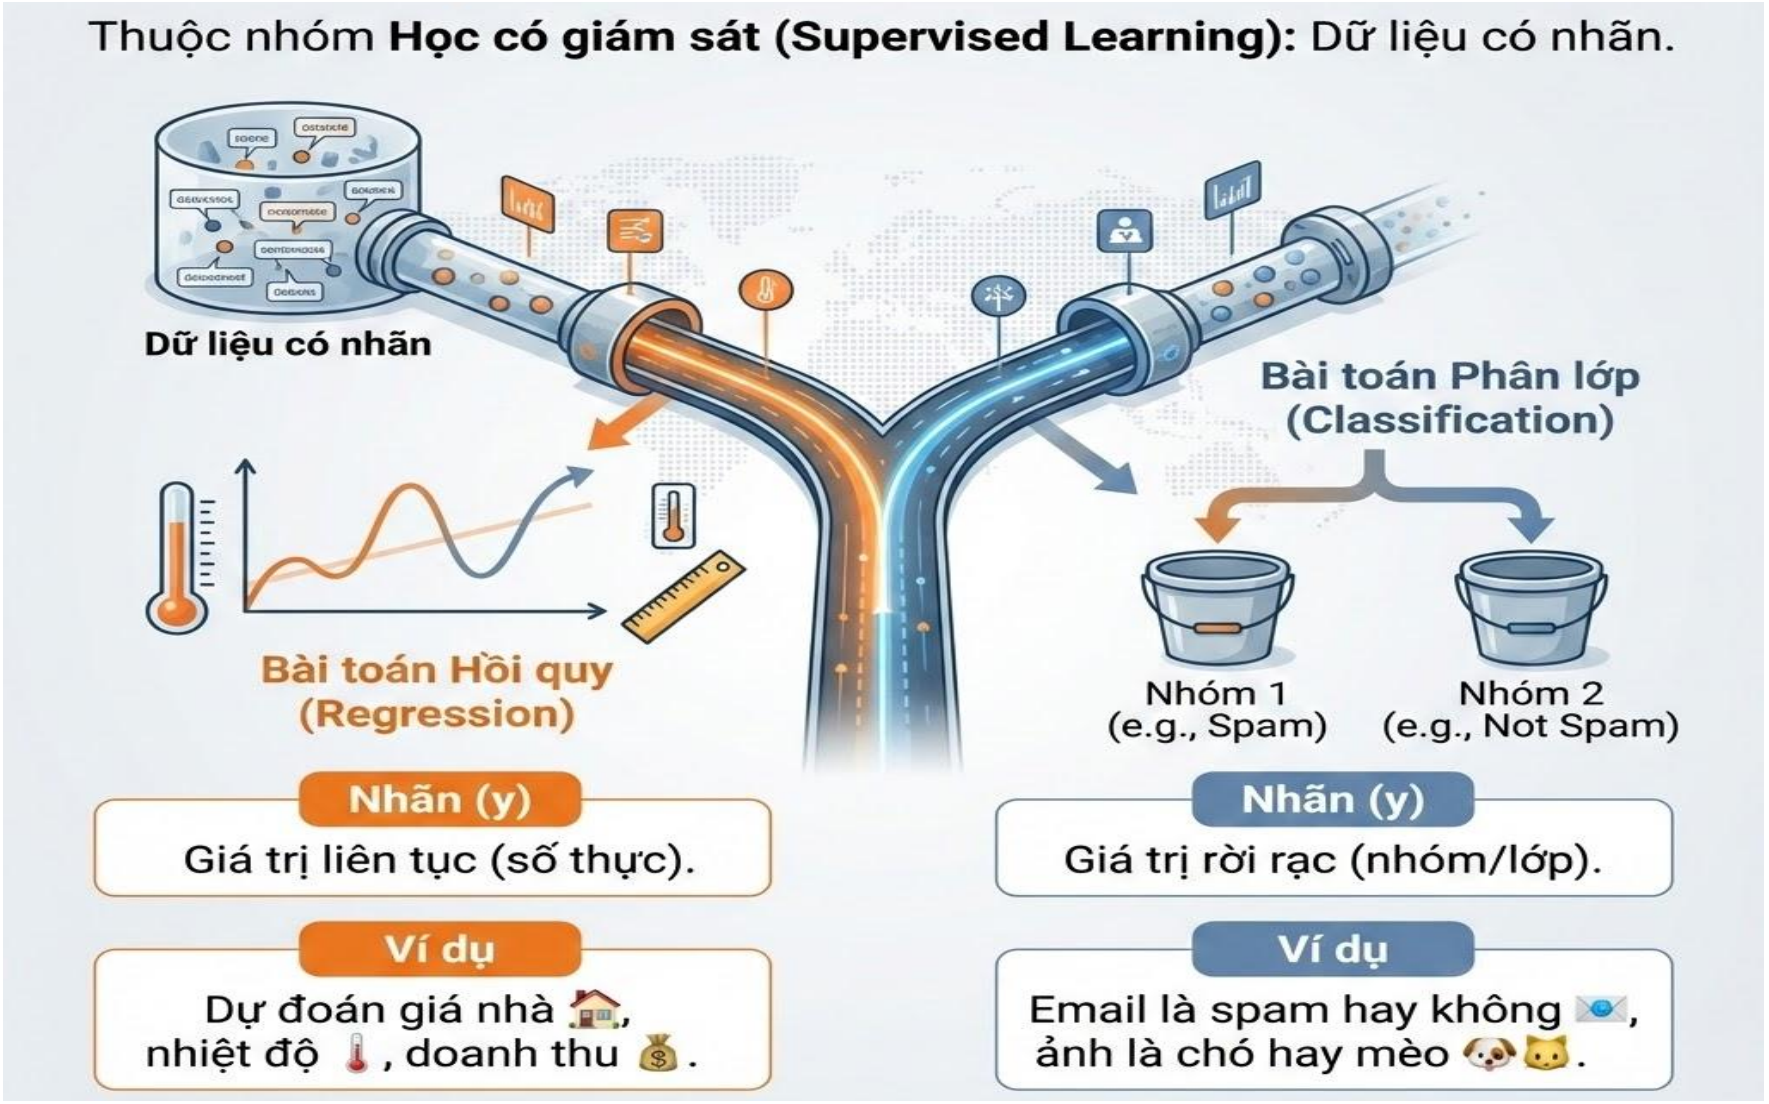
Phần 1: Lý thuyết cơ sở

- 1. Mô hình Hồi quy tuyến tính một biến.
- 2. Thuật toán Gradient Descent.
- 3. Mô hình Hồi quy tuyến tính nhiều biến.

Phần 2: Mở rộng & Ứng dụng

- 4. Mô hình Hồi quy Logistic.
- 5. Bài toán ứng dụng thực tế.

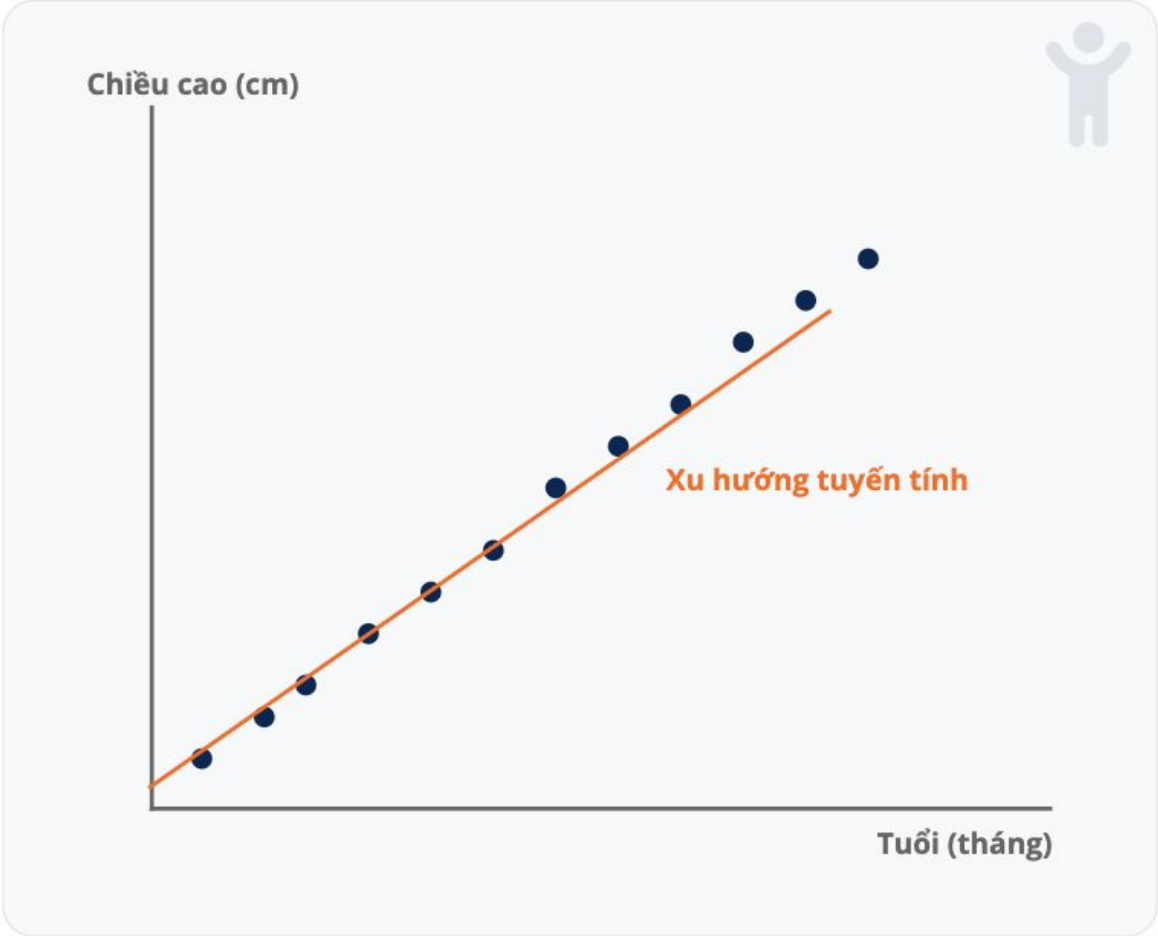
PHÂN BIỆT HAI LOẠI BÀI TOÁN CƠ BẢN



VÍ DỤ MỞ ĐẦU – DỰ ĐOÁN CHIỀU CAO

- **Bài toán:** Bệnh viện muốn dự đoán chiều cao trẻ em dựa trên độ tuổi.
- **Dữ liệu:** Thu thập từ 12 trẻ em (trong độ tuổi 18 - 30 tháng).
- **Quan sát:** Khi tuổi tăng, chiều cao cũng tăng theo một xu hướng đường thẳng (tuyến tính).

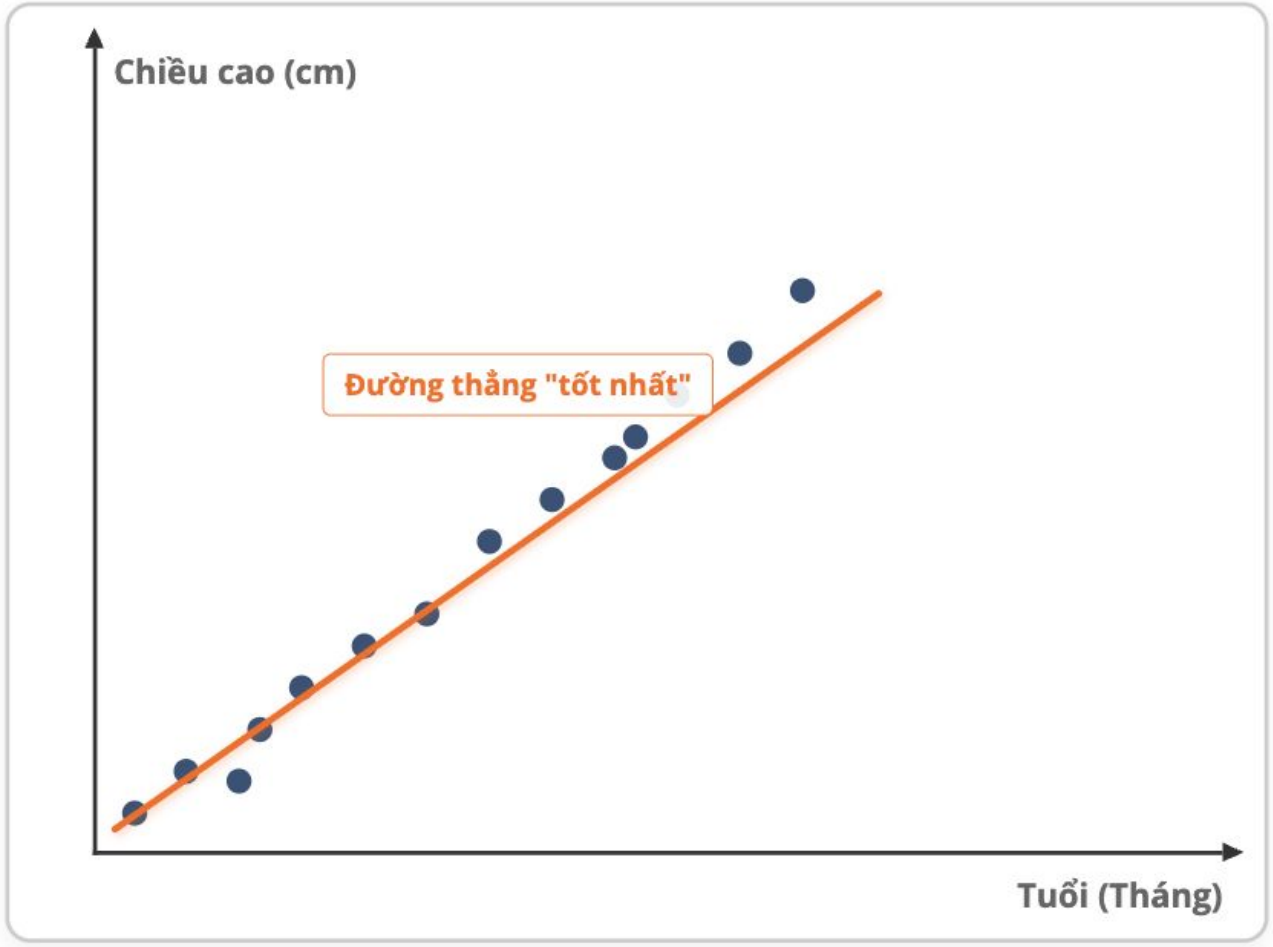
◎ **Mục tiêu:** Tìm ra công thức toán học biểu diễn mối quan hệ này.



TRỰC QUAN HÓA DỮ LIỆU (SCATTER PLOT)

- **Mối quan hệ tuyến tính:** Các điểm dữ liệu không nằm lộn xộn mà phân bố dọc theo một đường chéo (xu hướng tăng dần).
- **Mục tiêu:** Chúng ta cần tìm ra đường thẳng "tốt nhất" (Best Fit Line) đi qua trung tâm của đám mây điểm dữ liệu này.

  → *Đường thẳng này sẽ đại diện cho quy luật chung.*



MÔ HÌNH TOÁN HỌC

Công thức hồi quy tuyến tính một biến:

$$h_w(x) = w_0 + w_1 x$$

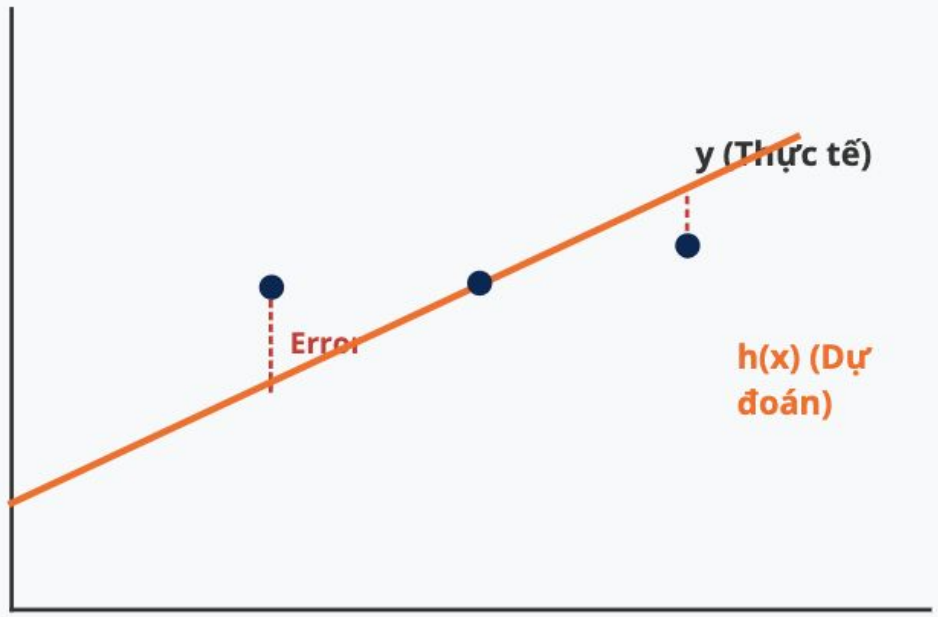
Giải thích:

- x: Đầu vào (biến độc lập - ví dụ: tuổi).
- $h_w(x)$: Giá trị dự đoán (đầu ra - ví dụ: chiều cao).
- w_0: Hệ số chặn (bias).
- w_1: Trọng số (hệ số góc).

MỤC TIÊU CỦA MÔ HÌNH

- **Nhiệm vụ:** Tìm bộ giá trị tối ưu cho tham số w_0 và w_1.
- **Thế nào là tối ưu?**
  - Đường thẳng dự đoán phải đi qua gần các điểm dữ liệu thực tế nhất.
  - Sai số (khoảng cách) giữa giá trị dự đoán $h_w(x)$ và giá trị thực tế y là **nhỏ nhất**.

Mục tiêu: Min(Error)



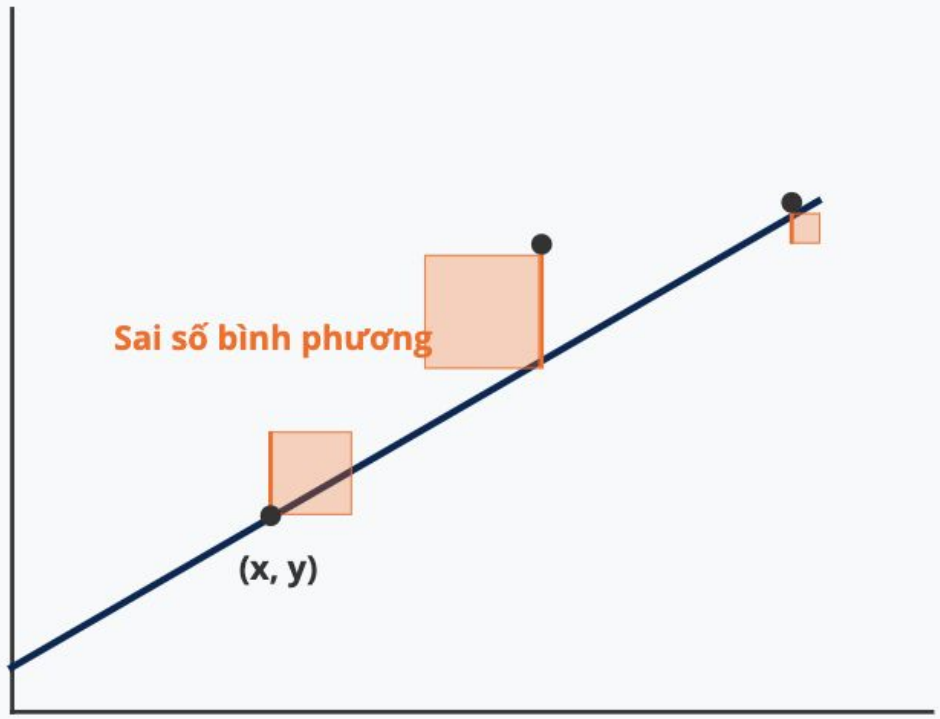
Các đường gạch đỏ thể hiện sai số cần giảm thiểu.

HÀM MẤT MÁT (LOSS FUNCTION)

- **Mục đích:** Công cụ để đo lường mức độ sai lệch giữa kết quả dự đoán và thực tế.
- Trong Hồi quy tuyến tính, ta sử dụng hàm **Mean Squared Error (MSE)** - Trung bình bình phương sai số.

Ý nghĩa MSE

Tính trung bình cộng của **bình phương khoảng cách** từ các điểm dữ liệu đến đường thẳng dự đoán.



CÔNG THỨC MEAN SQUARED ERROR (MSE)

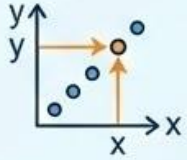
$$J(w_0, w_1) = \frac{1}{m}\sum_{i=1}^{m}\left[h_w(x^{(i)}) - y^{(i)}\right]^2$$
$$= \sum_{i=1}^{}\left[h_w(x^{(i)}) - y^{(i)}\right]^2$$

Giải thích:

- **m**: Số lượng mẫu dữ liệu (ví dụ: 12 trẻ em).



- $\mathbf{x^{(i)}}$, $\mathbf{y^{(i)}}$: Giá trị đầu vào và đầu ra thực tế của mẫu thứ i.



- $\mathbf{h_w(x^{(i)})}$: Giá trị mô hình dự đoán.



VÍ DỤ TÍNH TOÁN SAI SỐ ĐƠN GIẢN

Dữ liệu giả định

- Tuổi x = 2
- Chiều cao thực y = 80
- Mô hình hiện tại: $h(x) = 70 + 4x$

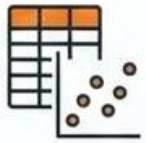
Tính toán

- Dự đoán: $h(2) = 70 + 4(2) = 78$
- Sai số: $(78 - 80)^2 = (-2)^2 = 4$

Mục tiêu:

Điều chỉnh w_0, w_1 để con số này càng nhỏ càng tốt.

TÓM TẮT BÀI TOÁN TỐI ƯU



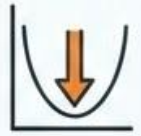
- **Input:** Tập dữ liệu (x, y).



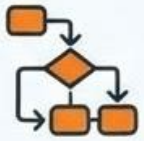
- **Model:** $h_w(x) = w_0 + w_1 x$.



- **Loss Function:** $J(w_0, w_1)$.



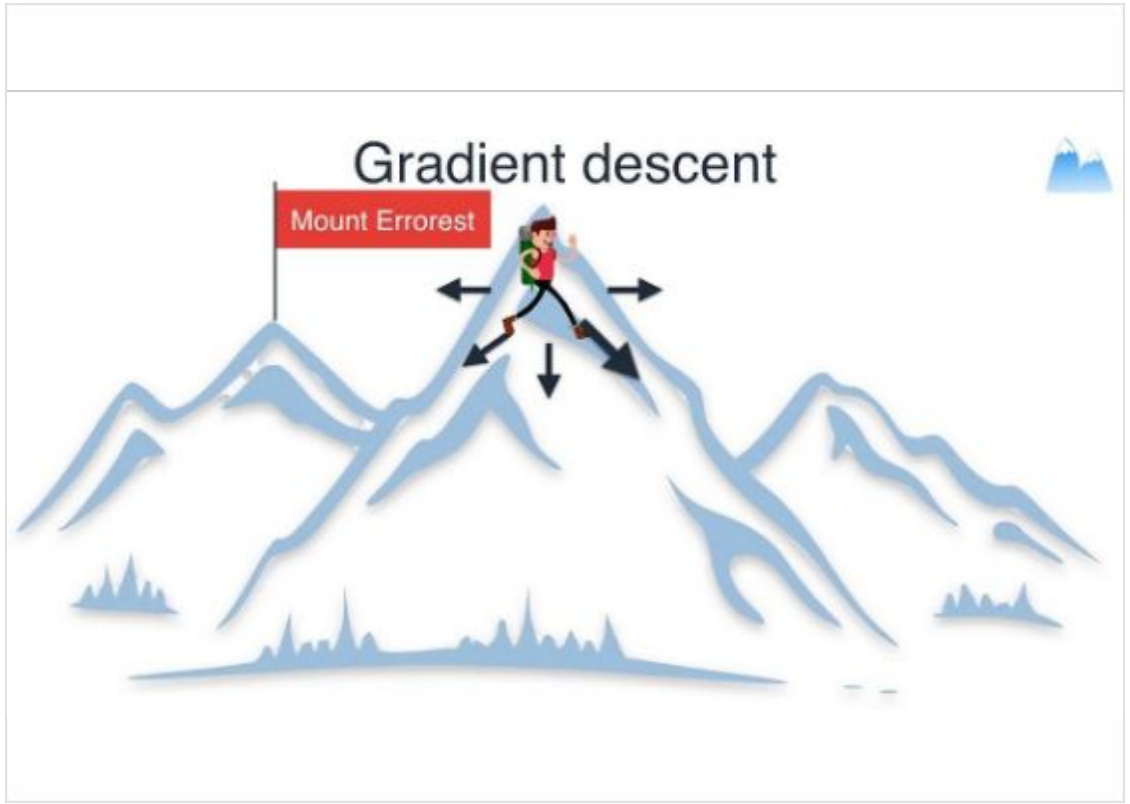
- **Goal:** Tìm $\min J(w_0, w_1)$.



- **Giải pháp:** Sử dụng thuật toán Gradient Descent.

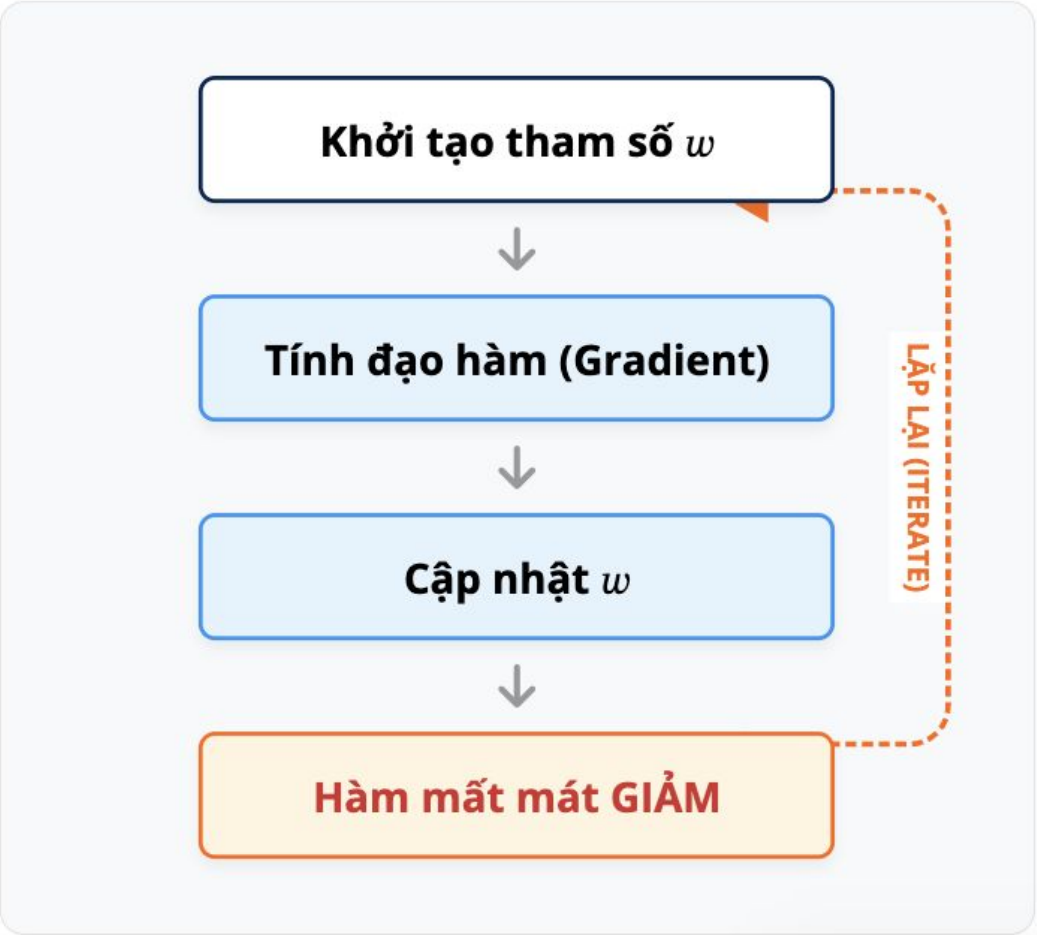
Ý TƯỞNG TRỰC QUAN – XUỐNG NÚI

- **Tưởng tượng:** Bạn đang đứng trên đỉnh núi mù sương (giá trị Loss cao).
- **Mục tiêu:** Xuống thung lũng thấp nhất (Loss thấp nhất).
- **Cách làm:** Nhìn xung quanh, tìm hướng dốc nhất đi xuống và bước một bước nhỏ. Lặp lại cho đến khi xuống đáy.



ĐỊNH NGHĨA GRADIENT DESCENT

- **Bản chất:** Là thuật toán tối ưu hóa lặp (Iterative Optimization).
- **Cơ chế:** Điều chỉnh các tham số w lặp đi lặp lại để giảm giá trị của hàm mất mát.
- **Phổ biến:** Là xương sống của việc huấn luyện trong Học máy và Học sâu nhờ tính đơn giản và hiệu quả.



QUY TRÌNH THỰC HIỆN: BƯỚC 1 & 2

▶ Bước 1: Khởi tạo

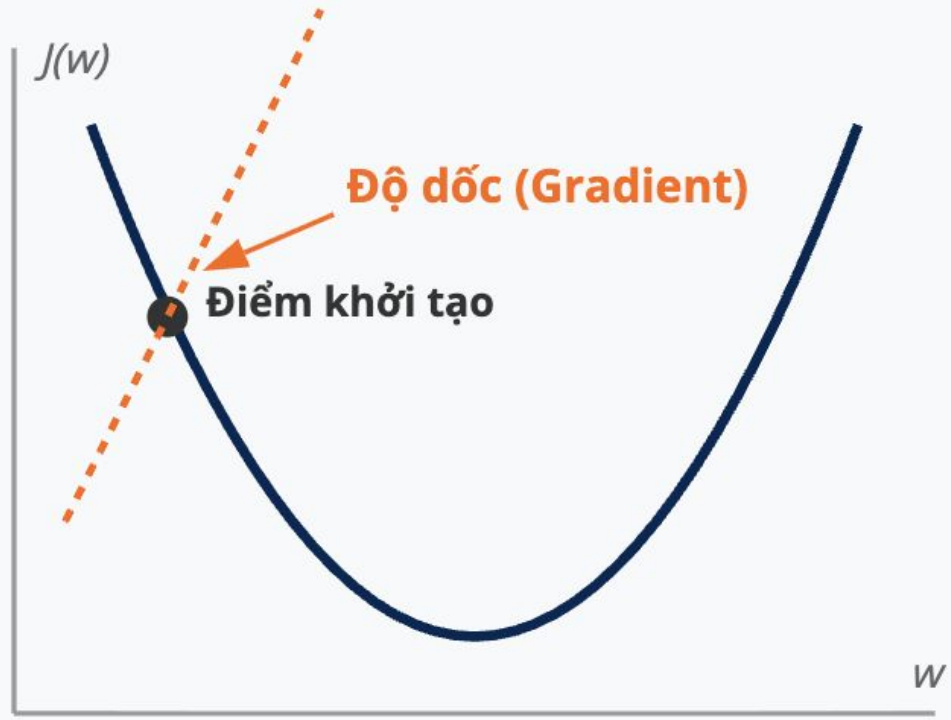
Khởi tạo giá trị ngẫu nhiên cho các tham số $w_0 w_1$.

(Ví dụ: Gán tất cả bằng 0 hoặc số nhỏ gần 0).

Bước 2: Tính đạo hàm

Tính **đạo hàm riêng** của hàm mất mát $J(w)$ theo từng tham số.

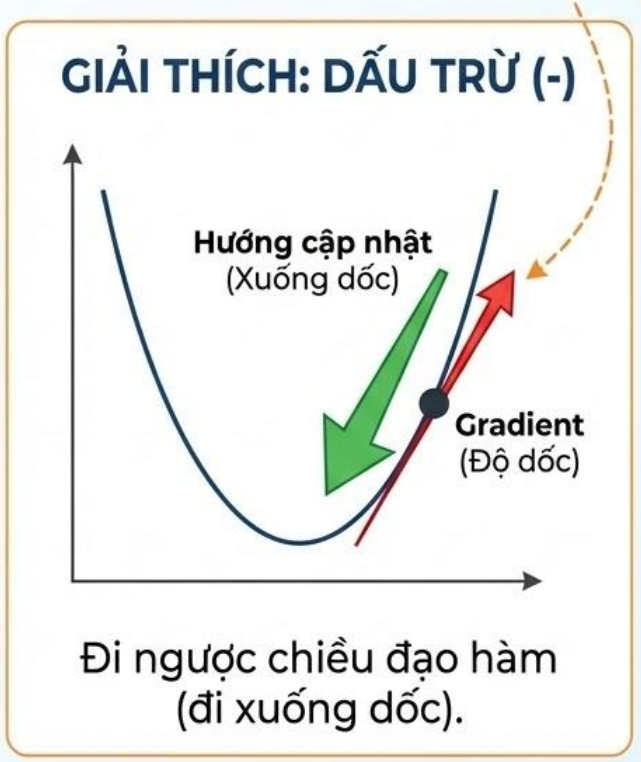
Ý nghĩa: Đạo hàm cho biết **độ dốc** (hướng tăng/giảm) của hàm số tại điểm hiện tại.

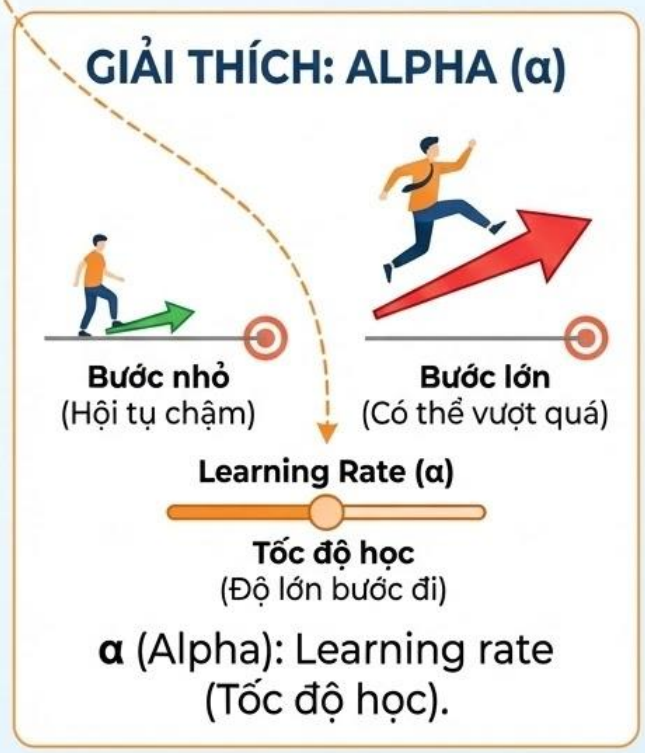


Minh họa Đạo hàm trên hàm Loss

BƯỚC 3: CẬP NHẬT THAM SỐ

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$$



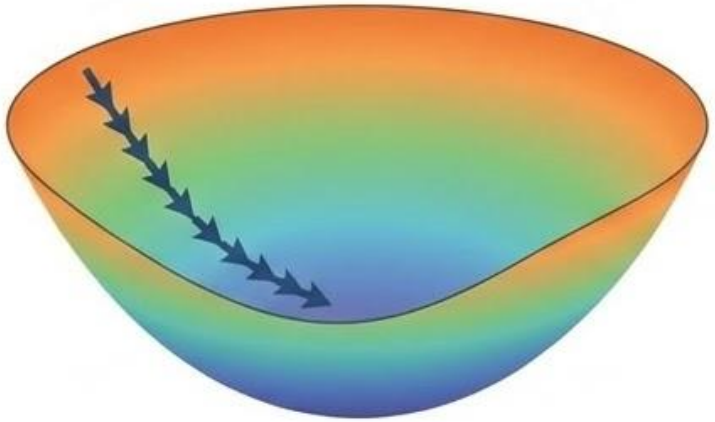


LEARNING RATE (α) – TỐC ĐỘ HỌC

Là siêu tham số (hyperparameter) quan trọng, nằm trong khoảng (0, 1).

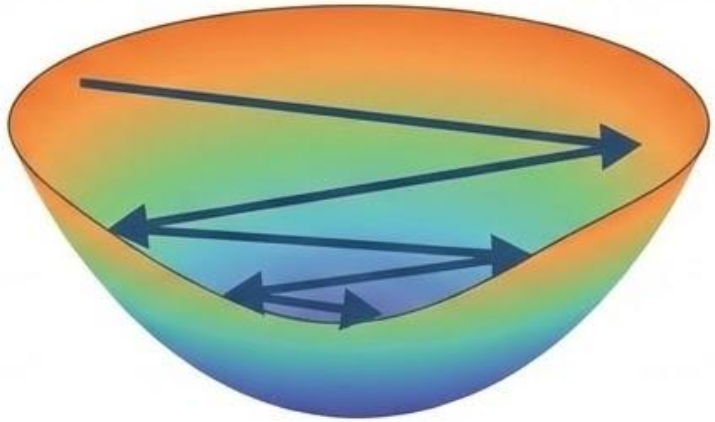
Nếu α quá nhỏ:

Thuật toán hội tụ **rất chậm** (bước đi quá ngắn, tốn nhiều thời gian).

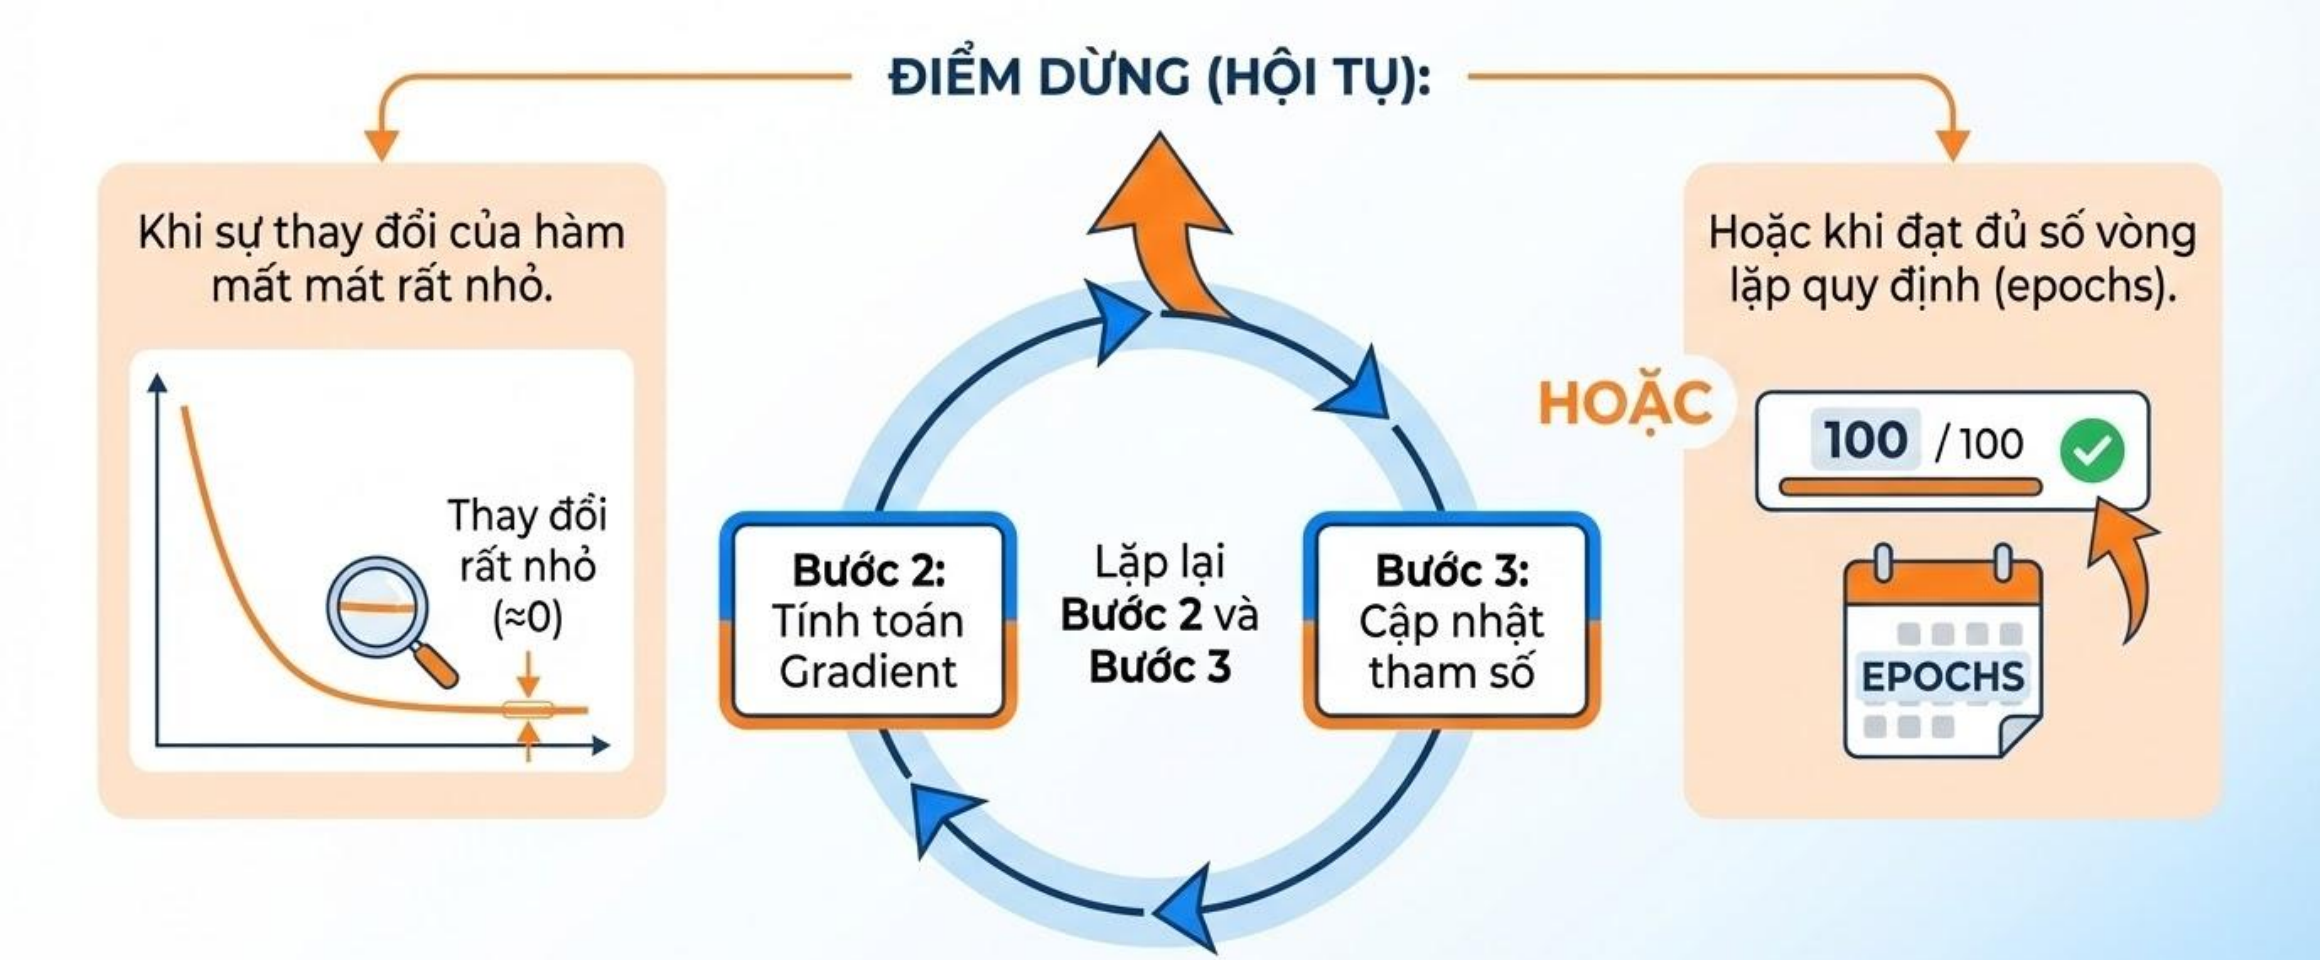


Nếu α quá lớn:

Thuật toán có thể **không hội tụ,** nhảy qua lại quanh điểm cực tiểu (bước đi quá dài, vượt qua đáy).

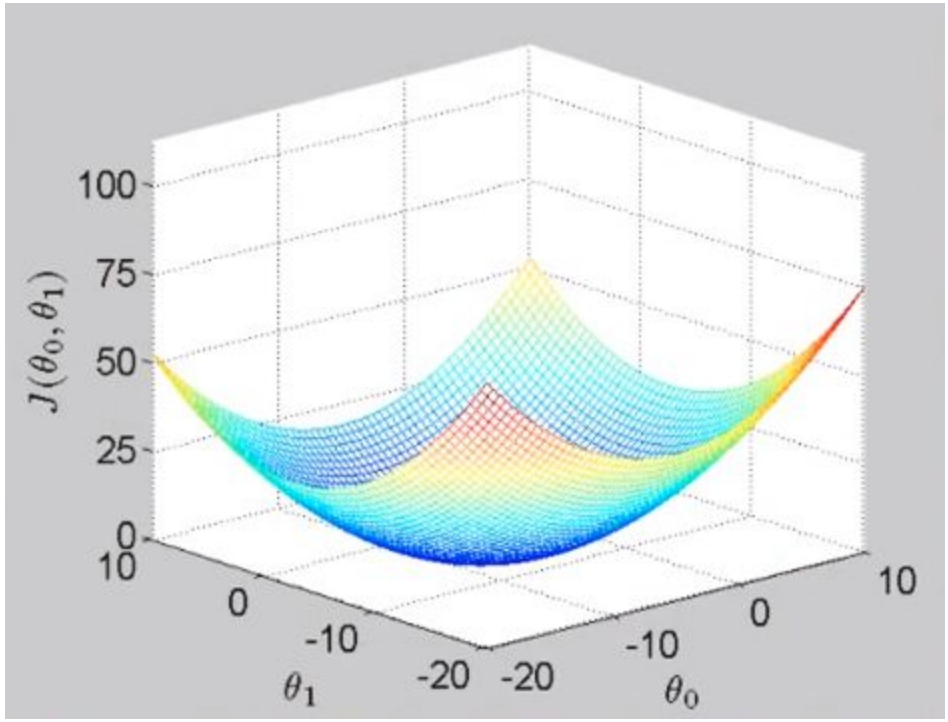


BƯỚC 4: LẶP LẠI ĐẾN KHI HỘI TỤ



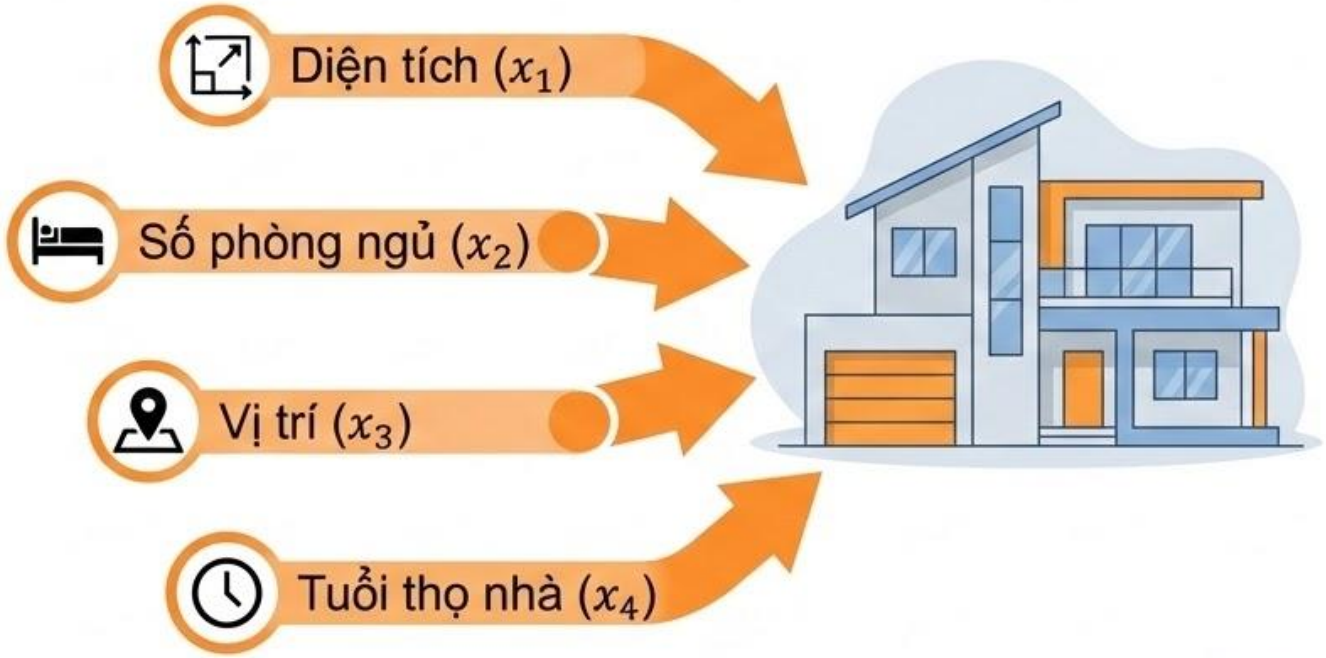
MINH HỌA ĐỒ THỊ GRADIENT DESCENT

- Hàm Loss thường có dạng hình cái bát (Paraboloid).
- Điểm bắt đầu ở trên cao (màu đỏ).
- Các mũi tên chỉ hướng đi zíc-zắc dần xuống điểm thấp nhất (Global Minimum - màu xanh).



HỒI QUY TUYẾN TÍNH ĐA BIẾN

- Thực tế: Một kết quả phụ thuộc nhiều yếu tố.
- Ví dụ: Giá nhà không chỉ phụ thuộc diện tích (x_1), mà còn:
  - Số phòng ngủ (x_2).
  - Vị trí (x_3).
  - Tuổi thọ nhà (x_4).



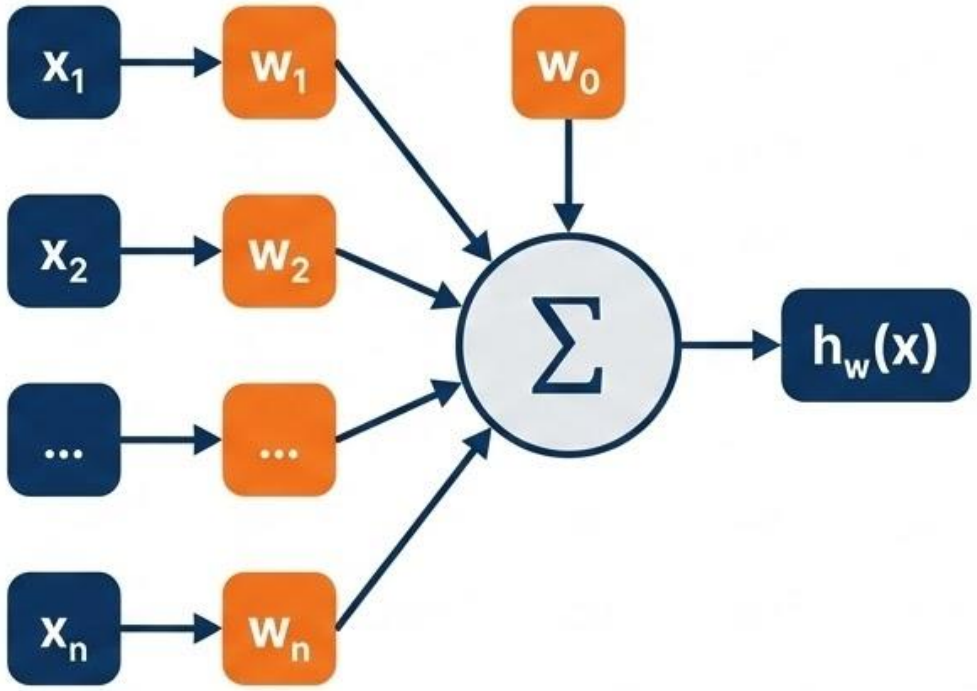
MÔ HÌNH TOÁN HỌC MỞ RỘNG

CÔNG THỨC:

$$h_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

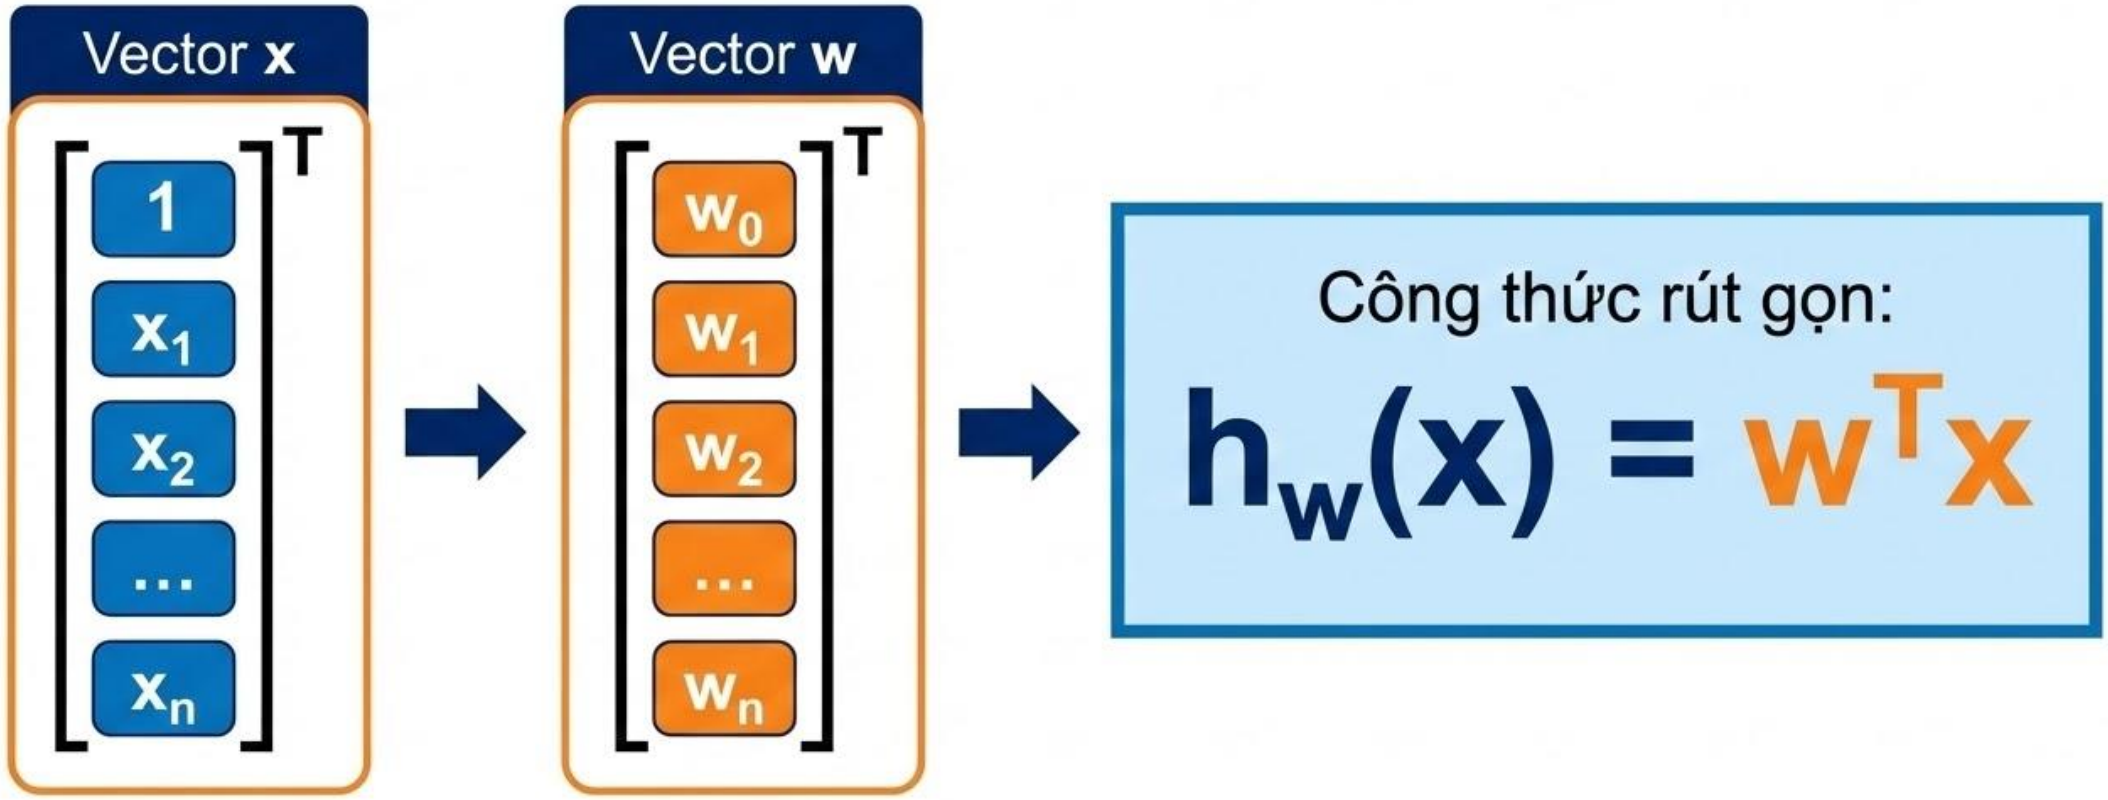
TRONG ĐÓ:

- **n**: Số lượng đặc trưng (biến đầu vào).
- $w_0, \dots, w_n$: Các tham số cần tìm.



BIỂU DIỄN DẠNG VECTOR

Để tính toán nhanh trên máy tính, ta dùng ma trận/vector.



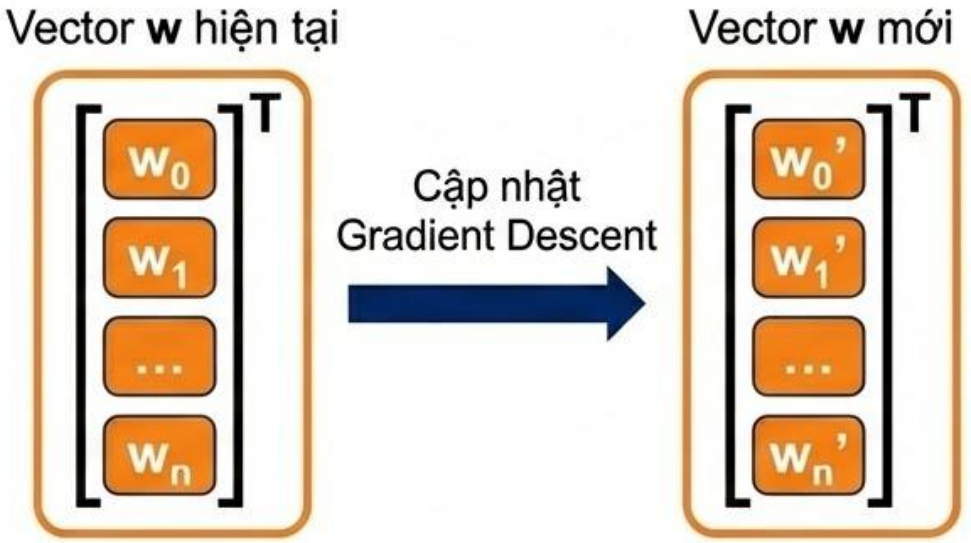
HÀM MẤT MÁT CHO ĐA BIẾN

- **Sử dụng MSE cho Vector**

$$J(w) = \frac{1}{m}\sum_{i=1}^{m}(h_w(x^{(i)}) - y^{(i)})^2$$

Vẫn sử dụng MSE nhưng áp dụng cho vectơr, tính tổng bình phương sai số trên toàn bộ tập dữ liệu m mẫu.

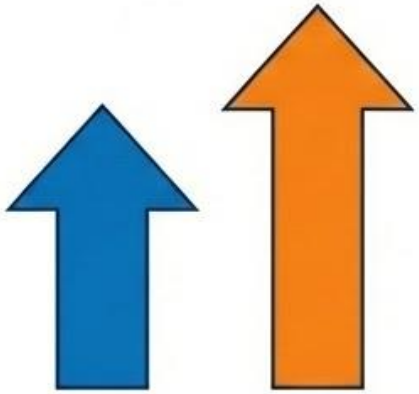
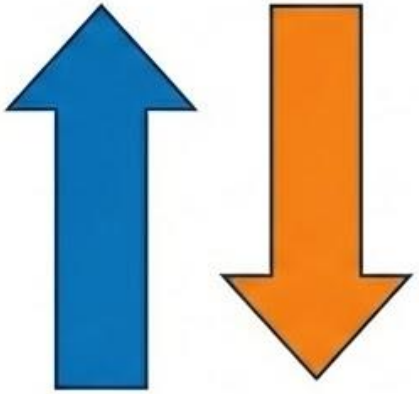
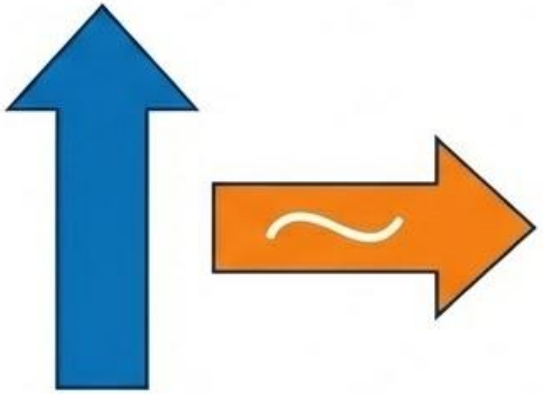
- **Tối ưu hóa bằng Gradient Descent**



Vẫn sử dụng Gradient Descent để tối ưu hóa tất cả các tham số w_j đồng thời trong mỗi bước lặp.

Ý NGHĨA CỦA TRỌNG SỐ (w)

Trọng số thể hiện mức độ ảnh hưởng của đặc trưng lên kết quả.

w_j dương	w_j âm	$w_j \approx 0$
		
w_j **dương**: Tăng đặc trưng → Tăng kết quả (Tỉ lệ thuận).	w_j **âm**: Tăng đặc trưng → Giảm kết quả (Tỉ lệ nghịch).	$w_j \approx 0$: Đặc trưng ít ảnh hưởng đến kết quả.

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỒI QUY

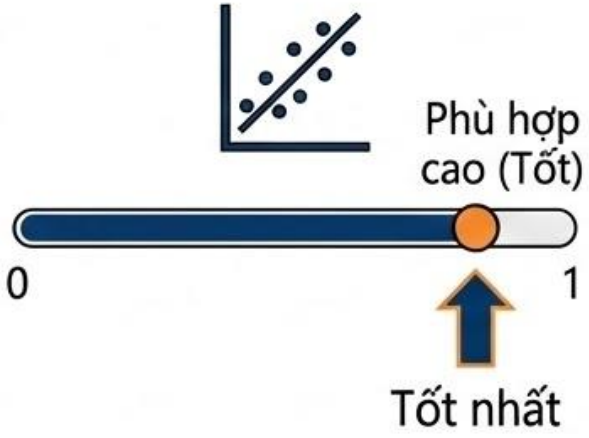
MSE (Mean Squared Error)

Sai số càng nhỏ càng tốt.



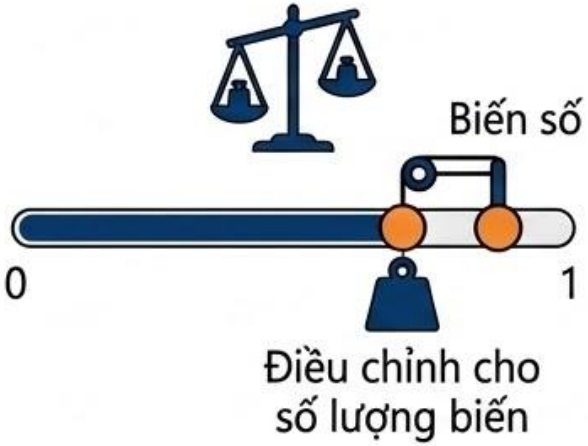
R-squared (R^2)

Đo mức độ phù hợp của mô hình (từ 0 đến 1, càng gần 1 càng tốt).



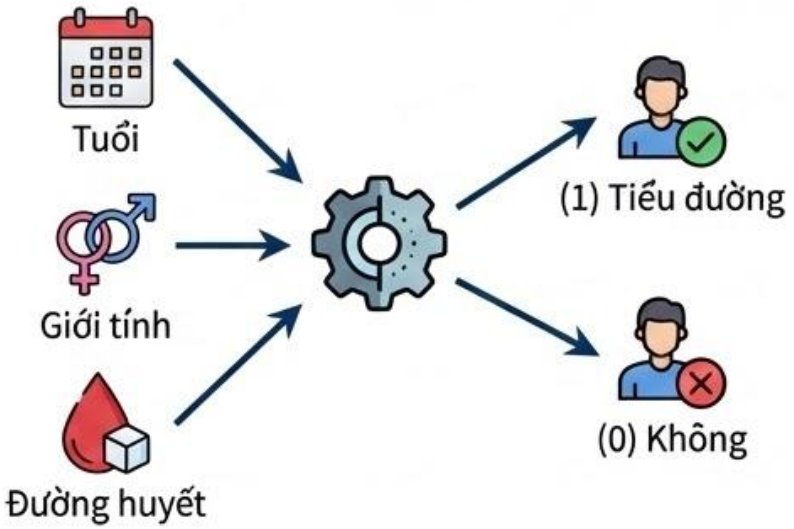
Adjusted R-squared

Dùng khi có nhiều biến số, tránh hiện tượng thêm biến rác vẫn tăng R2.



BÀI TOÁN PHÂN LỚP NHỊ PHÂN

Ví dụ:



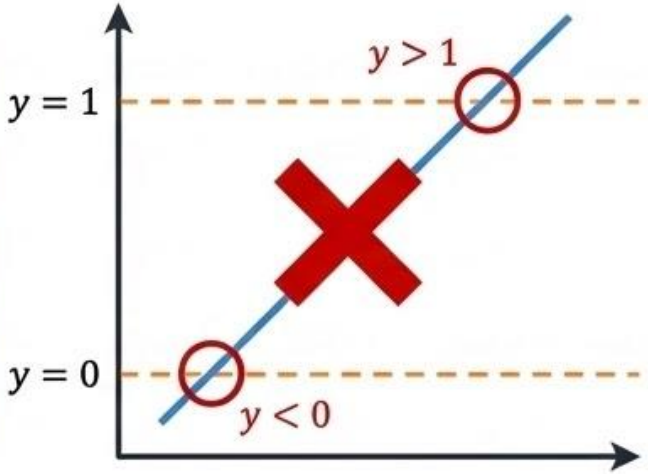
Dự đoán bệnh nhân bị tiểu đường (1) hay không (0) dựa trên Tuổi, Giới tính, Đường huyết.

Nhãn đầu ra y:



Chỉ nhận giá trị 0 hoặc 1.

Tại sao Hồi quy tuyến tính không phù hợp?

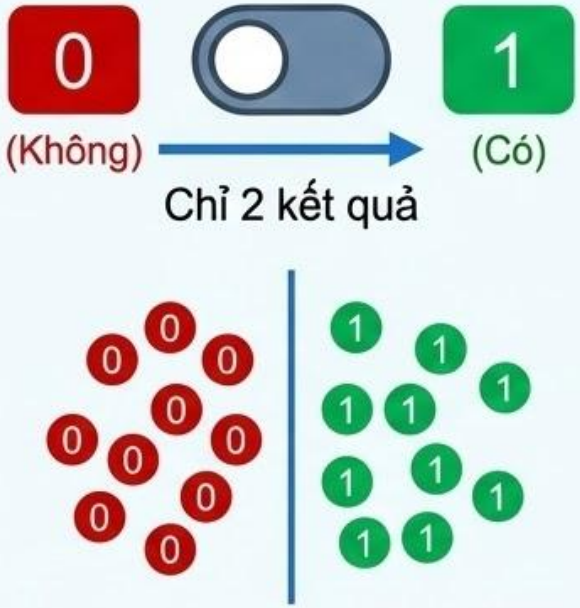


Vì nó trả về giá trị liên tục có thể lớn hơn 1 hoặc nhỏ hơn 0.

GIỚI THIỆU HỒI QUY LOGISTIC

Bài toán Phân lớp Nhị phân

Dùng cho bài toán phân lớp nhị phân.



Mục tiêu: Dự đoán Xác suất

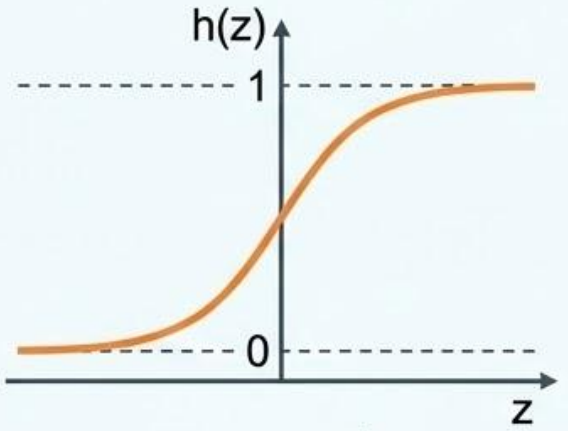
Dự đoán xác suất xảy ra của sự kiện (giá trị từ 0 đến 1).



Giá trị liên tục

Sử dụng Hàm Logistic (Sigmoid)

Hàm Logistic (Hàm Sigmoid) để **nén** đầu ra vào khoảng (0, 1).



$$h(z) = \frac{1}{1 + e^{-z}}$$

Đường cong chữ S

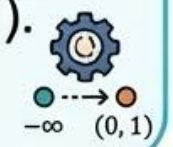
HÀM SIGMOID (LOGISTIC FUNCTION)

Công thức & Tính chất

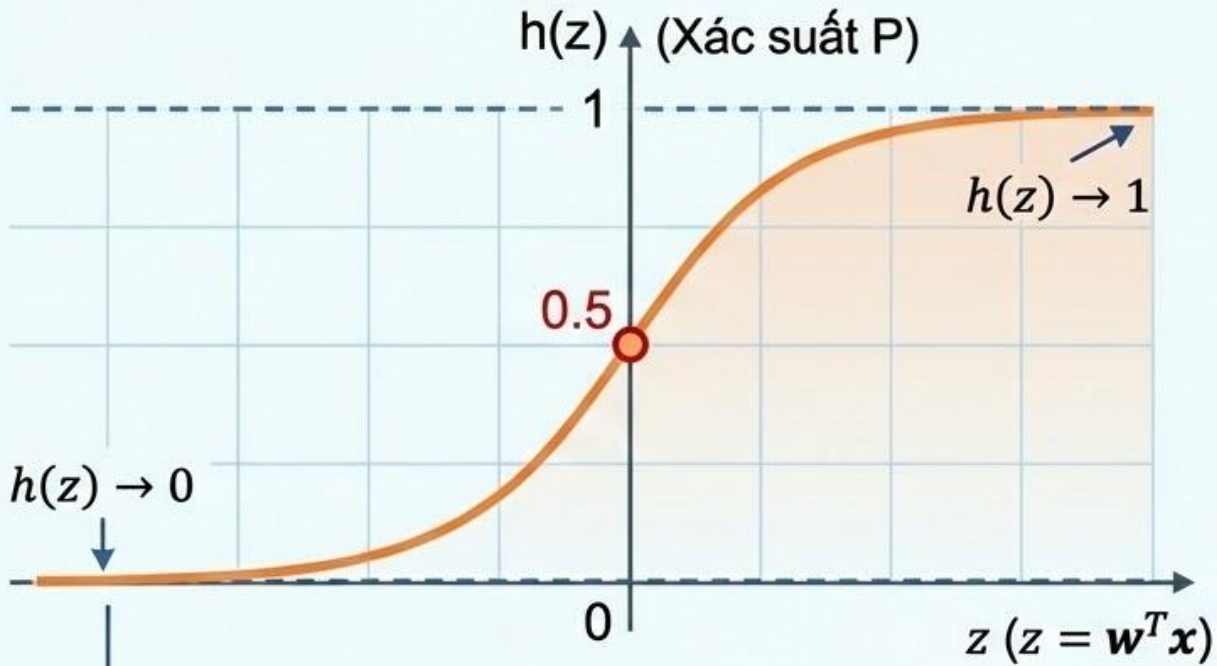
$$h_w(x) = \frac{1}{1 + e^{-z}}$$

trong đó $z = \boldsymbol{w}^T \boldsymbol{x}$

- Đồ thị hình chữ S:
- Khi $z \to \infty$, $h(z) \to 1$.
- Khi $z \to -\infty$, $h(z) \to 0$.
- Chuyển đổi mọi giá trị đầu vào thành khoảng (0, 1).



Đồ thị hình chữ S (Sigmoid Curve)

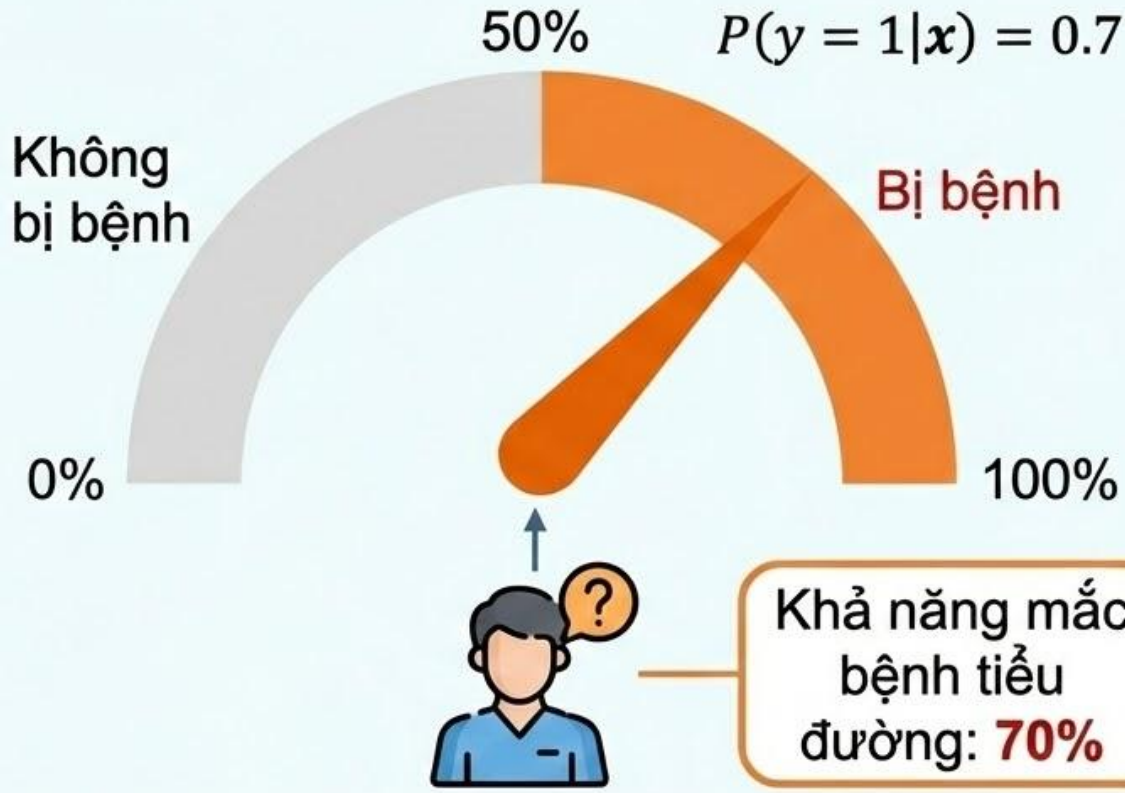


Hàm Sigmoid nén giá trị z bất kỳ vào khoảng (0, 1), phù hợp để biểu diễn xác suất.

Ý NGHĨA XÁC SUẤT

- Đầu ra của mô hình là xác suất mẫu thuộc lớp 1 (Lớp dương).
- P(y=1|**x**): Xác suất y=1 khi biết **x**.
- Ví dụ: $h_w(\boldsymbol{x}) = 0.7$ nghĩa là có 70% khả năng bệnh nhân bị tiểu đường.

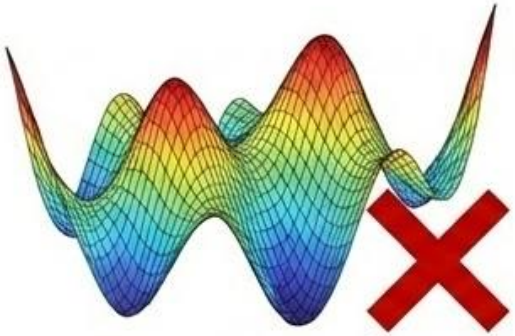
Ví dụ: Xác suất mắc bệnh tiểu đường



HÀM MẤT MÁT (LOG LOSS)

Vấn đề với MSE (Mean Squared Error)

- Không dùng MSE (vì tạo ra hàm không không lồi, khó tối ưu).



Hàm không lồi
(Non-Convex)

Dùng Log Loss (Binary Cross-Entropy)

- Dùng Log Loss (Binary Cross-Entropy):
  - Hàm lồi (Convex), dễ tìm cực tiểu.



Hàm lồi
(Convex)

Công thức Log Loss:

$$J(w) = \frac{-1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log(h_w) + (1-y^{(i)})\log(1-h_w)\right]$$

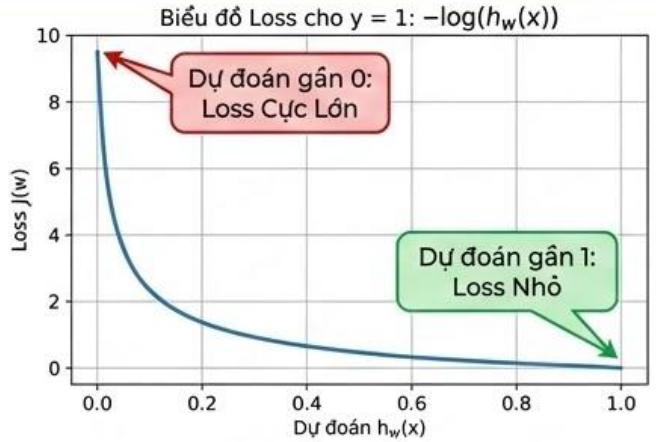
$y^{(i)}$: Nhãn thực tế, h_w: Xác suất dự đoán, m: Số lượng mẫu

PHÂN TÍCH HÀM LOG LOSS

PHÂN TÍCH HÀM LOG LOSS

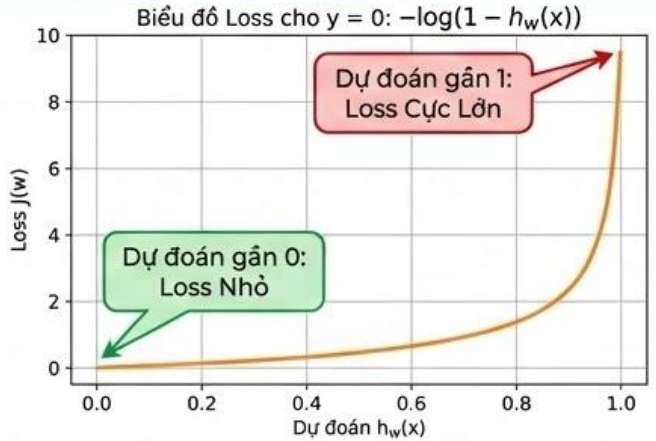
Cách hoạt động và ưu điểm của Binary Cross-Entropy

1. Trường hợp Thực Tế y = 1 (Lớp Dương)



- Khi $y = 1$, hàm Loss là $J(w) = -\log(h_w(x))$.
- Loss tiến tới 0 khi dự đoán $h_w(x)$ gần 1 (đúng).
- Loss tiến tới vô cùng khi dự đoán $h_w(x)$ gần 0 (sai).

2. Trường hợp Thực Tế y = 0 (Lớp Âm)



- Khi $y = 0$, hàm Loss là $J(w) = -\log(1 - h_w(x))$.
- Loss tiến tới 0 khi dự đoán $h_w(x)$ gần 0 (đúng).
- Loss tiến tới vô cùng khi dự đoán $h_w(x)$ gần 1 (sai).

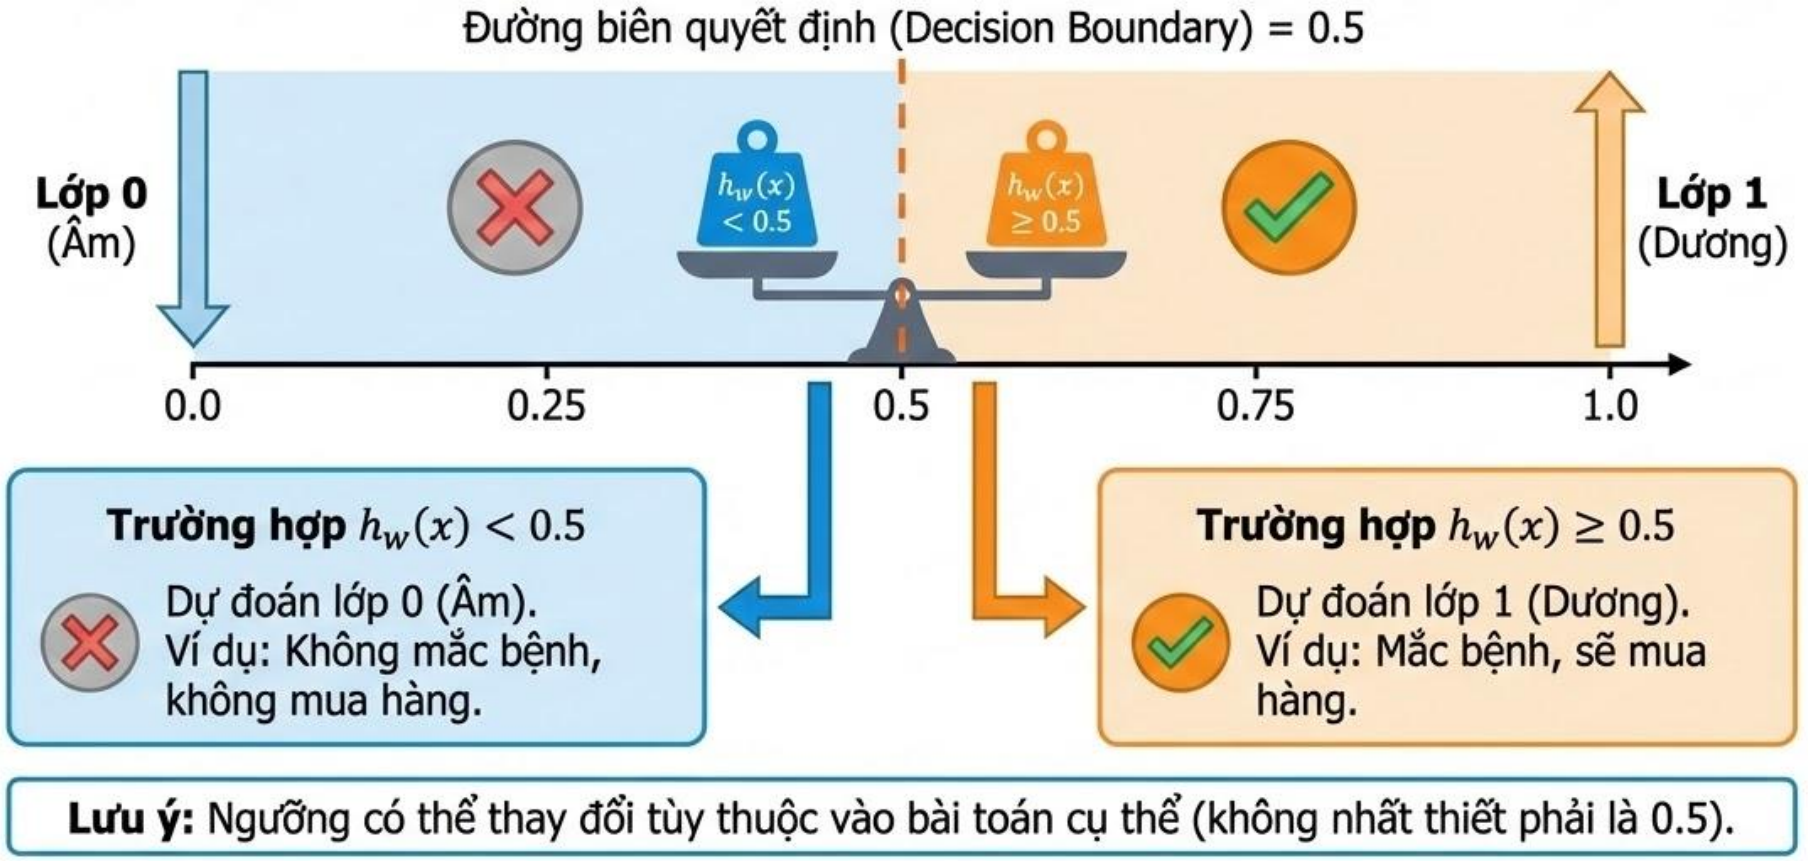
3. Ưu Điểm Của Hàm Log Loss

Phạt rất nặng các dự đoán sai: Đảm bảo mô hình học được từ những sai lầm lớn.

Hàm lồi (Convex): Dễ dàng tối ưu hóa và tìm được điểm cực tiểu toàn cục.

ĐƯỜNG BIÊN QUYẾT ĐỊNH (DECISION BOUNDARY)

Cách xác định lớp dự đoán từ xác suất đầu ra



ĐÁNH GIÁ MÔ HÌNH PHÂN LỚP

ACCURACY

Tỷ lệ dự đoán đúng trên tổng số.



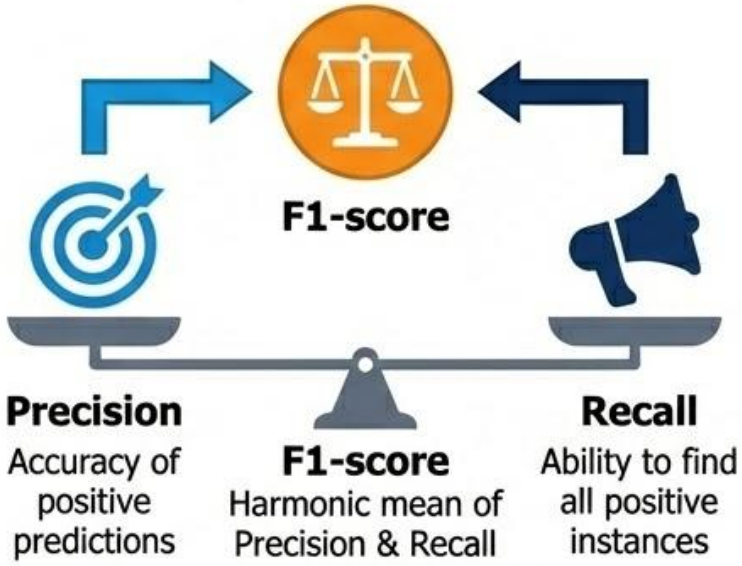
CONFUSION MATRIX

Ma trận nhầm lẫn (TP, TN, FP, FN).



PRECISION, RECALL, F1-SCORE

Dùng khi dữ liệu mất cân bằng.



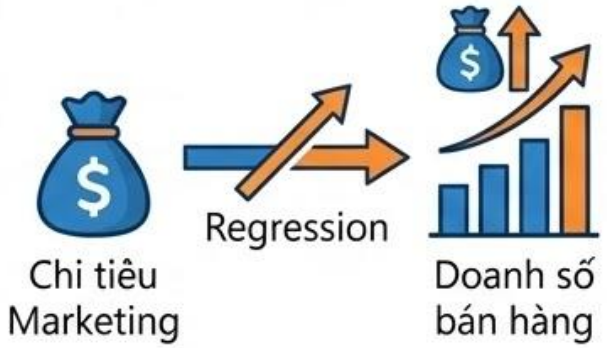
ỨNG DỤNG HỒI QUY TUYẾN TÍNH – KINH TẾ

DỰ ĐOÁN GIÁ CỔ PHIẾU



Dựa trên lịch sử và chỉ số kinh tế.

DỰ BÁO NHU CẦU



Doanh số bán hàng dựa trên chi tiêu Marketing.

ĐỊNH GIÁ BẤT ĐỘNG SẢN



Dựa trên vị trí, diện tích, số phòng.

ỨNG DỤNG HỒI QUY TUYẾN TÍNH – KHOA HỌC

Y Tế



Ước tính chi phí y tế.



Dự đoán chiều cao/cân nặng trẻ em.

Môi trường



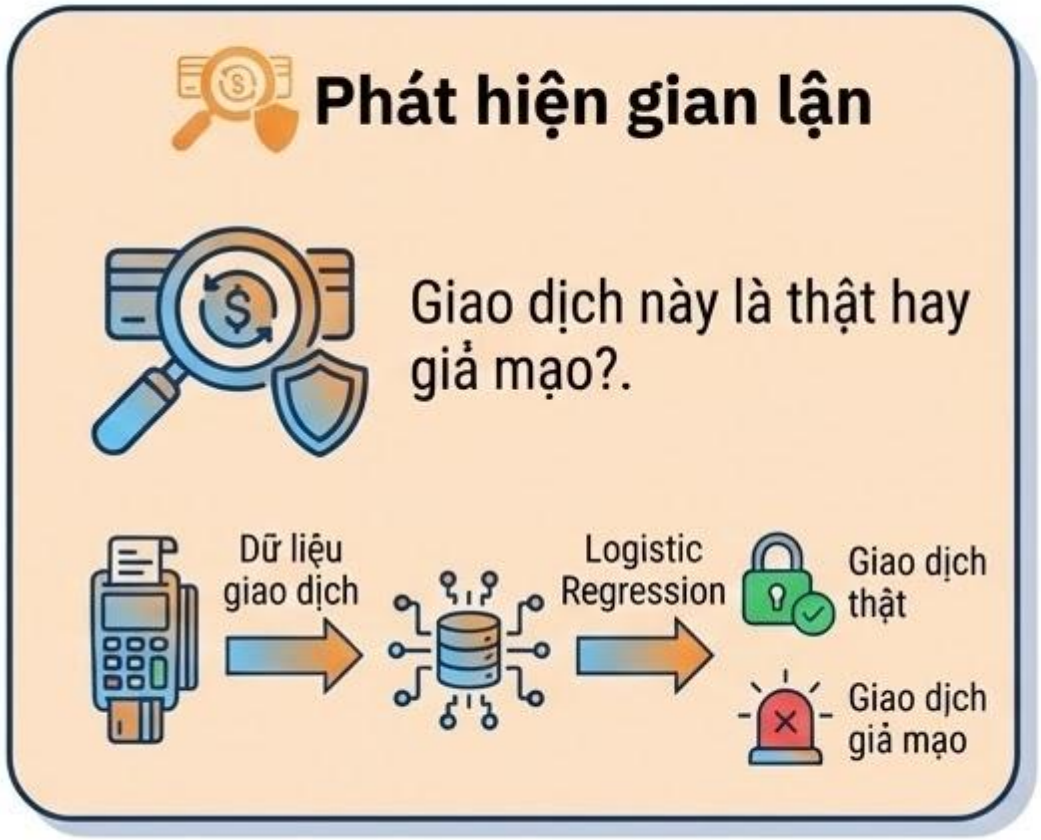
Dự báo mức tiêu thụ năng lượng.



Dự báo mức độ ô nhiễm không khí.

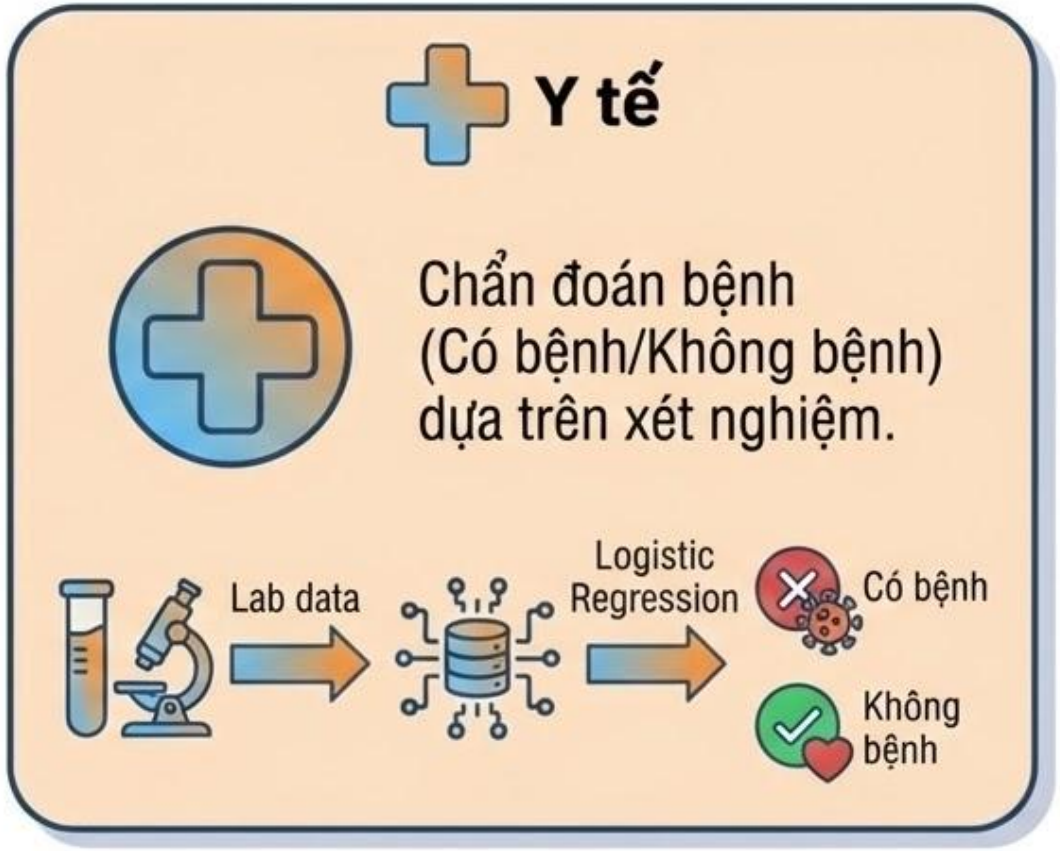
ỨNG DỤNG LOGISTIC – TÀI CHÍNH





ỨNG DỤNG LOGISTIC – MARKETING & Y TẾ





TÓM TẮT SO SÁNH

Đặc điểm	Hồi quy Tuyến tính	Hồi quy Logistic
Bài toán	Hồi quy (Giá trị liên tục)	Phân lớp (Nhãn rời rạc)
Hàm kích hoạt	Không (hoặc Tuyến tính)	Sigmoid (Phi tuyến)
Hàm mất mát	MSE (Mean Squared Error)	Log Loss (Binary Cross-Entropy)
Ứng dụng	Dự báo giá, doanh số	Chẩn đoán bệnh, phân loại

CÂU HỎI ÔN TẬP

- Giải thích sự khác biệt giữa hàm mất mát MSE và Log Loss.
- Tại sao cần Learning Rate phù hợp trong Gradient Descent?
- Tìm một bài toán thực tế cho mỗi loại mô hình và xác định Input/Output.

BÀI TẬP VỀ NHÀ

Bài tập 1

Thực hiện xây dựng mô hình **Hồi quy tuyến tính** dự đoán giá nhà trên bộ dữ liệu mẫu.

Bài tập 2

Thực hiện xây dựng mô hình **Hồi quy Logistic** phân loại hoa Iris.