CMP1020 – Học sâu

BÀI 4: MẠNG NEURON TÍCH CHẬP (CNN)

Giảng viên: TS. Bùi Danh Hường

MỤC TIÊU BÀI HỌC

- Hiểu nguyên lý hoạt động của phép tích chập (Convolution).
- Nắm vững các thành phần: Conv layer, Pooling layer, FC layer.
- Tính toán được kích thước đầu ra của các lớp.
- Hiểu các kiến trúc kinh điển: LeNet, AlexNet, VGG.
- Ứng dụng vào bài toán Phân loại ảnh và Phát hiện đối tượng.

TẠI SAO CẦN CNN?

Hạn chế Mạng truyền thống

- **Mất cấu trúc:** Duỗi phẳng vector làm mất quan hệ không gian.
- **Bùng nổ tham số:** Ảnh 1000x1000 → 1 triệu Input. Lớp ẩn 1000 neuron → 1 tỷ trọng số → Không thể tính toán.

Ưu điểm CNN

- **Kết nối cục bộ (Local Connectivity):** Mỗi neuron chỉ nhìn 1 vùng nhỏ.
- **Chia sẻ trọng số (Parameter Sharing):** Dùng chung bộ lọc cho toàn ảnh.

CẤU TRÚC TỔNG QUÁT CỦA CNN

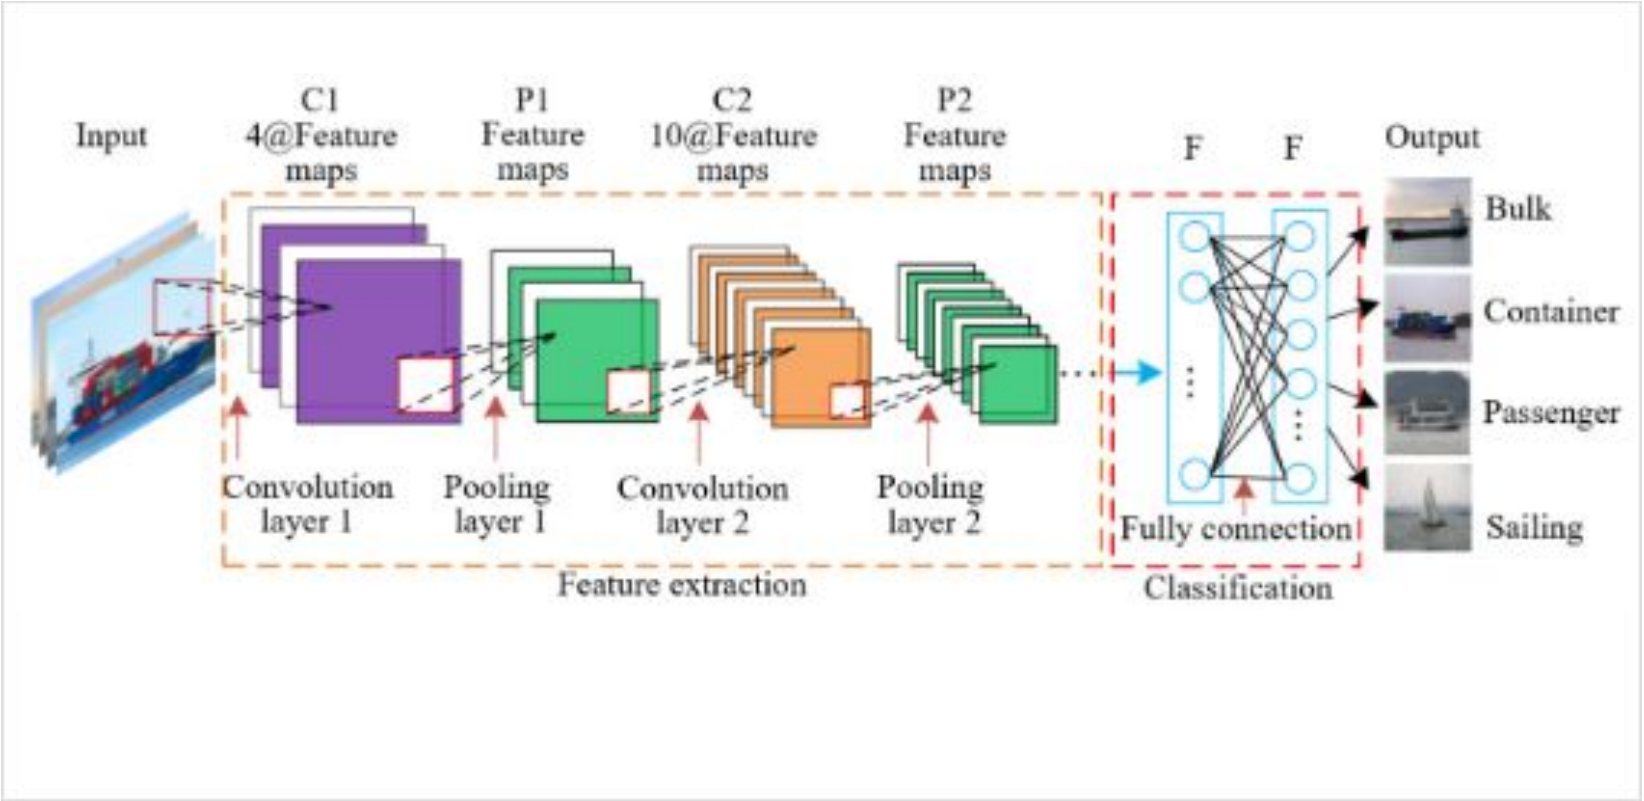
$$Input \rightarrow [[Conv \rightarrow ReLU] \rightarrow Pool] \times N \rightarrow Flatten \rightarrow FC \rightarrow Softmax$$

1. Khối trích xuất đặc trưng:

Gồm các lớp Convolution và Pooling xếp chồng lên nhau để học các features từ thấp đến cao.

21. Khối phân loại:

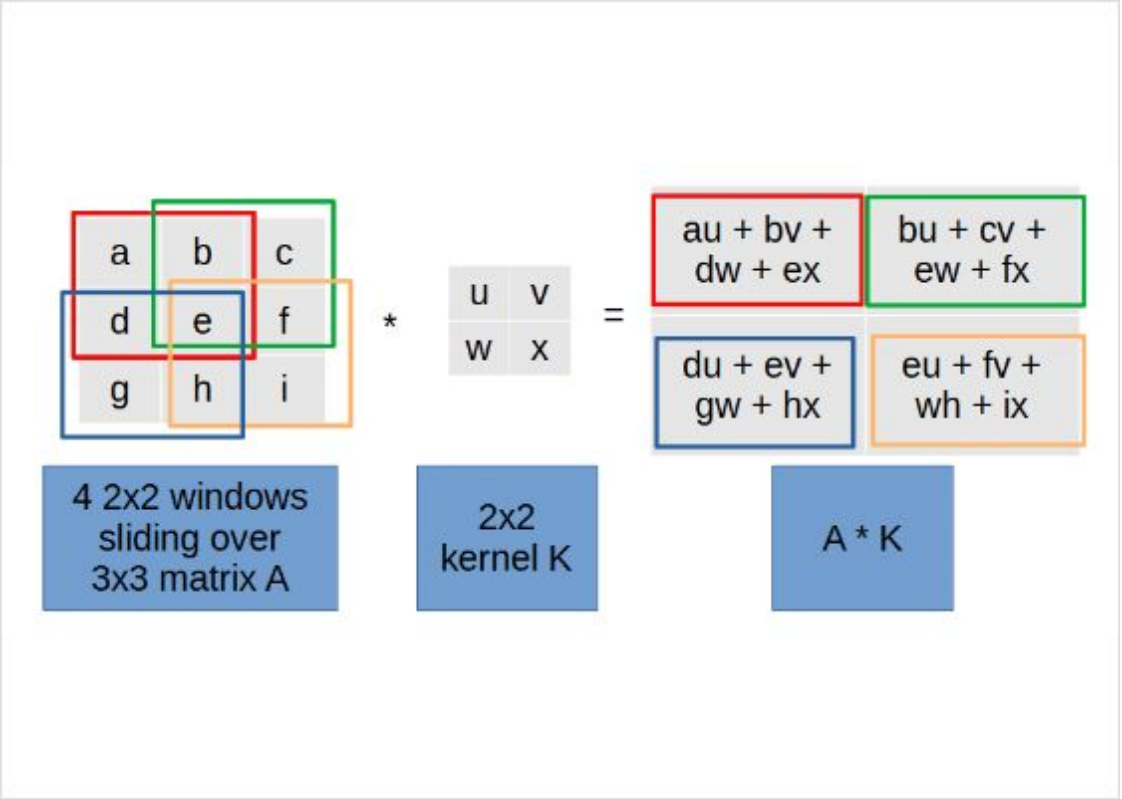
Khối Classification là phần cuối cùng của một mô hình CNN, có nhiệm vụ đưa ra dự đoán nhãn cho dữ liệu đầu vào



PHÉP TOÁN TÍCH CHẬP (CONVOLUTION)

- **Định nghĩa:** Trượt một Bộ lọc (Kernel/Filter) qua ma trận đầu vào để tính tích vô hướng.
- **Mục đích:** Trích xuất các đặc trưng như cạnh, góc, đường nét.
- **Ký hiệu:** Toán tử $*$

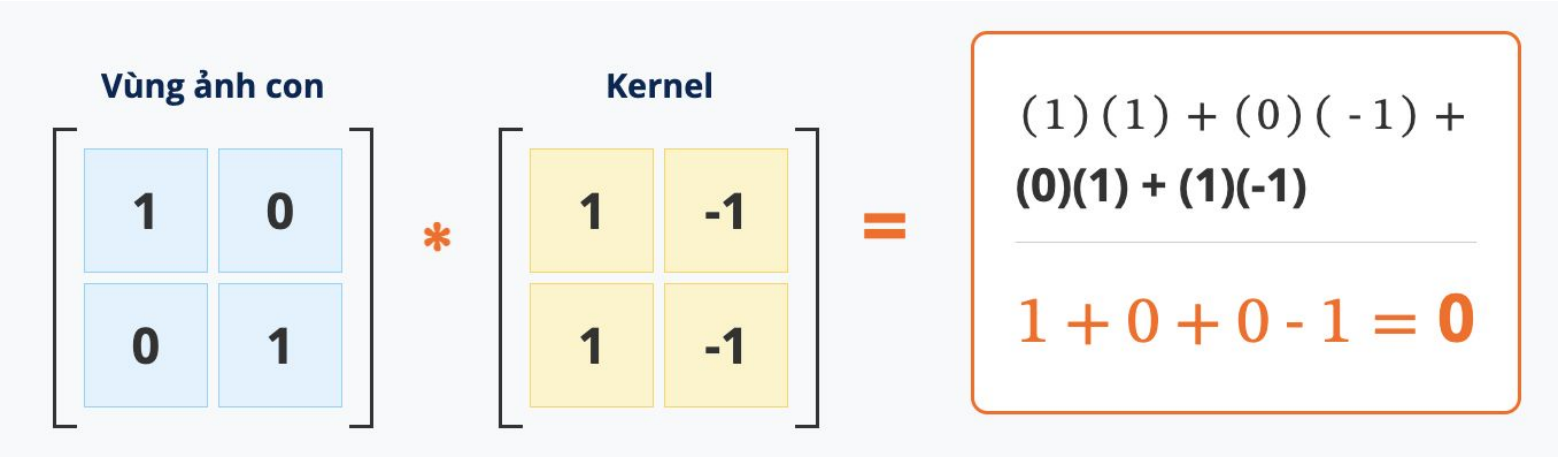
$$\text{FeatureMap} = \text{Input} * \text{Kernel}$$



VÍ DỤ TÍNH TOÁN (2D)

Input (I): Ma trận 5 × 5. **Kernel (K):** Ma trận 3 × 3.
Công thức tính giá trị tại vị trí (i, j) của Feature map:

$$S(i,j) = (I * K)(i,j) = \sum_m \sum_n I(i+m, j+n) \cdot K(m,n)$$



THAM SỐ: STRIDE (BƯỚC TRƯỢT)

Định nghĩa (S)

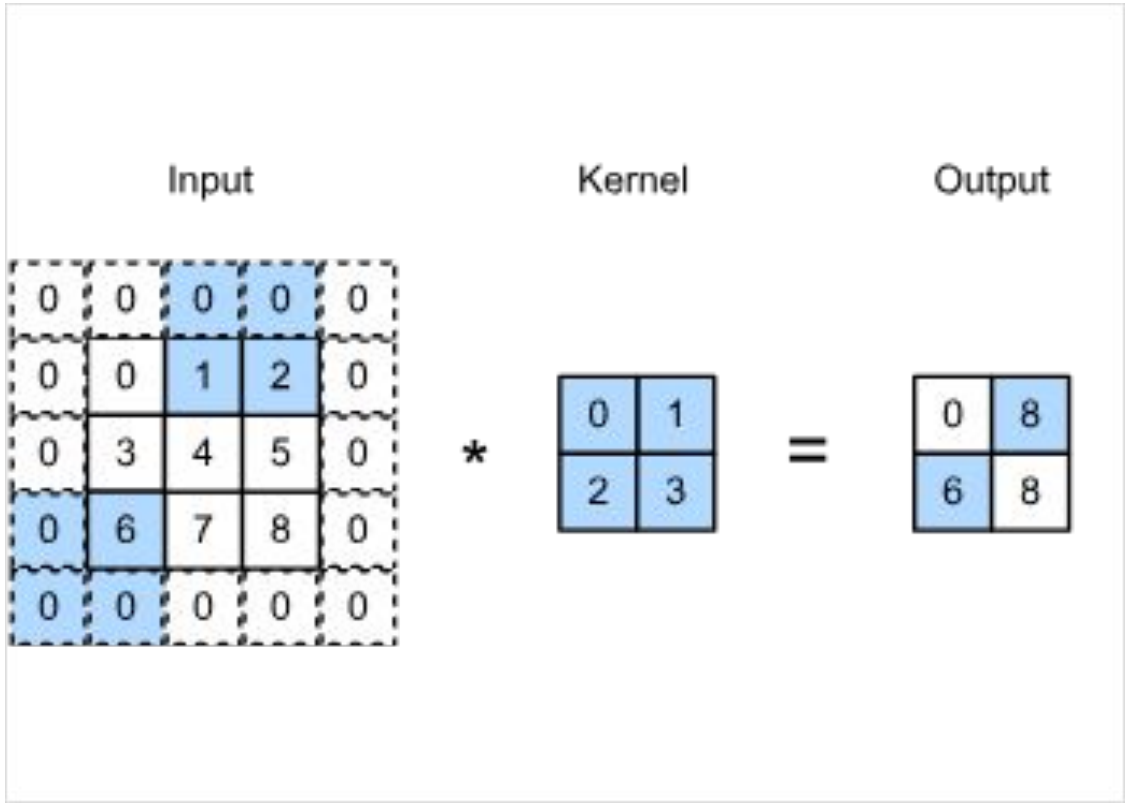
Số pixel mà bộ lọc dịch chuyển sau mỗi bước tính toán.

Tác động

- **Stride = 1:** Dịch chuyển từng pixel (Đầu ra lớn, giữ chi tiết).
- **Stride = 2:** Dịch chuyển 2 pixel/lần (Đầu ra giảm kích thước ~1/2).

THAM SỐ: PADDING (LỀ)

- **Vấn đề:** Khi tích chập, ảnh bị thu nhỏ dần và thông tin ở biên (cạnh ảnh) bị mất do ít được quét qua.
- **Giải pháp (p):** Thêm các pixel giá trị 0 bao quanh ảnh (Zero-padding).
- **Mục đích:** Giữ nguyên kích thước ảnh sau khi tích chập (Same padding).



CÔNG THỨC KÍCH THƯỚC ĐẦU RA

Input size: $W_{in} \times H_{in}$

Filter size: $F \times F$

Padding: P

Stride: S

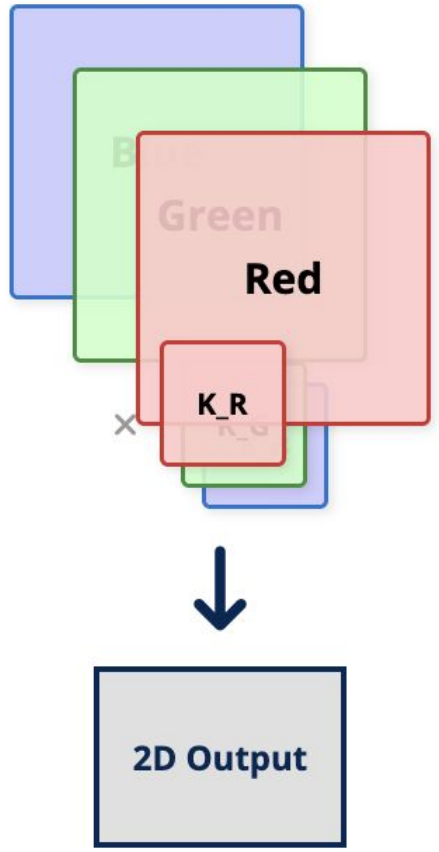
KÍCH THƯỚC OUTPUT ($W_{out} \times H_{out}$)

$$W_{out} = \left\lfloor \frac{W_{in} - F + 2P}{S} \right\rfloor + 1 \qquad H_{out} = \left\lfloor \frac{H_{in} - F + 2P}{S} \right\rfloor + 1$$

(Ký hiệu $\lfloor x \rfloor$ là hàm làm tròn xuống - floor function)

TÍCH CHẬP TRÊN KHỐI (ẢNH MÀU RGB)

- **Input:** Ảnh màu có 3 kênh (Red, Green, Blue).
  Kích thước: $H \times W \times 3$.
- **Filter (Bộ lọc):** Cũng phải có 3 kênh tương ứng.
  Kích thước: $F \times F \times 3$.
- **Tính toán:** Tích chập trên từng kênh riêng biệt, sau đó cộng tổng lại và thêm Bias.



Công thức Output:

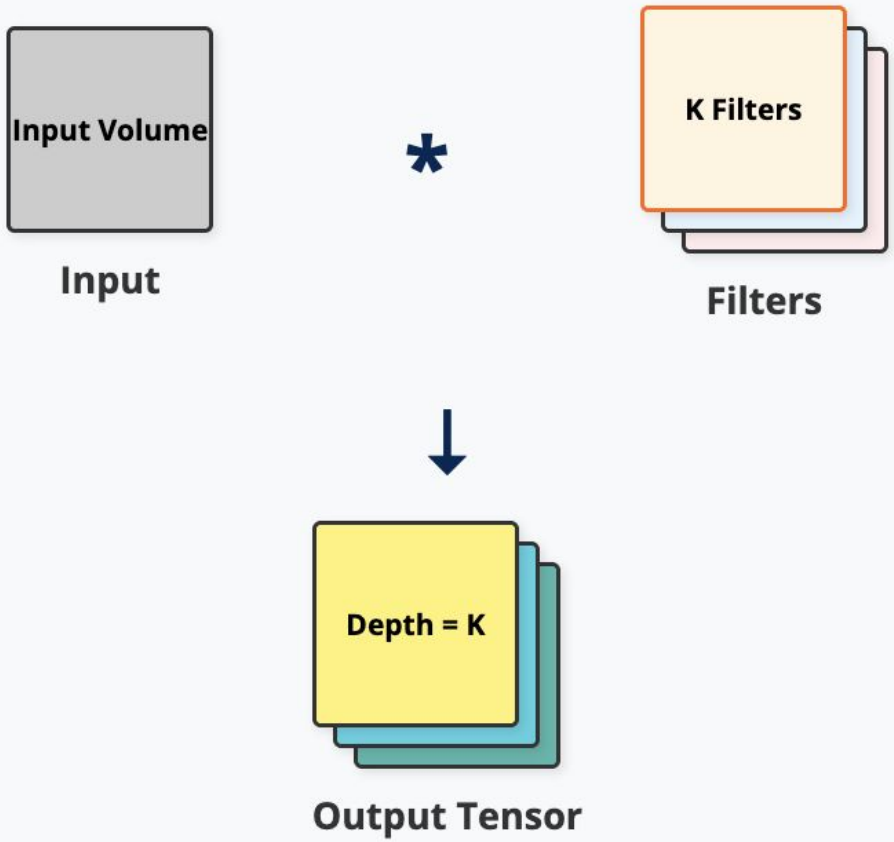
$$\text{Output} = \sum R * K_R + G * K_G + B * K_B + \text{Bias}$$

→ *Kết quả đầu ra là ma trận 2D (1 kênh duy nhất).*

SỬ DỤNG NHIỀU BỘ LỌC

- **Vấn đề:** Một bộ lọc chỉ học được 1 đặc trưng duy nhất (ví dụ: chỉ phát hiện cạnh dọc hoặc cạnh ngang).
- **Giải pháp:** Muốn học nhiều đặc trưng → Dùng K bộ lọc khác nhau.

Input:	$W \times H \times C$
Filters (K cái):	$F \times F \times C$
Output (Tensor 3D):	$W_{\text{out}} \times H_{\text{out}} \times K$



CẤU TRÚC LỚP TÍCH CHẬP

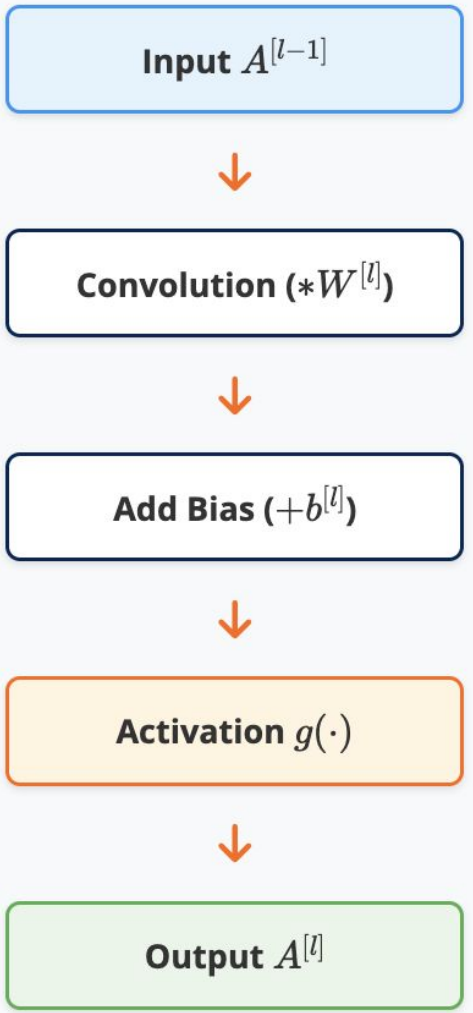
Đây là **khối xây dựng cơ bản** của mạng CNN.
Quy trình xử lý trong 1 lớp bao gồm:

1. **Convolution:** Tính tích chập tuyến tính giữa Input và Filter.
2. **Add Bias:** Cộng hệ số chặn vào kết quả.
3. **Activation:** Áp dụng hàm kích hoạt phi tuyến (thường là ReLU).

Công thức tổng quát:

$$A^{[l]} = g(W^{[l]} * A^{[l-1]} + b^{[l]})$$

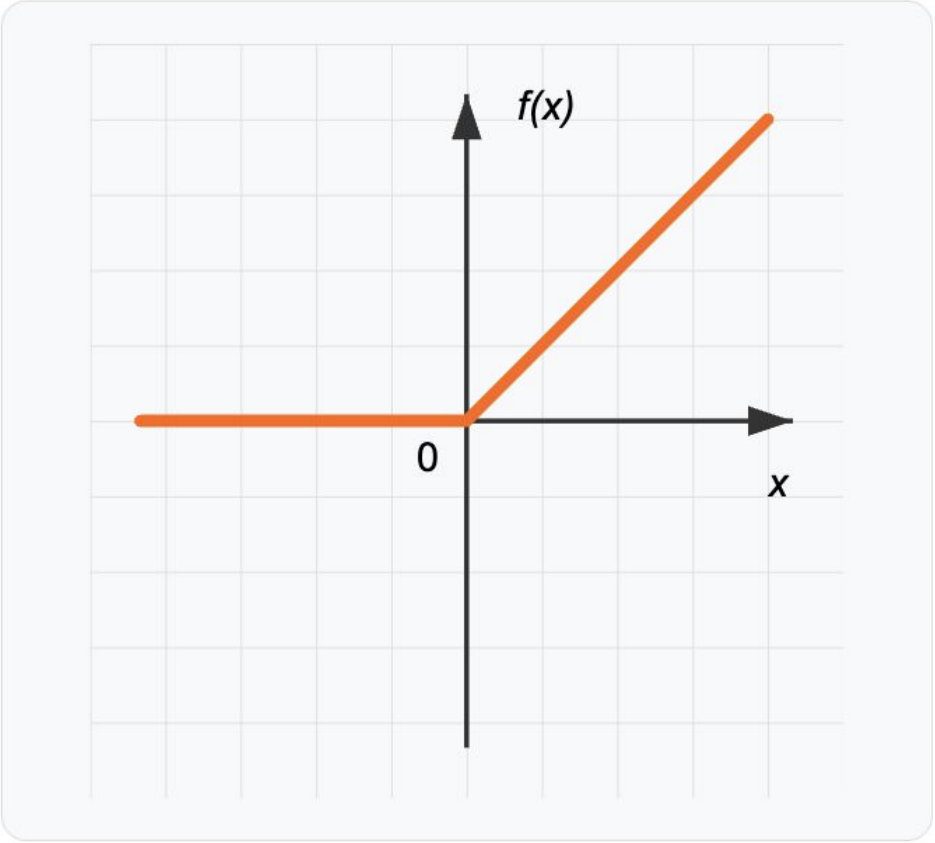
(Trong đó g là hàm kích hoạt)



HÀM KÍCH HOẠT RELU

$$f(x) = \max(0, x)$$

- **Tính toán nhanh:** Chỉ cần phép so sánh với 0 (không cần hàm mũ như Sigmoid).
- **Hội tụ nhanh hơn:** Giúp Gradient Descent chạy nhanh hơn do không bị bão hòa ở miền dương.
- **Giải quyết vấn đề biến mất đạo hàm** (Vanishing Gradient) khi mạng sâu.



Thứ tự áp dụng: CONV → RELU → POOL

LỚP POOLING (LỚP GỘP)

- **Mục đích:** Giảm kích thước không gian (W, H) của Feature Map.
  → Giảm số lượng tham số và khối lượng tính toán.
- **Đặc điểm:**
  - Hoạt động độc lập trên từng kênh độ sâu (Depth).
  - **Không có tham số trọng số** để học (W, b).

Các siêu tham số (Hyperparameters):

- Kích thước bộ lọc (F)
- Bước trượt - Stride (S)



Input: $W \times H \times D$

Pooling



Output: $\frac{W}{2} \times \frac{H}{2} \times D$

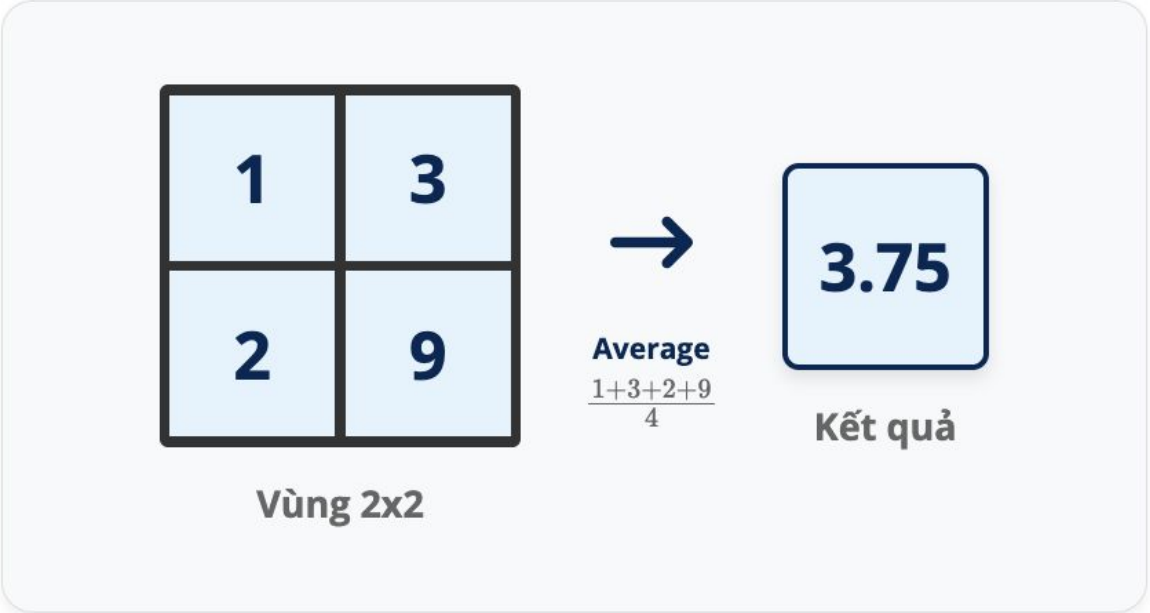
MAX POOLING (GỘP CỰC ĐẠI)

- **Cơ chế:** Lấy giá trị lớn nhất trong vùng cửa sổ trượt (window).
- **Ý nghĩa:**
  - Giữ lại đặc trưng nổi bật nhất (kết cấu, cạnh, góc).
  - Giảm nhiễu (loại bỏ các giá trị nhỏ không quan trọng).
- Đây là loại Pooling **phổ biến nhất** trong các mạng CNN hiện đại.



AVERAGE POOLING (GỘP TRUNG BÌNH)

- **Cơ chế:** Tính giá trị trung bình cộng của các phần tử trong vùng cửa sổ trượt.
- **Ý nghĩa:**
  - Làm mượt ảnh (smoothing).
  - Giảm nhiễu nhưng cũng có thể làm mờ các đặc trưng sắc nét.
- Hiện nay **ít được sử dụng hơn** so với Max Pooling trong các kiến trúc CNN hiện đại.



FLATTENING (LÀM PHẲNG)

- **Định nghĩa:** Chuyển đổi Tensor 3D (đầu ra từ các lớp Conv/Pool) thành Vector 1D.
- **Mục đích:** Chuẩn bị dữ liệu để đưa vào mạng Fully Connected (mạng nơ-ron truyền thống), vốn chỉ nhận đầu vào là vector.

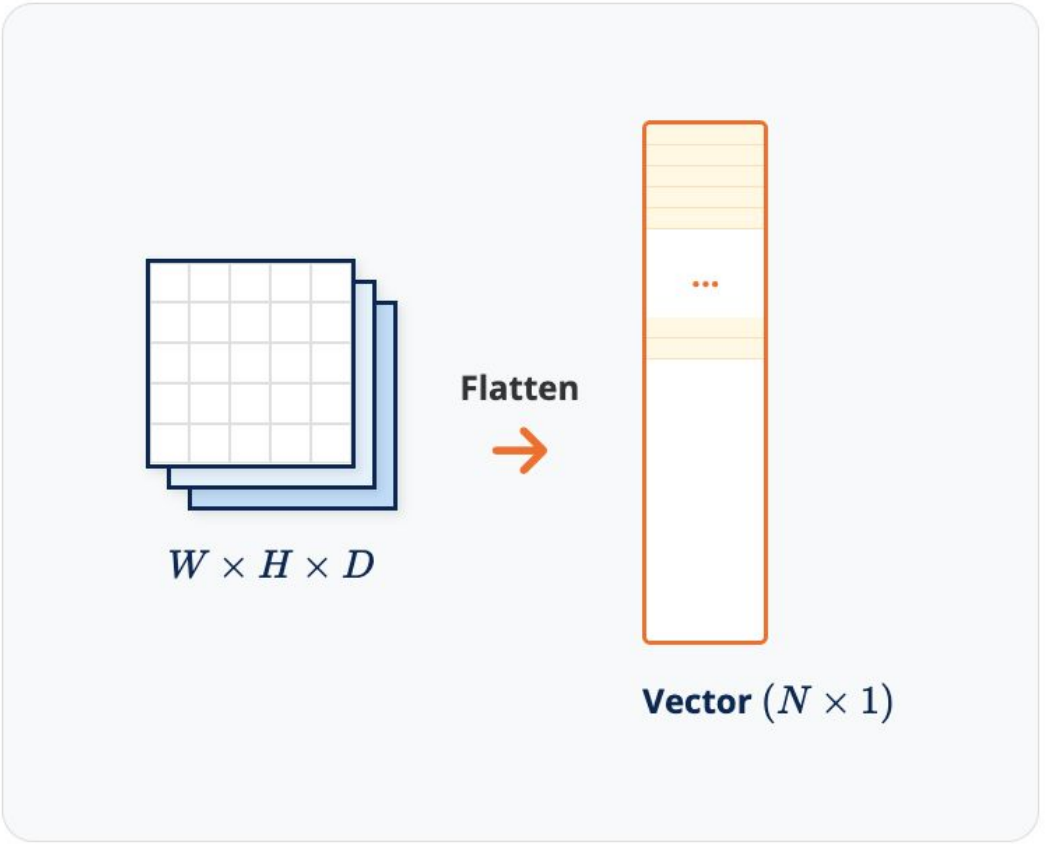
Ví dụ minh họa:

Feature Map: $5 \times 5 \times 16$

↓

Vector: $(400, 1)$

(Vì $5 \times 5 \times 16 = 400$*)*



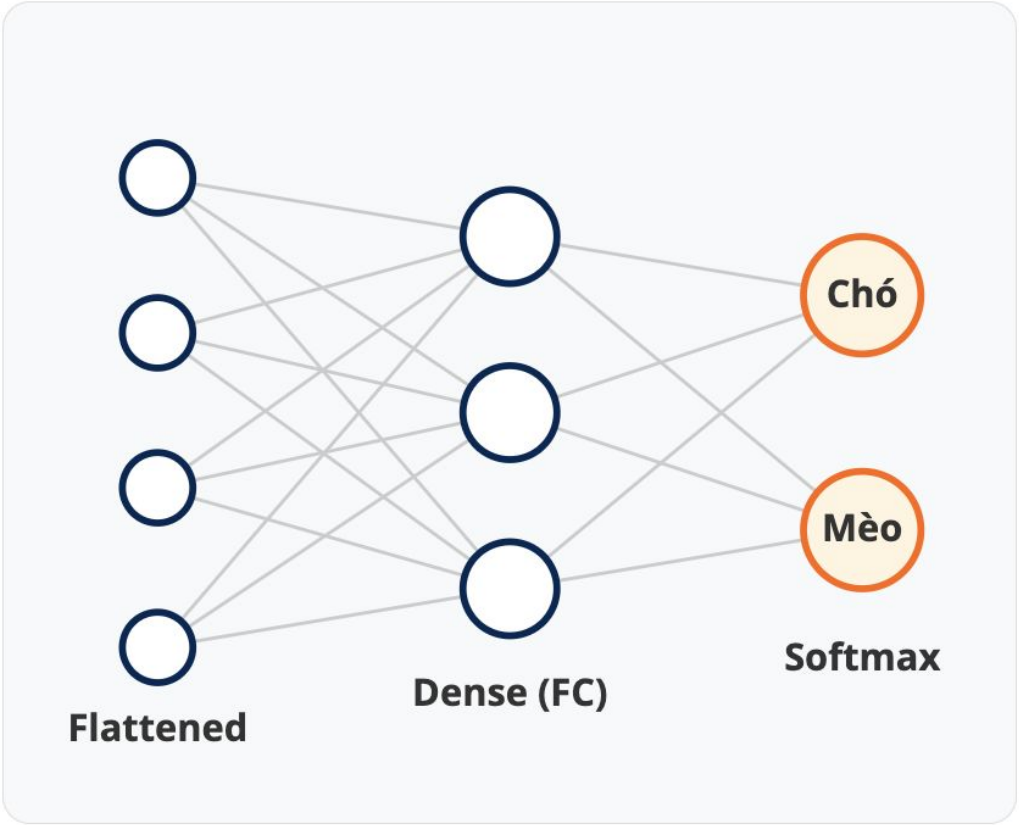
FULLY CONNECTED LAYER (FC)

- **Bản chất:** Giống mạng neuron truyền thống (MLP - Bài 3).
- **Chức năng:** Kết hợp tất cả các đặc trưng cục bộ (đã được làm phẳng) để đưa ra quyết định toàn cục.
- **Lớp cuối cùng (Output):** Thường dùng hàm **Softmax** để tính xác suất phân loại.

Công thức Softmax:

$$P(y = j|x) = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}}$$

(Xác suất để ảnh thuộc về lớp j)



LỊCH SỬ PHÁT TRIỂN

1998

LeNet-5

Mở đầu CNN

2012

AlexNet

Bùng nổ Deep Learning

2014

VGG

Mạng sâu (Deep)

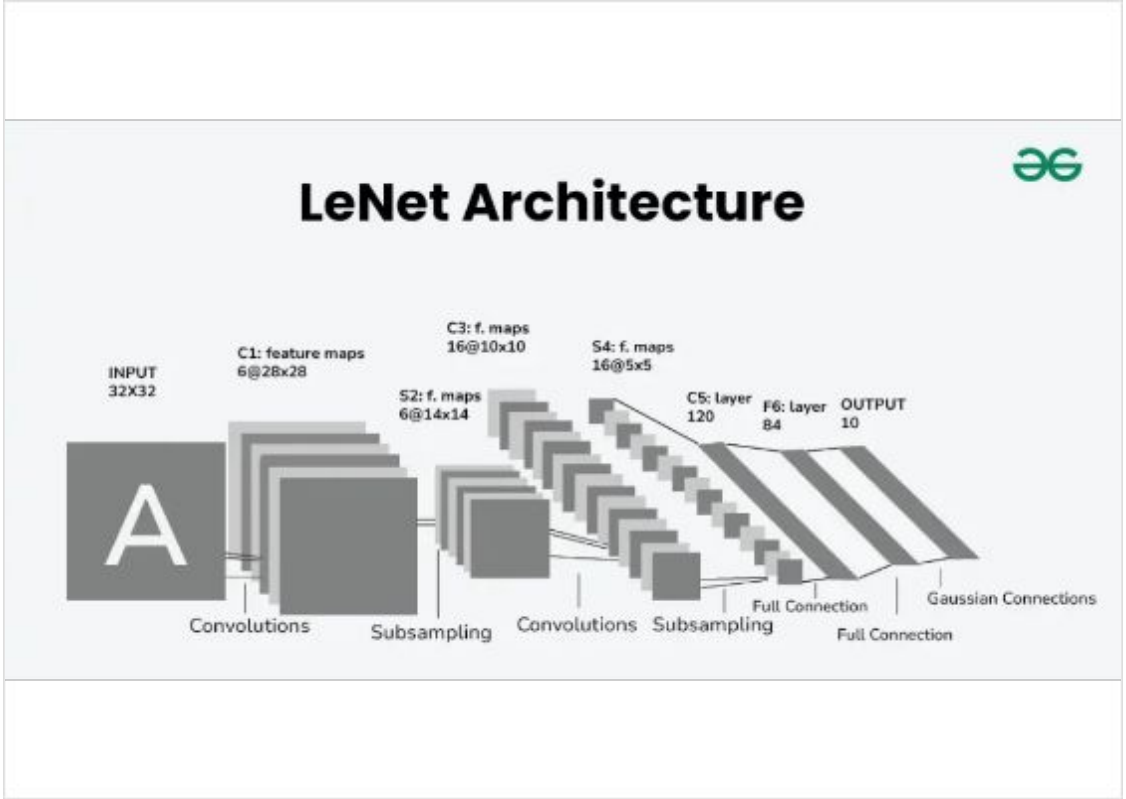
2015

ResNet

Siêu sâu (Residual)

LENET-5 (1998)

- **Tác giả:** Yann LeCun.
- **Mục đích:** Nhận diện chữ số viết tay (MNIST).
- **Kiến trúc:** Input(32x32) → Conv → Avg Pool → Conv → Avg Pool → FC → Output.
- **Đặc điểm:** Dùng Sigmoid/Tanh, Average Pooling. Filter ít (6, 16).

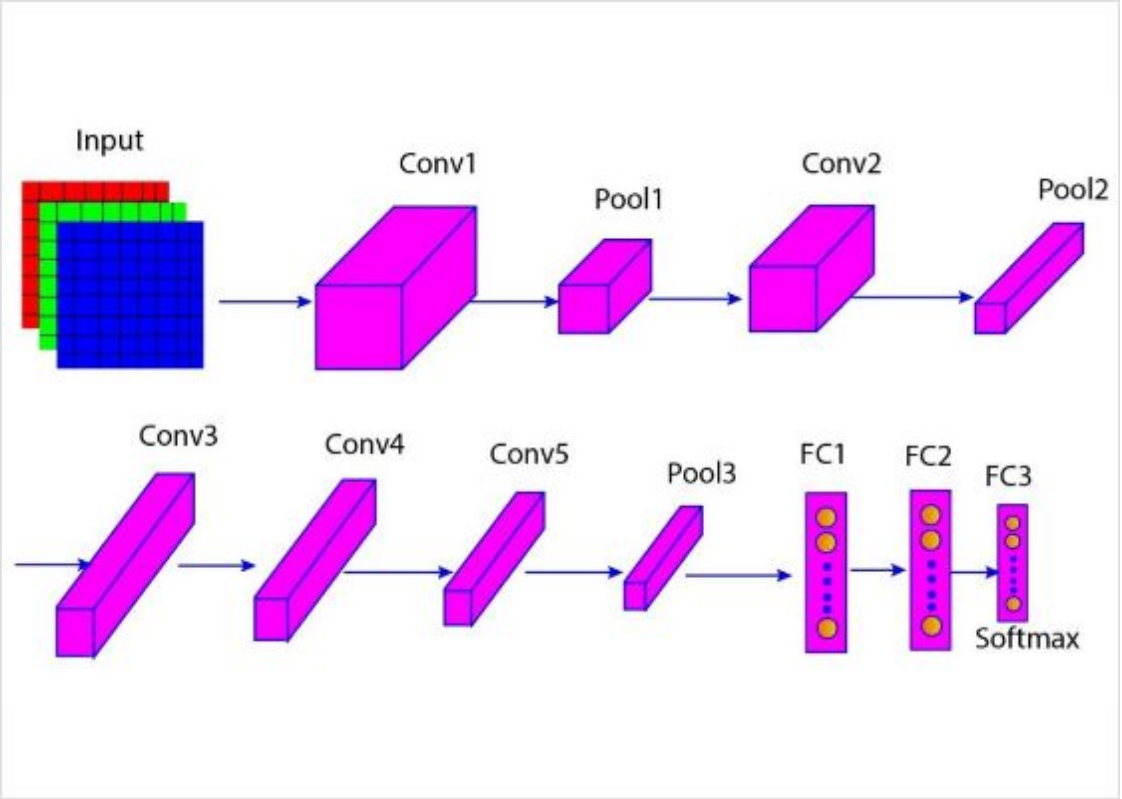


ALEXNET (2012)

Chiến thắng ImageNet 2012, độ lỗi giảm từ 26% xuống 15.3%.

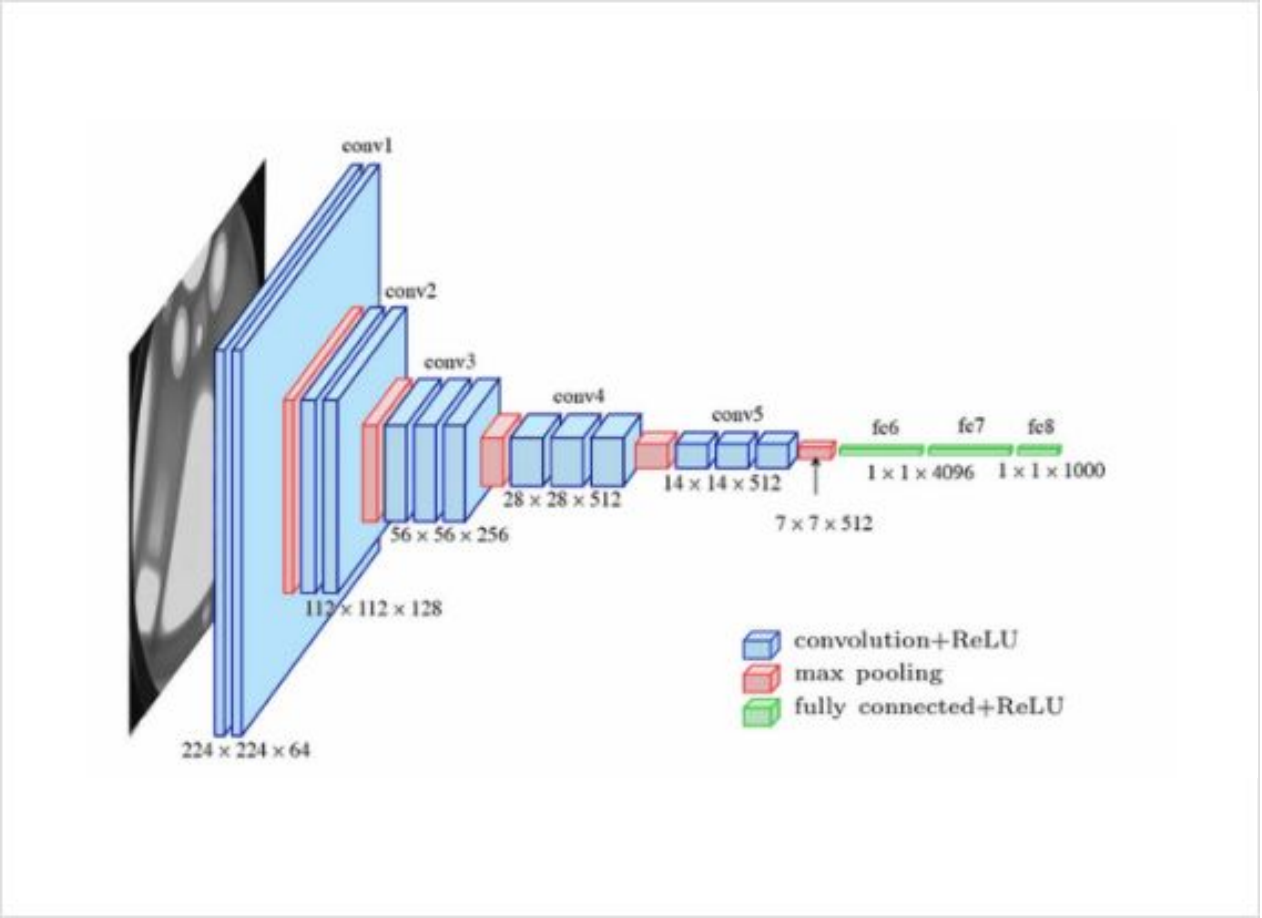
Cải tiến

- Sâu hơn (8 lớp).
- Dùng **ReLU** thay vì Sigmoid.
- Dùng Max Pooling.
- Dùng **Dropout** (0.5).



VGG-16/19 (2014)

- **Triết lý:** Đơn giản và Đồng nhất.
- Chỉ sử dụng bộ lọc kích thước **3x3** với Stride=1, Padding=1.
- Chỉ sử dụng Max Pooling 2x2 với Stride=2.
- **VGG-16:** 13 lớp Conv + 3 lớp FC.



TẠI SAO VGG DÙNG BỘ LỌC 3x3?

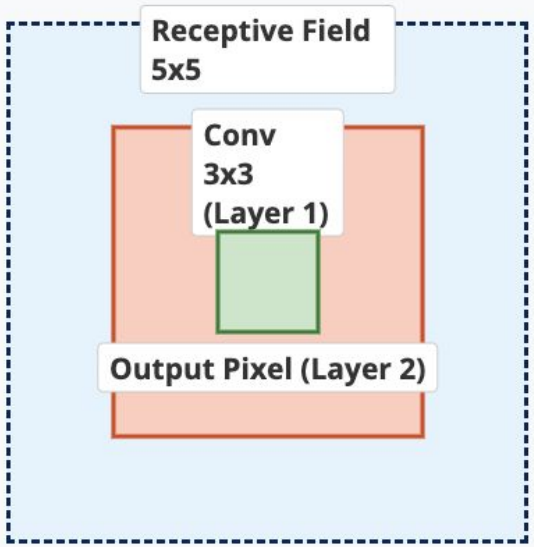
- **Vùng nhìn (Receptive Field):**
  - 2 lớp Conv 3x3 xếp chồng tương đương 1 lớp 5x5 ($3 + 3 - 1 = 5$).
  - 3 lớp Conv 3x3 tương đương 1 lớp 7x7.
- **Lợi ích 1: Giảm số lượng tham số**

$$3 \times (3^2C^2) < 1 \times (7^2C^2)$$

(27 < 49 → Giảm ~45%)

- **Lợi ích 2: Tăng tính phi tuyến**

Nhiều lớp ReLU hơn giữa các lớp Conv → Mạng học được các đặc trưng phức tạp tốt hơn.



Minh họa: Một pixel ở Output (xanh lá) nhìn thấy vùng 3x3 ở lớp giữa (cam), vùng này lại nhìn thấy vùng 5x5 ở Input (xanh dương).

TÍNH SỐ LƯỢNG THAM SỐ

Conv Layer

$$(F \times F \times C_{in} + 1) \times K$$

(+1 là Bias, K là số Filters)

Pool Layer

0 tham số

(Chỉ có siêu tham số)

FC Layer

$$(N_{in} + 1) \times N_{out}$$

VÍ DỤ MINH HỌA

Cấu hình:

Filter size (F):	**3**	(3x3)
Input Depth (C_{in}):		**64**
Filters (K):		**128**

Tính toán:

$$\text{Params} = (\mathbf{3} \times \mathbf{3} \times \mathbf{64} + 1) \times \mathbf{128}$$

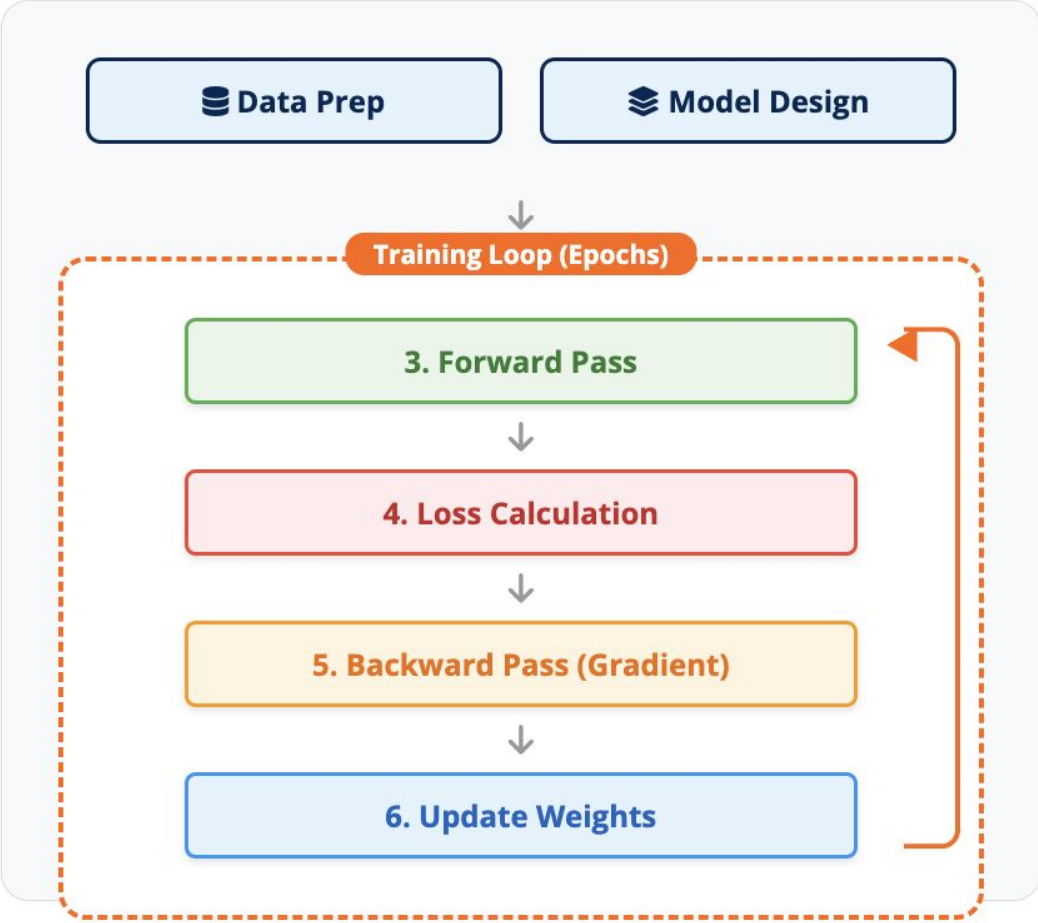
$$= (576 + 1) \times 128$$

$$= 577 \times 128$$

$$= \mathbf{73,856}$$

QUY TRÌNH HUẤN LUYỆN CNN

1. **Chuẩn bị dữ liệu**
   Resize, Normalize, Data Augmentation.
2. **Thiết kế mô hình**
   Chọn kiến trúc (số lớp, filter size, stride...).
3. **Forward Pass**
   Đưa ảnh vào, tính toán qua các lớp để ra output dự đoán.
4. **Loss Calculation**
   So sánh dự đoán với nhãn thực tế, tính sai số.
5. **Backward Pass**
   Tính đạo hàm (gradient) của Loss theo trọng số.
6. **Optimizer**
   Cập nhật trọng số (W, b) để giảm lỗi.

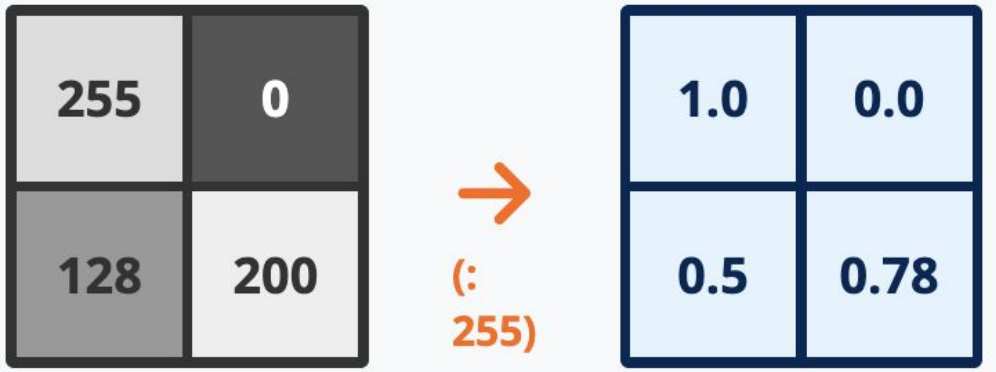


TIỀN XỬ LÝ – CHUẨN HÓA

- **Vấn đề:** Ảnh đầu vào thường có giá trị pixel trong khoảng rộng **[0, 255]**.
- **Giải pháp:** Đưa dữ liệu về khoảng nhỏ hơn, thường là **[0, 1]** hoặc **[-1, 1]**.

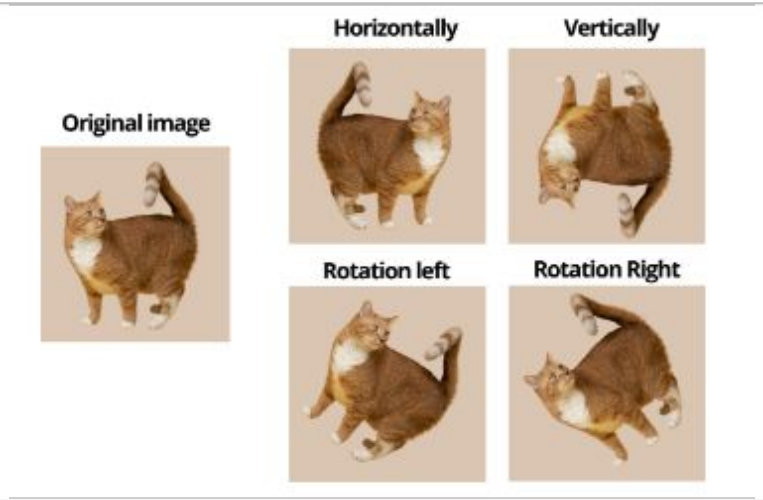
$$x_{\text{norm}} = \frac{x}{255}$$

- **Lợi ích:**
  - Giúp **Gradient Descent** hội tụ nhanh hơn.
  - Tránh hiện tượng **bão hòa** hàm kích hoạt (như Sigmoid/Tanh).



TĂNG CƯỜNG DỮ LIỆU (AUGMENTATION)

- **Vấn đề:** CNN cần rất nhiều dữ liệu để tránh Overfitting.
- **Giải pháp:** Tạo dữ liệu mới từ dữ liệu gốc.
- **Kỹ thuật:** Xoay (Rotation), Lật (Flip), Zoom, Dịch chuyển (Shift).

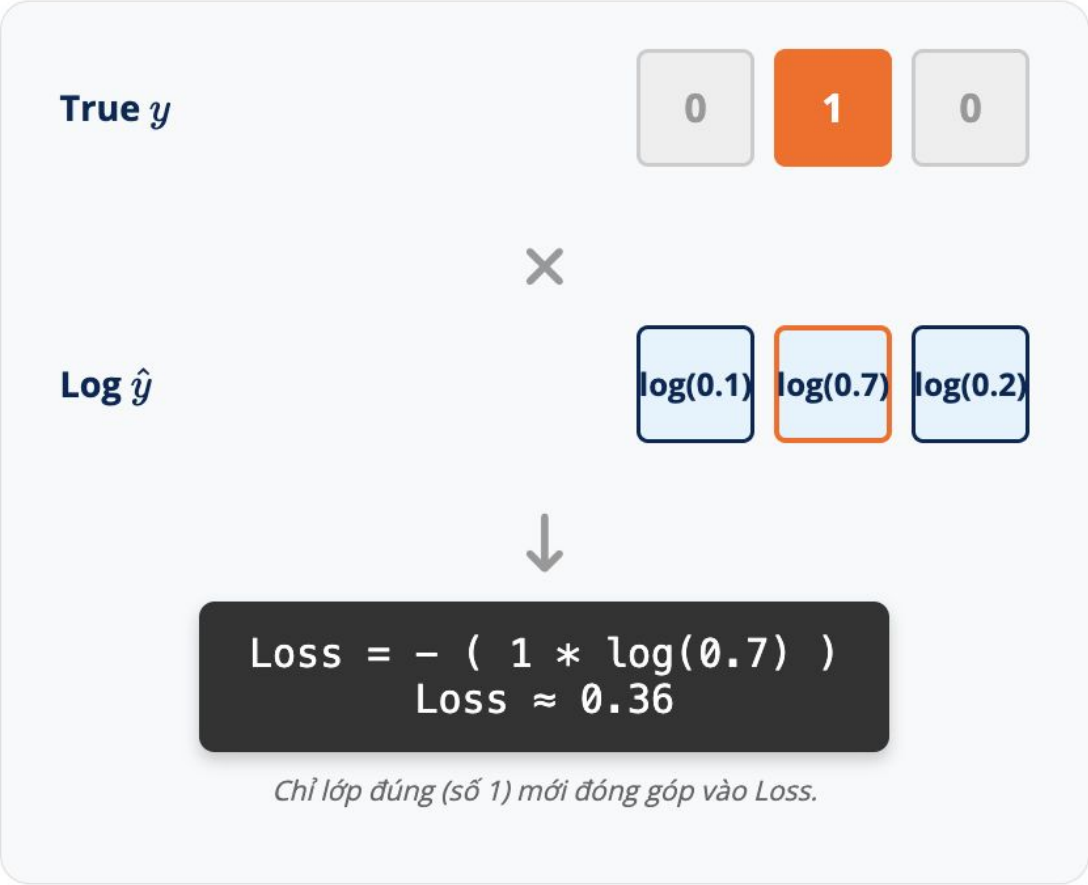


HÀM MẤT MÁT (LOSS FUNCTION)

- Áp dụng cho bài toán **Phân loại đa lớp** (Multi-class Classification).
- Sử dụng hàm **Categorical Cross-Entropy**:

$$J = -\sum_{i=1}^{C} y_i \log(\hat{y}_i)$$

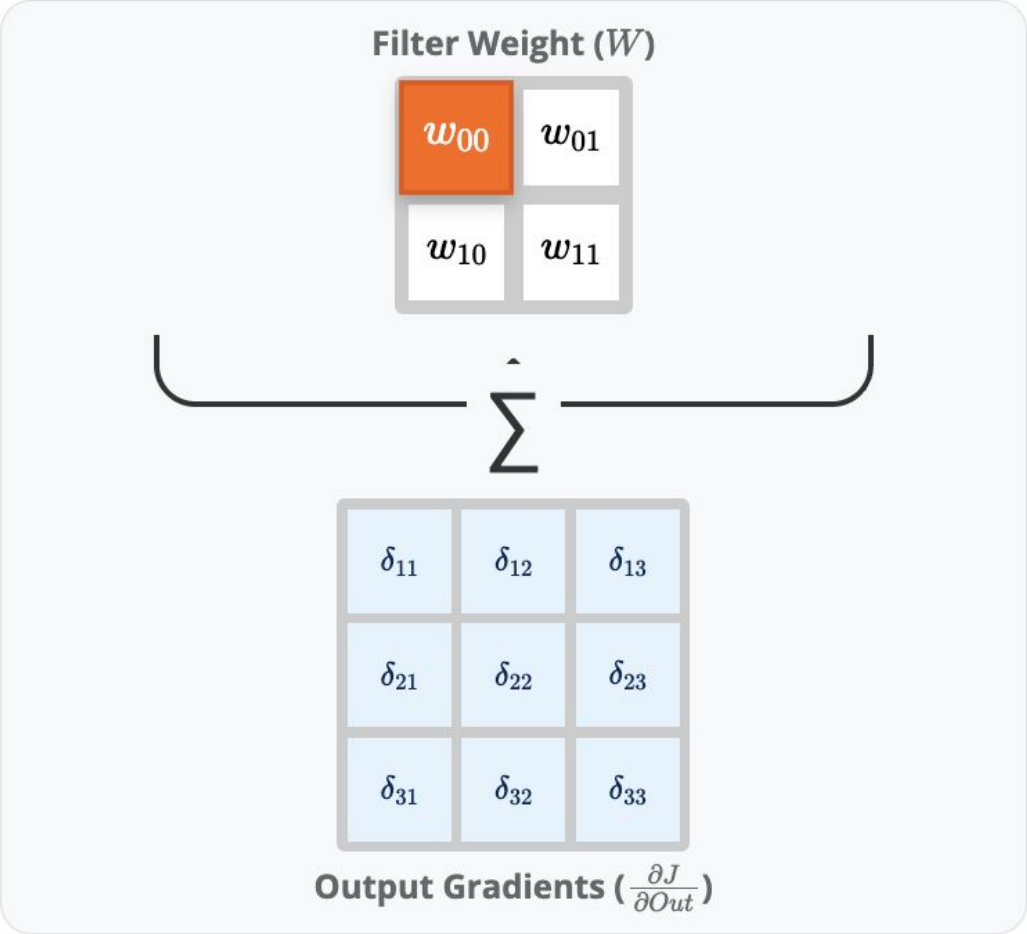
- y_i: Nhãn thực tế (One-hot vector).
  (VD: [0, 1, 0])
- $\hat{y}_i$: Xác suất dự đoán (Output của Softmax).
  (VD: [0.1, 0.7, 0.2])



LAN TRUYỀN NGƯỢC TRONG CNN

- **Phức tạp hơn mạng thường:** Do cơ chế **chia sẻ trọng số** (Parameter Sharing).
- **Nguyên lý:** Gradient của một trọng số trong bộ lọc là **tổng** các gradient từ tất cả các vị trí mà bộ lọc đó đã quét qua trên Feature Map.

$$\frac{\partial J}{\partial W_{filter}} = \sum_{pixels} \frac{\partial J}{\partial Output}$$



TỐI ƯU HÓA (OPTIMIZATION)

1. SGD (Stochastic Gradient Descent)

Phương pháp cập nhật cơ bản theo hướng ngược chiều đạo hàm.

$$W = W - \alpha \nabla J(W)$$

2. Adam (Adaptive Moment Estimation)

- Kết hợp ưu điểm của **Momentum** (đà quán tính) và **RMSProp** (tốc độ học thích ứng).
- **Ưu điểm:** Hội tụ nhanh và ổn định hơn.
- Là lựa chọn **mặc định** hiện nay.



Adam (Cam) đi thẳng đến đích nhanh hơn SGD (Xám).

BÀI TOÁN PHÂN LOẠI ẢNH

- **Mục tiêu:** Gán một nhãn (label) duy nhất cho toàn bộ bức ảnh đầu vào.
- **Input:** Ảnh màu RGB (Tensor 3D).
- **Output:** Nhãn lớp (ví dụ: Chó, Mèo, Xe hơi...).
- **Ví dụ kinh điển:** Bộ dữ liệu **CIFAR-10** (10 lớp: máy bay, ô tô, chim, mèo, hươu, chó, ếch, ngựa, tàu, xe tải).

> ⚠ **Thách thức:**
> Góc chụp, điều kiện ánh sáng, vật thể bị che khuất (occlusion), biến dạng (deformation).



Bộ dữ liệu CIFAR-10

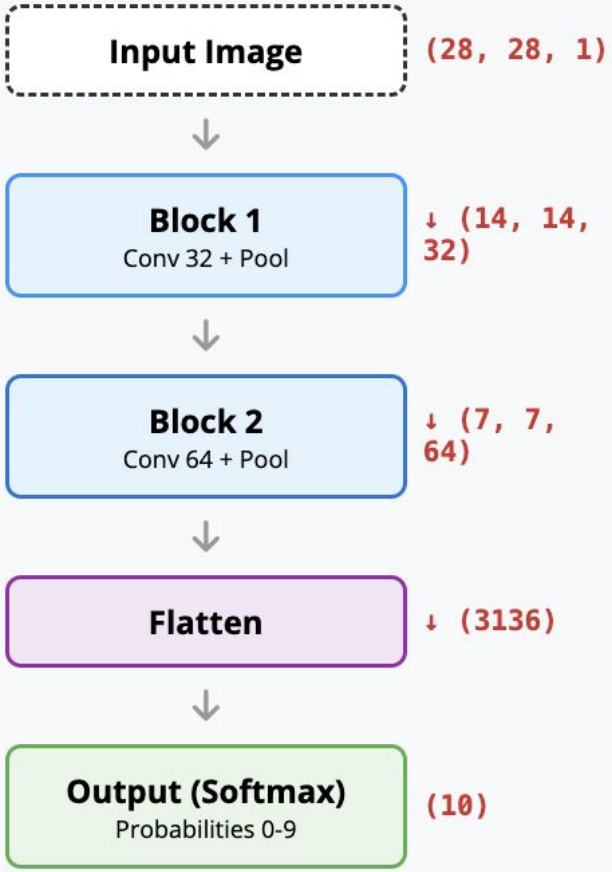
(60,000 ảnh màu 32x32 pixel thuộc 10 lớp)

 → **"Con Mèo"**

CASE STUDY: MNIST VỚI CNN

Input: $28 \times 28 \times 1$ **(Ảnh xám)**

1. **Conv2D** 32 filters, 3x3, ReLU
2. **MaxPooling** 2x2
3. **Conv2D** 64 filters, 3x3, ReLU
4. **MaxPooling** 2x2
5. **Flatten** Duỗi phẳng vector
6. **Dense** 10 units, Softmax



ĐÁNH GIÁ MÔ HÌNH

Accuracy (Độ chính xác)

Tỷ lệ số mẫu dự đoán đúng trên tổng số mẫu kiểm tra. Đơn giản nhưng có thể gây hiểu lầm nếu dữ liệu mất cân bằng.

Confusion Matrix

Bảng phân tích chi tiết các lỗi sai. Giúp nhận biết mô hình đang "nhầm lẫn" giữa các lớp nào (Ví dụ: hay nhìn nhầm số 4 thành số 9).

Top-5 Accuracy

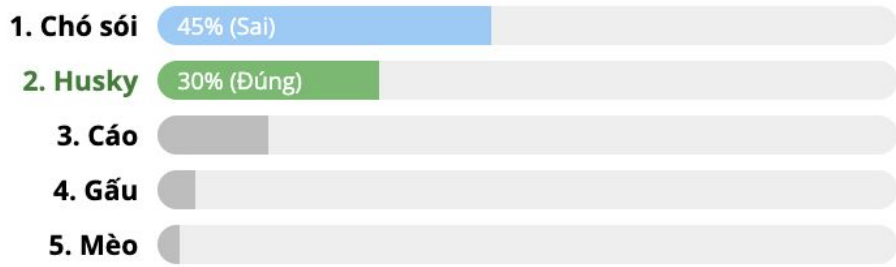
Tỷ lệ nhãn đúng nằm trong **5 dự đoán có xác suất cao nhất**. Thường dùng cho các bài toán khó nhiều lớp (như ImageNet 1000 lớp).

VÍ DỤ CONFUSION MATRIX (MNIST)

	Pred 4	Pred 9
True 4	92	8
True 9	12	88

(Mô hình hay nhầm số 9 thành số 4)

VÍ DỤ TOP-5 (IMAGENET)

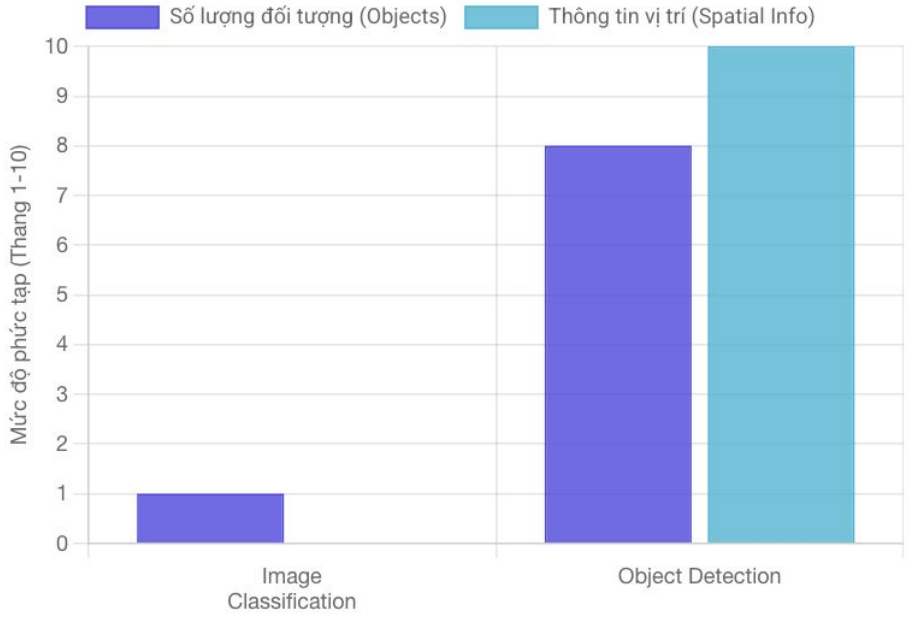


✓ Được tính là ĐÚNG trong Top-5

GIỚI THIỆU PHÁT HIỆN ĐỐI TƯỢNG

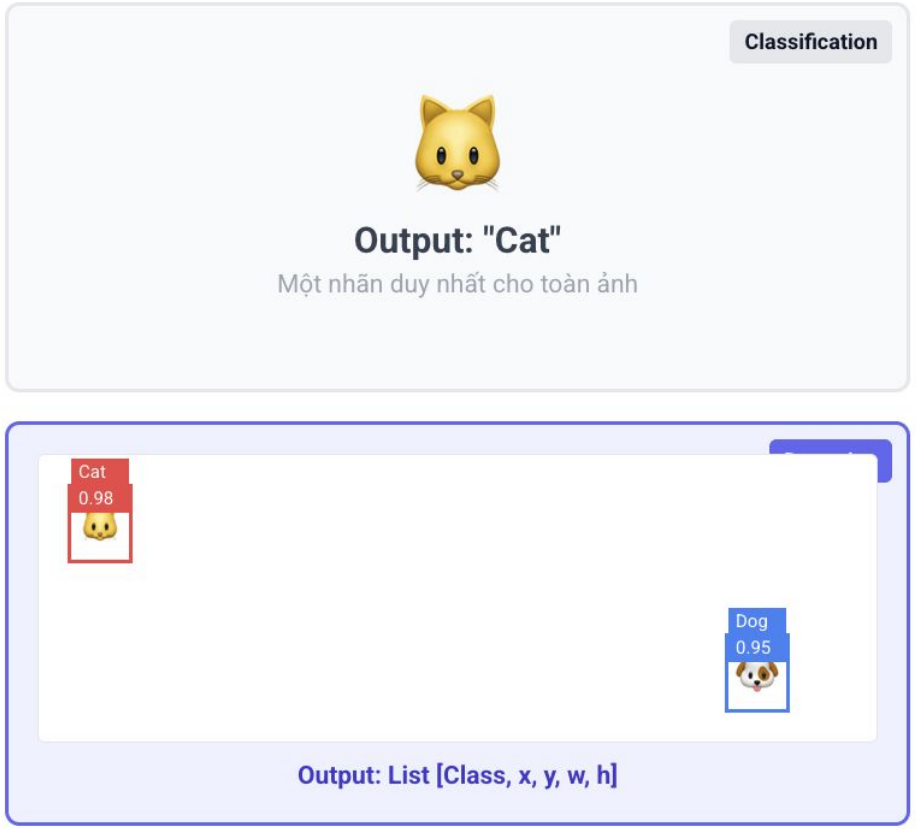
1. Phân Loại vs. Phát Hiện

Sự khác biệt cốt lõi nằm ở câu hỏi mà mô hình phải trả lời. Phân loại chỉ quan tâm đến "Nhãn", trong khi Phát hiện cần cả "Nhãn" và "Hộp bao quanh" (Bounding Box).



Biểu đồ so sánh độ phức tạp thông tin đầu ra giữa hai bài toán.

Minh Họa Trực Quan



GIỚI THIỆU PHÁT HIỆN ĐỐI TƯỢNG

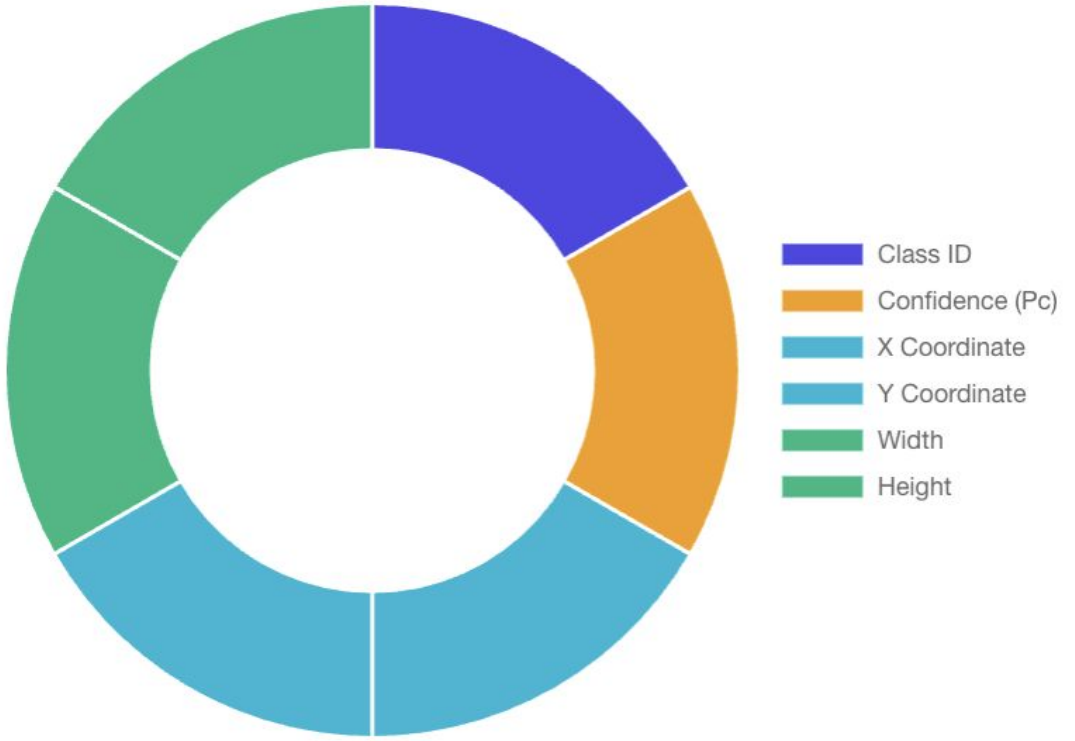
2. Cấu Trúc Đầu Ra (Output)

Mỗi đối tượng phát hiện được biểu diễn bằng một vector chứa các thông tin định danh và định vị. Công thức tổng quát: `Output = (Class, x, y, w, h, Pc)`

ID — **Class (Nhãn lớp)**
Xác định vật thể là gì (Người, Xe, Chó...).

Box — **Bounding Box (x, y, w, h)**
Vị trí (tâm hoặc góc) và kích thước khung hình chữ nhật.

% — **Confidence Score (Pc)**
Độ tin cậy (xác suất) vật thể tồn tại.



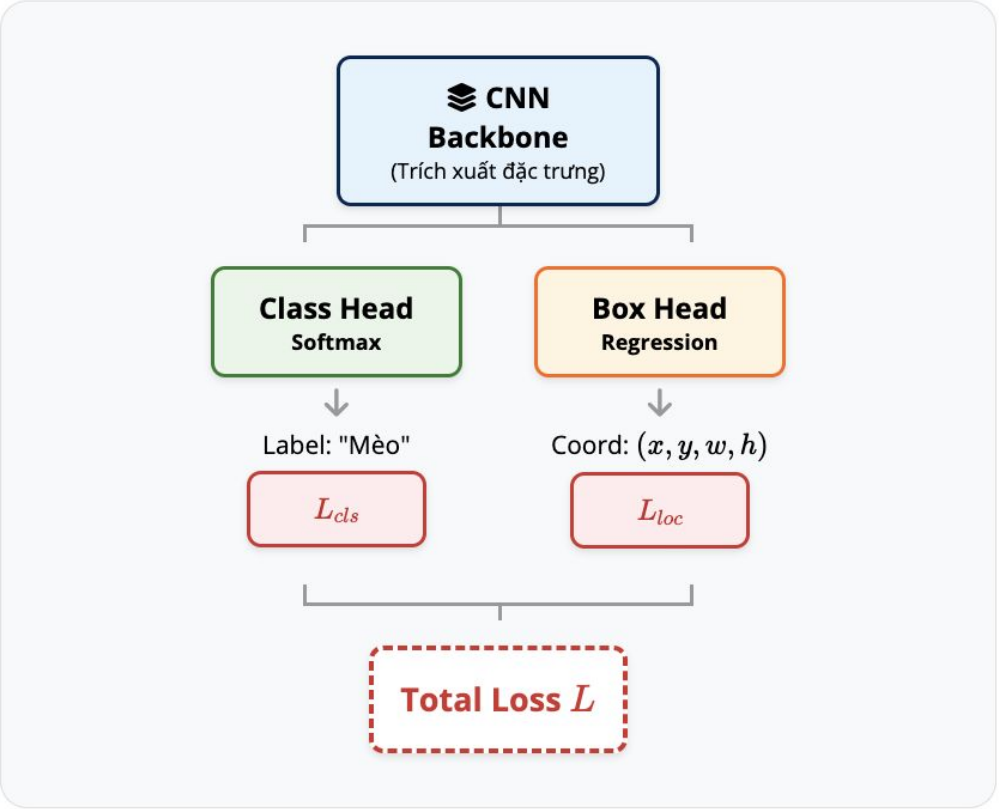
Các thành phần cấu tạo nên một kết quả phát hiện

BOUNDING BOX REGRESSION

- Ngoài nhánh phân loại (Classification), mạng có thêm nhánh **Hồi quy (Regression)** để dự đoán tọa độ hộp.
- **Hàm Loss tổng hợp** (Multi-task Loss):

$$L = L_{cls} + \lambda L_{loc}$$

- L_{cls}: Loss phân loại (Cross-Entropy).
- L_{loc}: Loss vị trí tọa độ.
- λ: Hệ số cân bằng giữa 2 nhiệm vụ.
- L_{loc} thường dùng **MSE** hoặc **Smooth L1 Loss**.

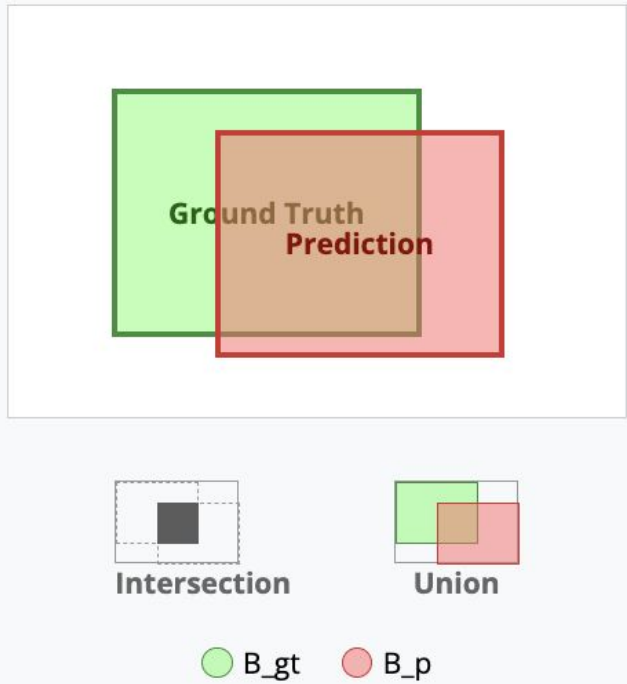


CHỈ SỐ IOU (INTERSECTION OVER UNION)

- **Định nghĩa:** Độ đo đánh giá mức độ trùng khớp giữa Bounding Box dự đoán (B_p) và Bounding Box thực tế (B_{gt}).

$$\text{IoU} = \frac{\text{Area}(B_p \cap B_{\text{gt}})}{\text{Area}(B_p \cup B_{\text{gt}})}$$

IoU > 0.5 thường được coi là phát hiện ĐÚNG (True Positive).



CÁC THUẬT TOÁN DETECTION TIÊU BIỂU

Two-stage (2 Giai đoạn)

- *R-CNN, Fast R-CNN, Faster R-CNN*

Cơ chế:

Proposal → **Classify**

- **Chính xác cao** (High Accuracy)
- **Chậm** (Low Speed / High Latency)

One-stage (1 Giai đoạn)

- *YOLO (You Only Look Once), SSD*

Cơ chế:

Direct Prediction (Grid)

- **Rất nhanh** (Real-time Speed)
- Kém chính xác hơn với **vật thể nhỏ**

SO SÁNH R-CNN VÀ YOLO

R-CNN



- **Cơ chế:** Trích xuất hàng nghìn vùng đề xuất (Region Proposals) từ ảnh.
- **Vấn đề:** Phải chạy mạng CNN độc lập trên **từng vùng** một cách tuần tự.
- Kết quả: **Rất Chậm**.

YOLO



- **Cơ chế:** Chia ảnh thành lưới $S \times S$. Xem toàn bộ ảnh một lần duy nhất (You Only Look Once).
- **Ưu điểm:** Dự đoán tọa độ và lớp cho tất cả các ô trong lưới **cùng một lúc** (song song).
- Kết quả: **Rất Nhanh (Real-time)**.

TỔNG KẾT BÀI HỌC

Những khái niệm cốt lõi về Mạng Nơ-ron Tích chập (CNN) đứng sau công nghệ phát hiện đối tượng.

1 Conv Layer (Tích chập)

Trích xuất đặc trưng (cạnh, góc, texture) bằng các bộ lọc (kernels) chia sẻ trọng số.

2 Pooling Layer (Gộp)

Giảm chiều dữ liệu để giảm tải tính toán nhưng vẫn giữ lại các đặc trưng nổi bật nhất (Max Pooling).

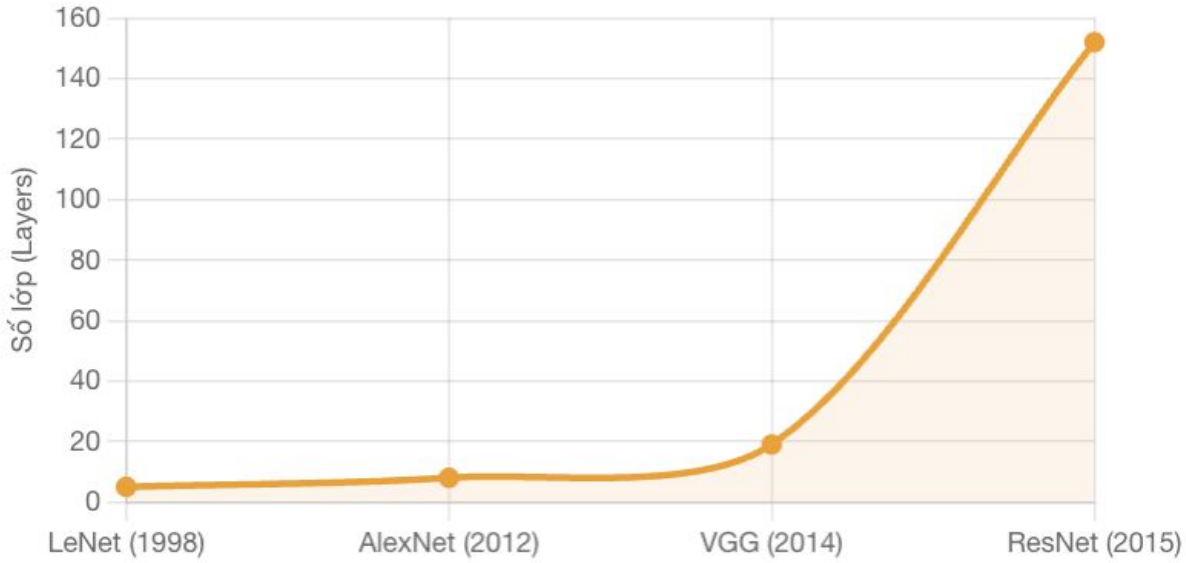
3. CÔNG THỨC OUTPUT SIZE

$$Output = \lfloor (W - F + 2P) / S \rfloor + 1$$

(W: Input, F: Filter, P: Padding, S: Stride)

4. Xu hướng Kiến trúc & 5. Ứng dụng

Mạng ngày càng sâu hơn (Deep Learning) để trích xuất đặc trưng tốt hơn.



CÂU HỎI & BÀI TẬP

- Tính kích thước đầu ra nếu Input 227x227, Filter 11x11, Stride 4, Padding 0? (AlexNet).
- Tại sao CNN lại tốt hơn mạng Fully Connected cho xử lý ảnh?
- **Tìm hiểu thêm:** Mạng ResNet giải quyết vấn đề gì khi tăng độ sâu?