BÀI 1

Khám phá tri thức từ dữ liệu

TỔNG QUAN VỀ KDD VÀ DATA MINING

DỮ LIỆU LÀ ĐỊA HÌNH

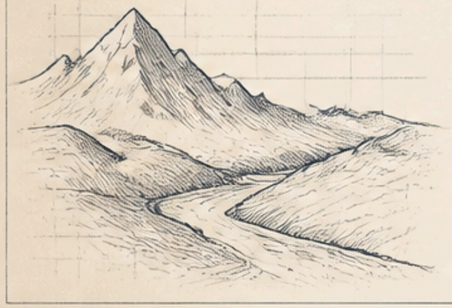

01 THU THẬP DỮ LIỆU

02 TIỀN XỬ LÝ

03 KHAI THÁC

04 ĐÁNH GIÁ

05 DIỄN GIẢI TRI THỨC

TỪ DỮ LIỆU ĐẾN TRI THỨC

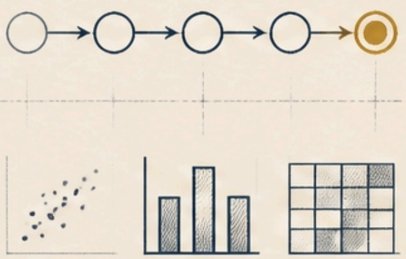

KIỂU DỮ LIỆU

BẢNG BIỂU · VĂN BẢN · HÌNH ẢNH · ÂM THANH · ĐỒ THỊ · ...

ỨNG DỤNG

- KINH DOANH
- TÀI CHÍNH
- Y TẾ
- MẠNG XÃ HỘI
- GIÁO DỤC
- KHOA HỌC

MỤC TIÊU BÀI HỌC

Sáu điều học viên làm được sau bài học

1. Giải thích khái niệm Data Mining và Knowledge Discovery.
2. Phân biệt Data Mining với KDD, Statistics và Data Science.
3. Mô tả quy trình KDD.
4. Nhận diện các loại dữ liệu thường gặp.
5. Nhận diện các bài toán Data Mining cơ bản.
6. Xác định một bài toán thực tế có thể giải quyết bằng Data Mining.

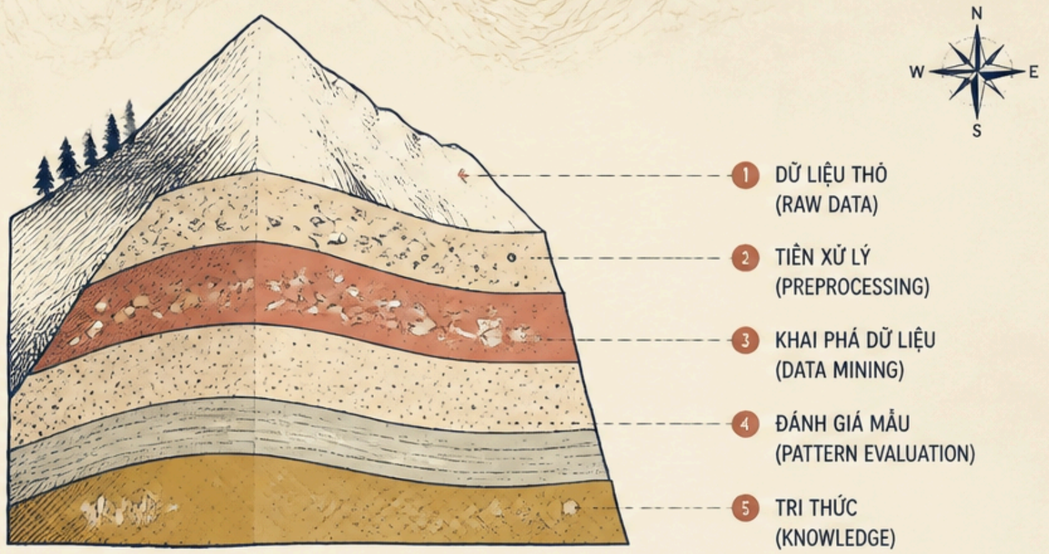

LA BÀN DỮ LIỆU

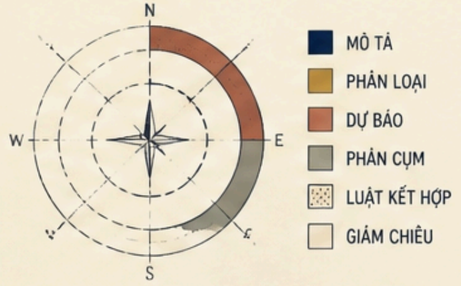

TỌA ĐỘ DỮ LIỆU

LOẠI DỮ LIỆU	ĐỊNH TÍNH	ĐỊNH LƯỢNG	THỜI GIAN	KHÔNG GIAN	VĂN BẢN
CẤU TRÚC					
VÍ DỤ	Giới tính, Loại SP	Tuổi, Thu nhập, Nhiệt độ	Doanh số theo ngày	Vị trí cửa hàng, Tọa độ GPS	Bài viết, Đánh giá

QUY TRÌNH KDD

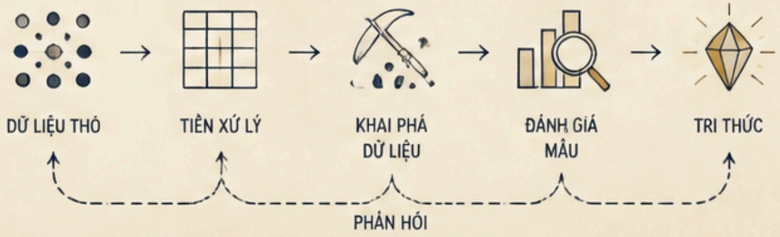

ĐỊA HÌNH DỮ LIỆU

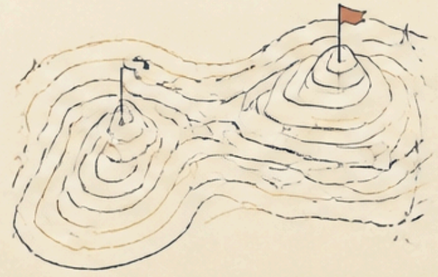

Sáu chủ đề định hình bài học

Nội dung chính

21°02'N
106°51'E

01 Tại sao cần Data Mining?

02 Data Mining là gì?

03 Knowledge Discovery là gì?

04 Quy trình KDD

05 Các loại dữ liệu và bài toán

06 Từ dữ liệu đến quyết định

10°46'N
106°40"E

Thế giới đang tạo ra dữ liệu nhiều chưa từng thấy

21° 01’ N
105° 51’ E

1. Chi phí lưu trữ ngày càng thấp
2. Truyền dữ liệu giữa các hệ thống nhanh hơn bao giờ hết
3. Smartphone và sensor thu thập dữ liệu khổng lồ
4. Hệ thống số ghi nhận hoạt động liên tục

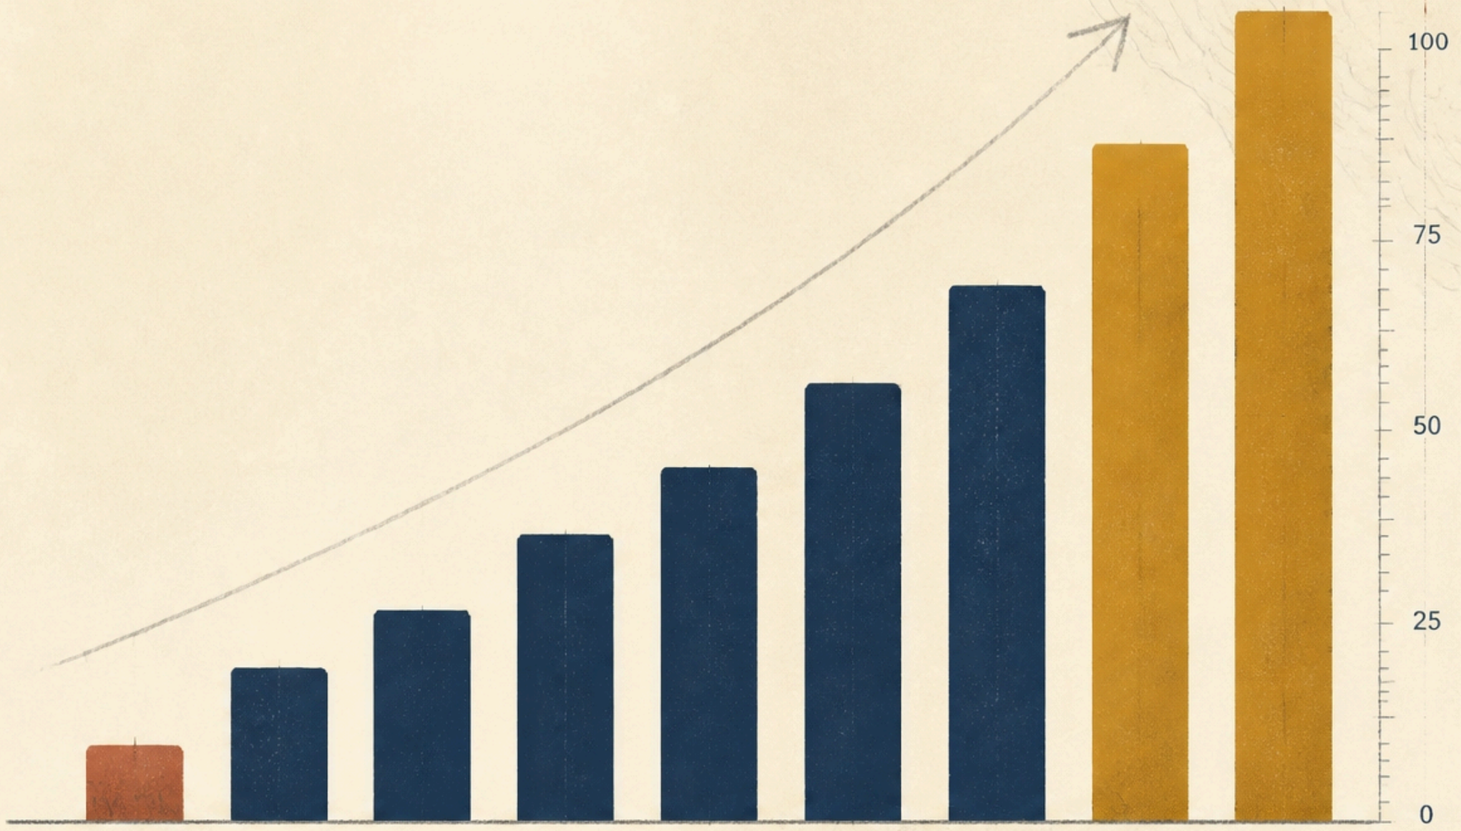

Câu hỏi không còn là ‘có dữ liệu hay không’ — mà là khai thác như thế nào.

Dữ liệu đến từ đâu?

1

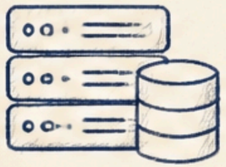

Hệ thống doanh nghiệp

2

Giao dịch ngân hàng

3

Thương mại điện tử

4

Smartphone

5

IoT và sensor

6

Phương tiện giao thông

7

Mạng xã hội

8

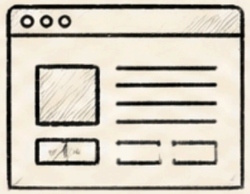

Website

9

Camera

10

Thiết bị y tế

Dữ liệu được tạo ra gần như trong mọi hoạt động của xã hội.

Một cá nhân — một doanh nghiệp, nhiều luồng dữ liệu

Từ cơ thể con người

- Chuyển động
- Nhịp tim
- Huyết áp
- Tín hiệu não
- Chuyển động mắt
- Vị trí địa lý
- Hành vi thiết bị

Từ quầy thu ngân đến chiến dịch

Ngân hàng (Banking)

Thu nhập · Chi tiêu · Giao dịch · Hành vi tài chính

Bán lẻ (Retail)

Sản phẩm · Review · Hành vi khách hàng · Marketing campaign · Khảo sát

Làm thế nào biến các dòng dữ liệu này thành tri thức kinh doanh?

Nhiều dữ liệu không có nghĩa là nhiều tri thức

Dữ liệu không tự giải thích chính nó

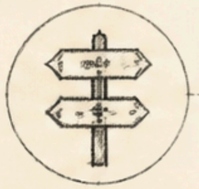

Dữ liệu không tự đưa ra quyết định

Data rich but information poor

Phân tích thủ công dữ liệu rất lớn gần như bất khả thi

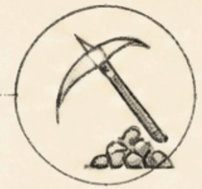

Thông tin quan trọng có thể bị bỏ sót

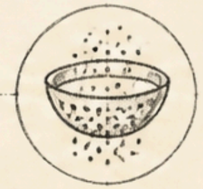

Tình trạng này được gọi là 'data rich but information poor'.

Mục tiêu cuối cùng là quyết định, không phải dữ liệu

Data Mining và Knowledge Discovery thực hiện chuỗi chuyển đổi này.

Data Mining tìm những mẫu ẩn mà con người chưa thấy

Data Mining — Khai thác dữ liệu: tập hợp các kỹ thuật tự động phát hiện những pattern thú vị trong dữ liệu nhằm khám phá tri thức.

01 **mối quan hệ**	02 **xu hướng** 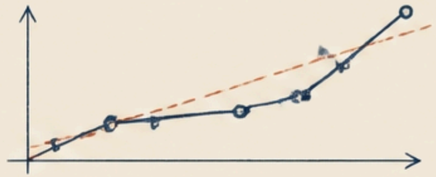
04 **quy luật** 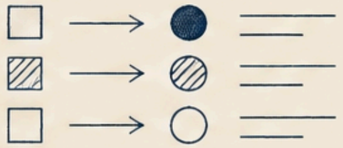	05 **bất thường** 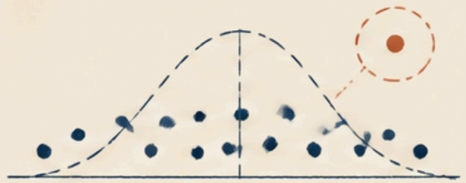

03 **nhóm**
06 **cấu trúc tiềm ẩn**

Một pattern có thể là quan hệ, xu hướng, nhóm, quy luật, bất thường, hoặc cấu trúc tiềm ẩn.

Hiểu quá khứ — Dự đoán tương lai

UNDERSTAND THE PAST

1. Điều gì đã xảy ra?
2. Vì sao nó xảy ra?
3. Những yếu tố nào liên quan?

PREDICT THE FUTURE

1. Điều gì có thể xảy ra tiếp theo?
2. Khách hàng có trả nợ không?
3. Một sự kiện bất thường có xảy ra không?

Database trả lời câu hỏi đã biết — Data Mining khám phá điều chưa biết

01 DATABASE

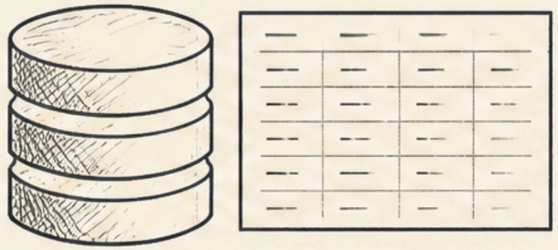

Trả lời câu hỏi đã biết trước

Ví dụ: Tìm tất cả bệnh nhân nam trên 20 tuổi.

02 DATA MINING

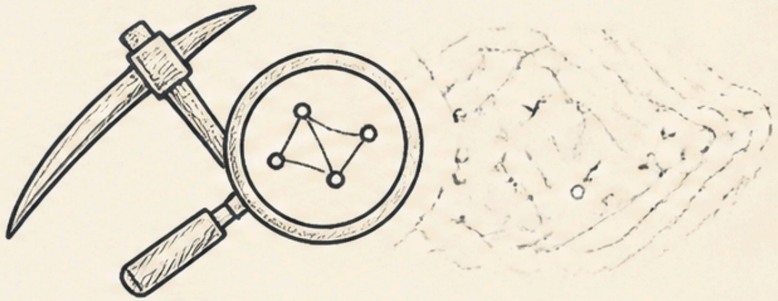

Khám phá những quan hệ mà người sử dụng chưa biết

Ví dụ: Nhóm bệnh nhân trẻ có khả năng đáp ứng tốt nhất với phương pháp điều trị nào?

Database → Retrieve known information | Data Mining → Discover unknown knowledge

Data Mining chỉ là một bước trong hành trình dài hơn

Trước Data Mining: thu thập, làm sạch, tích hợp, lựa chọn, biến đổi — **Sau Data Mining:** đánh giá, diễn giải, trực quan hóa, sử dụng tri thức.

Knowledge Discovery — ba giai đoạn lớn

1 PREPARING DATA
chuẩn bị dữ liệu

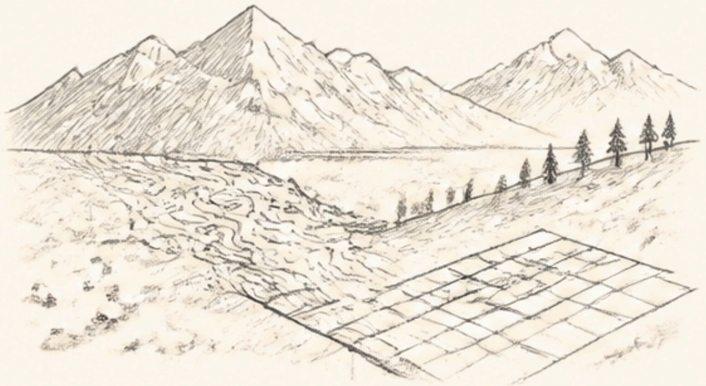

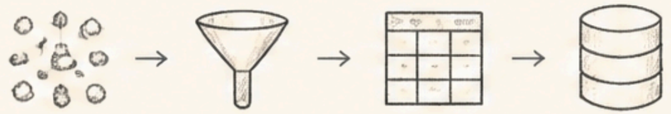

2 DISCOVERING PATTERNS
khám phá mẫu ẩn

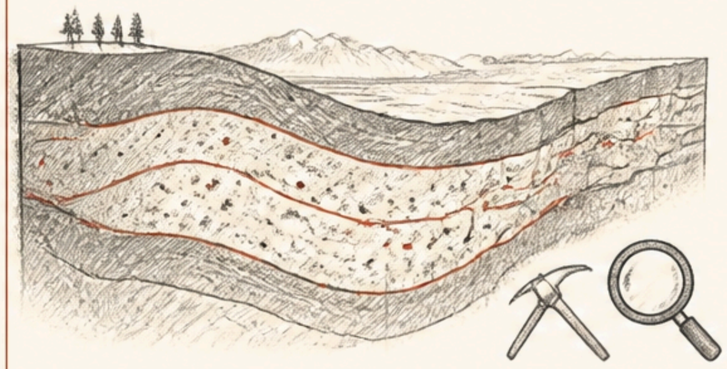

3 EVALUATING & USING KNOWLEDGE
đánh giá và sử dụng tri thức

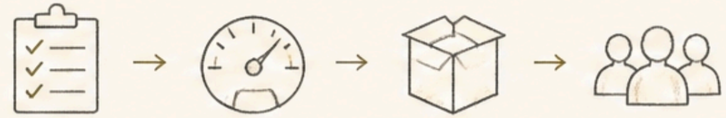

Biến dữ liệu ban đầu thành những pattern và tri thức có giá trị — gồm ba giai đoạn lớn.

Bảy bước từ dữ liệu thô đến tri thức

Quy trình KDD

Clean → Integrate → Select → Transform → Mine → Evaluate → Visualize

Hai bước đầu tiên — Làm sạch và Tích hợp dữ liệu

Bước 1 + 2

BƯỚC 1 — DATA CLEANING

Nâng cao chất lượng dữ liệu

- Missing values
- Dữ liệu nhiễu
- Giá trị không hợp lệ
- Trùng lặp, không thống nhất

Ví dụ

Age = 25	/	"25 years"	/	null	/	~~-10~~

BƯỚC 2 — DATA INTEGRATION

Kết hợp dữ liệu từ nhiều nguồn

NGUỒN DỮ LIỆU

- Database
- Excel
- Website
- Sensor
- API
- Log
- Transaction system

THÁCH THỨC

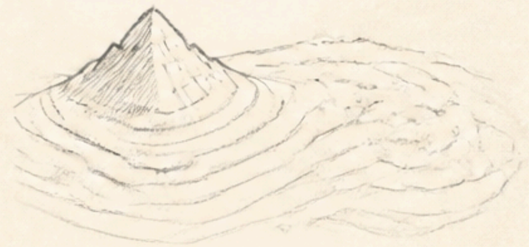

khác schema, khác định dạng, trùng lập, cùng đối tượng nhưng khác định danh

Hai bước tiếp theo — Chọn lọc và Biến đổi dữ liệu

21°02'N, 105°50'E

BƯỚC 3 — DATA SELECTION

Chọn dữ liệu phù hợp với mục tiêu

CÓ THỂ CẦN

→ thời gian sử dụng, số lần giao dịch, khiếu nại, mức chi tiêu

CÓ THỂ KHÔNG CẦN

→ ID nội bộ không mang ý nghĩa dự báo

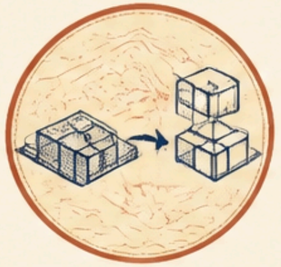

BƯỚC 4 — DATA TRANSFORMATION

Chuyển dữ liệu sang dang phù hợp với thuật toán

1. Chuẩn hóa
2. Mã hóa categorical
3. Tổng hợp
4. Rời rạc hóa
5. Tạo thuộc tính mới
6. Giảm chiều dữ liệu

Ví dụ: Ngày sinh → Tuổi | Purchase history → Tổng chi tiêu

Năm bài toán cốt lõi của Data Mining

1 CLASSIFICATION

gán nhãn lớp

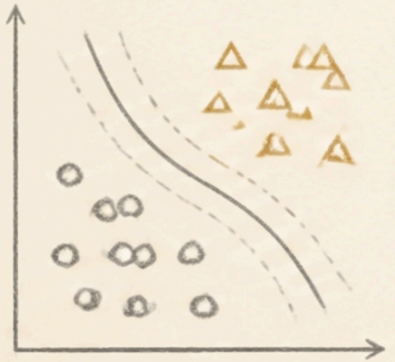

2 CLUSTERING

nhóm đối tượng tương tự

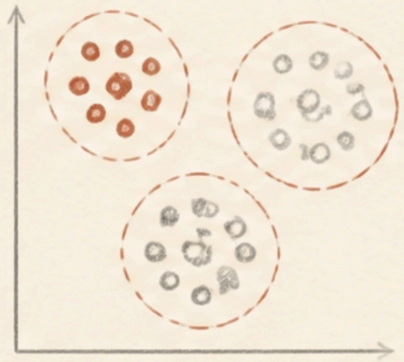

3 ASSOCIATION

luật đi kèm

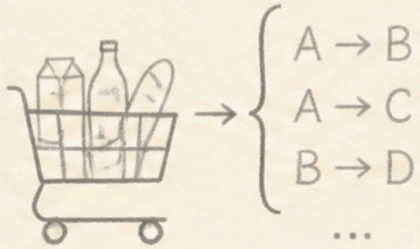

4 ANOMALY DETECTION

phát hiện bất thường

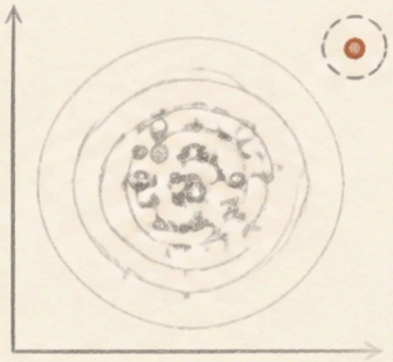

5 TREND / SEQUENTIAL PATTERN

xu hướng và chuỗi

Không có một thuật toán phù hợp cho mọi bài toán — chọn đúng bài toán là một nửa công việc.

Hai bước cuối — Đánh giá và Trực quan hóa

Bước 6 + 7

6 BƯỚC 6 — PATTERN EVALUATION

Lọc ra các pattern có giá trị

Một thuật toán có thể tìm ra hàng nghìn hoặc hàng triệu patterns — không phải cái nào cũng quan trọng, hữu ích, hoặc đáng để xem xét

7 BƯỚC 7 — VISUALIZATION & KNOWLEDGE

Đưa tri thức vào hành động

- **Diễn giải**
- **Trực quan hóa**
- **Trình bày cho người ra quyết định**
- **Liên kết tri thức miền**

Một mô hình tốt nhưng không thể hiểu hoặc sử dụng cũng có giá trị thực tế hạn chế.

Data Mining nằm ở giao điểm của nhiều lĩnh vực

SO SÁNH & BỐI CẢNH LIÊN NGÀNH

LAT	21° 01′ 38″ N
LON	105° 51′ 27″ E

0 25 50 75 100 km

Data Science

Phạm vi rộng hơn — kết hợp Statistics, Data Mining, Machine Learning, Programming, Data Engineering, Visualization, Domain Knowledge

Statistics

Descriptive statistics — mô tả dữ liệu; Inferential statistics — kiểm định giả thuyết và suy luận

Data Mining

Tự động phát hiện các tính chất chưa biết trước — pattern, trend, anomaly, correlation; có nhiều vùng giao với Statistics

ĐỘ CAO (m)
1500
1000
500
250
0

Database Systems • Algorithms • Computer Science • Machine Learning • Visualization • Image Processing • Signal Processing

Từ bài toán thực tế đến quyết định — pipeline của cả học phần

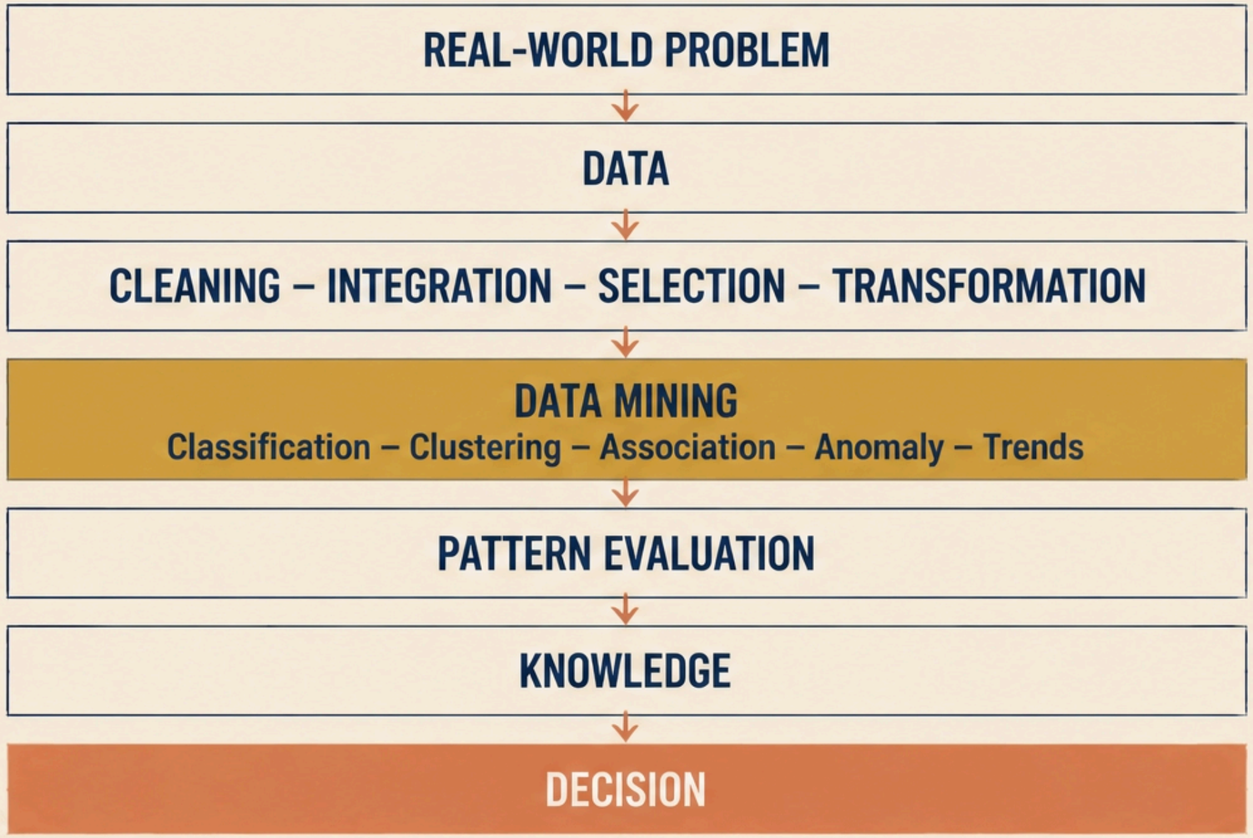

CÂU HỎI THẢO LUẬN

1. Dữ liệu đến từ đâu?
2. Đối tượng cần phân tích là gì?
3. Tri thức cần khám phá là gì?
4. Đây là Classification, Clustering, Association hay Anomaly Detection?
5. Kết quả sẽ hỗ trợ quyết định gì?

Data Mining không đơn thuần là chạy thuật toán — đó là một thành phần của quá trình biến dữ liệu thành tri thức có giá trị để hiểu vấn đề và hỗ trợ ra quyết định.