BÀI 2

Dữ liệu, Khám phá dữ liệu và Tiền xử lý

Khám phá tri thức và khai thác dữ liệu — Knowledge Discovery and Data Mining

Mục tiêu bài học

Sau Bài 2, học viên có thể:

1. Xác định data object, attribute, feature và target

2. Phân biệt các loại thuộc tính và loại dữ liệu

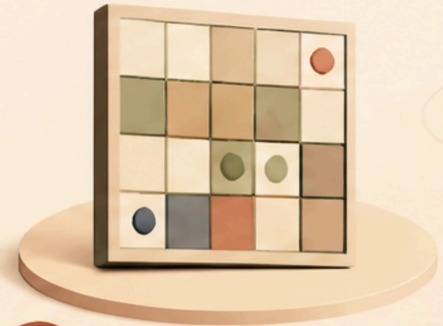

3. Thực hiện Exploratory Data Analysis – EDA

4. Sử dụng độ đo similarity/distance phù hợp

5. Nhận diện các vấn đề chất lượng dữ liệu

6. Thực hiện cleaning, integration, selection, transformation và reduction

Bài 2 nằm ở đâu trong KDD?

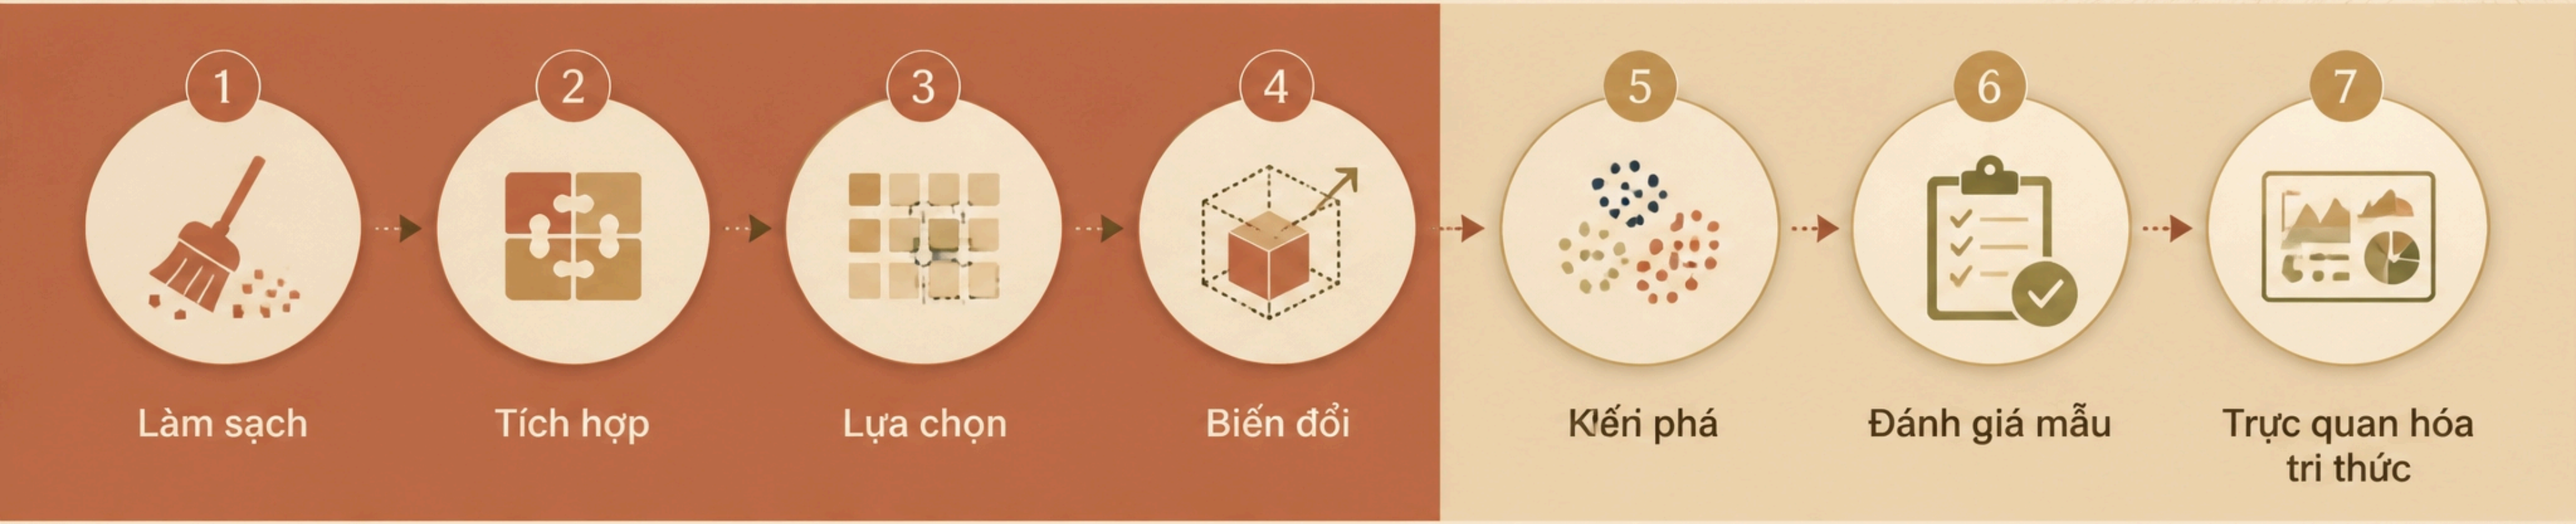

Bốn bước đầu tiên liên quan trực tiếp đến chuẩn bị dữ liệu

Trước khi hỏi dùng thuật toán nào,
hãy hỏi dữ liệu của chúng ta thực sự là gì.

Ba câu hỏi trước khi khai phá dữ liệu

Sai ở giai đoạn này có thể khiến
model tốt về kỹ thuật nhưng kết luận sai về khoa học.

Data Object — đối tượng dữ liệu

ĐỒNG NGHĨA

object
instance
record
observation
sample

THẺ MẪU · DATA OBJECT

01

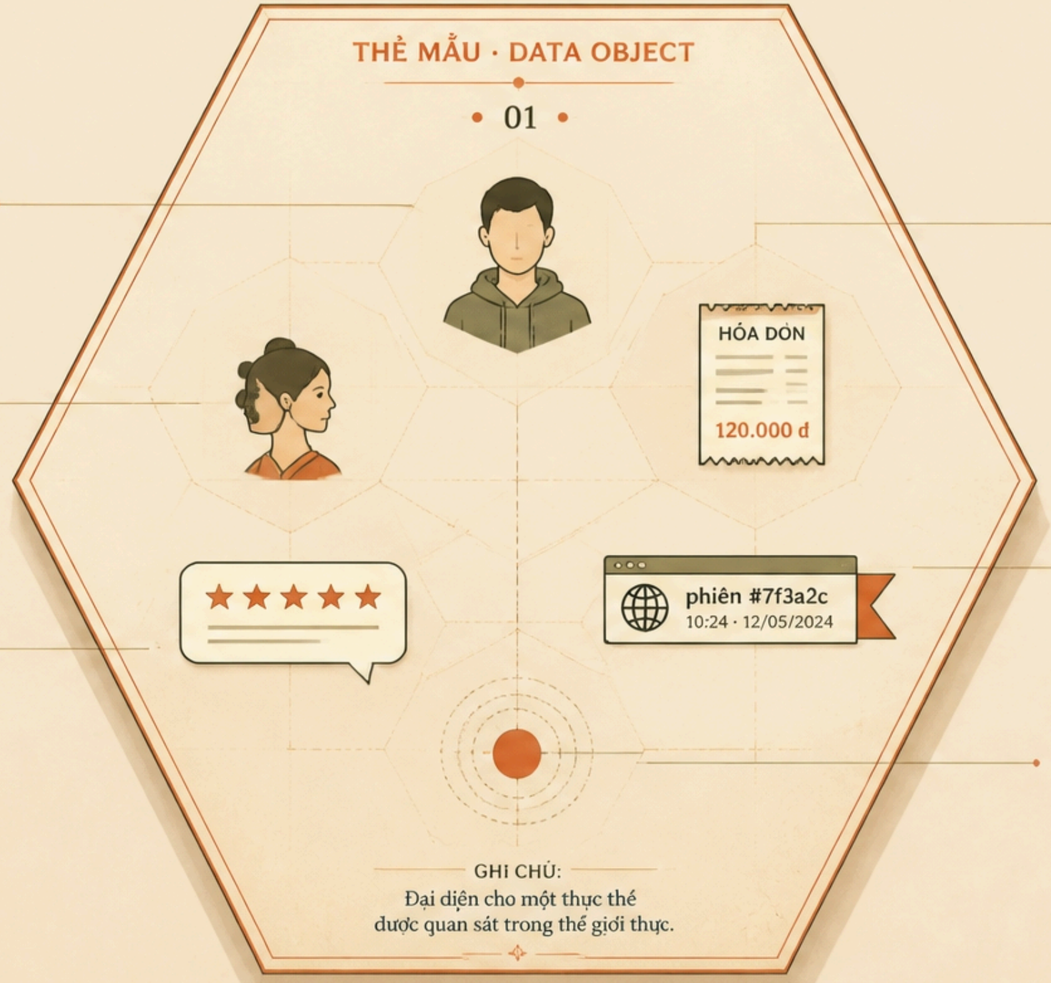

Data object là đơn vị mà chúng ta quan sát và muốn phân tích.

Attribute — thuộc tính

- **Attribute / Feature**
  = đặc điểm mô tả một data object.

- **Object**
  = cái chúng ta phân tích.

- **Feature**
  = thông tin dùng để mô tả object.

Feature và Target

- Điểm danh
- Hoạt động trên LMS
- Hoàn thành bài tập
- Điểm thi giữa kỳ

X

Features X

Target y

Ví dụ: Pass / Fail

Cần xác định rõ target trước khi thiết kế preprocessing.

Unit of analysis — đơn vị phân tích

Một dòng dữ liệu đại diện cho cái gì?

- Người dùng
- Giao dịch
- Ngày
- Phiên (session)
- Sản phẩm
- Cặp người dùng–sản phẩm

100 records

≠

100 students

⚠ Nhầm unit of analysis có thể dẫn tới thiết kế train/test sai.

Các loại thuộc tính

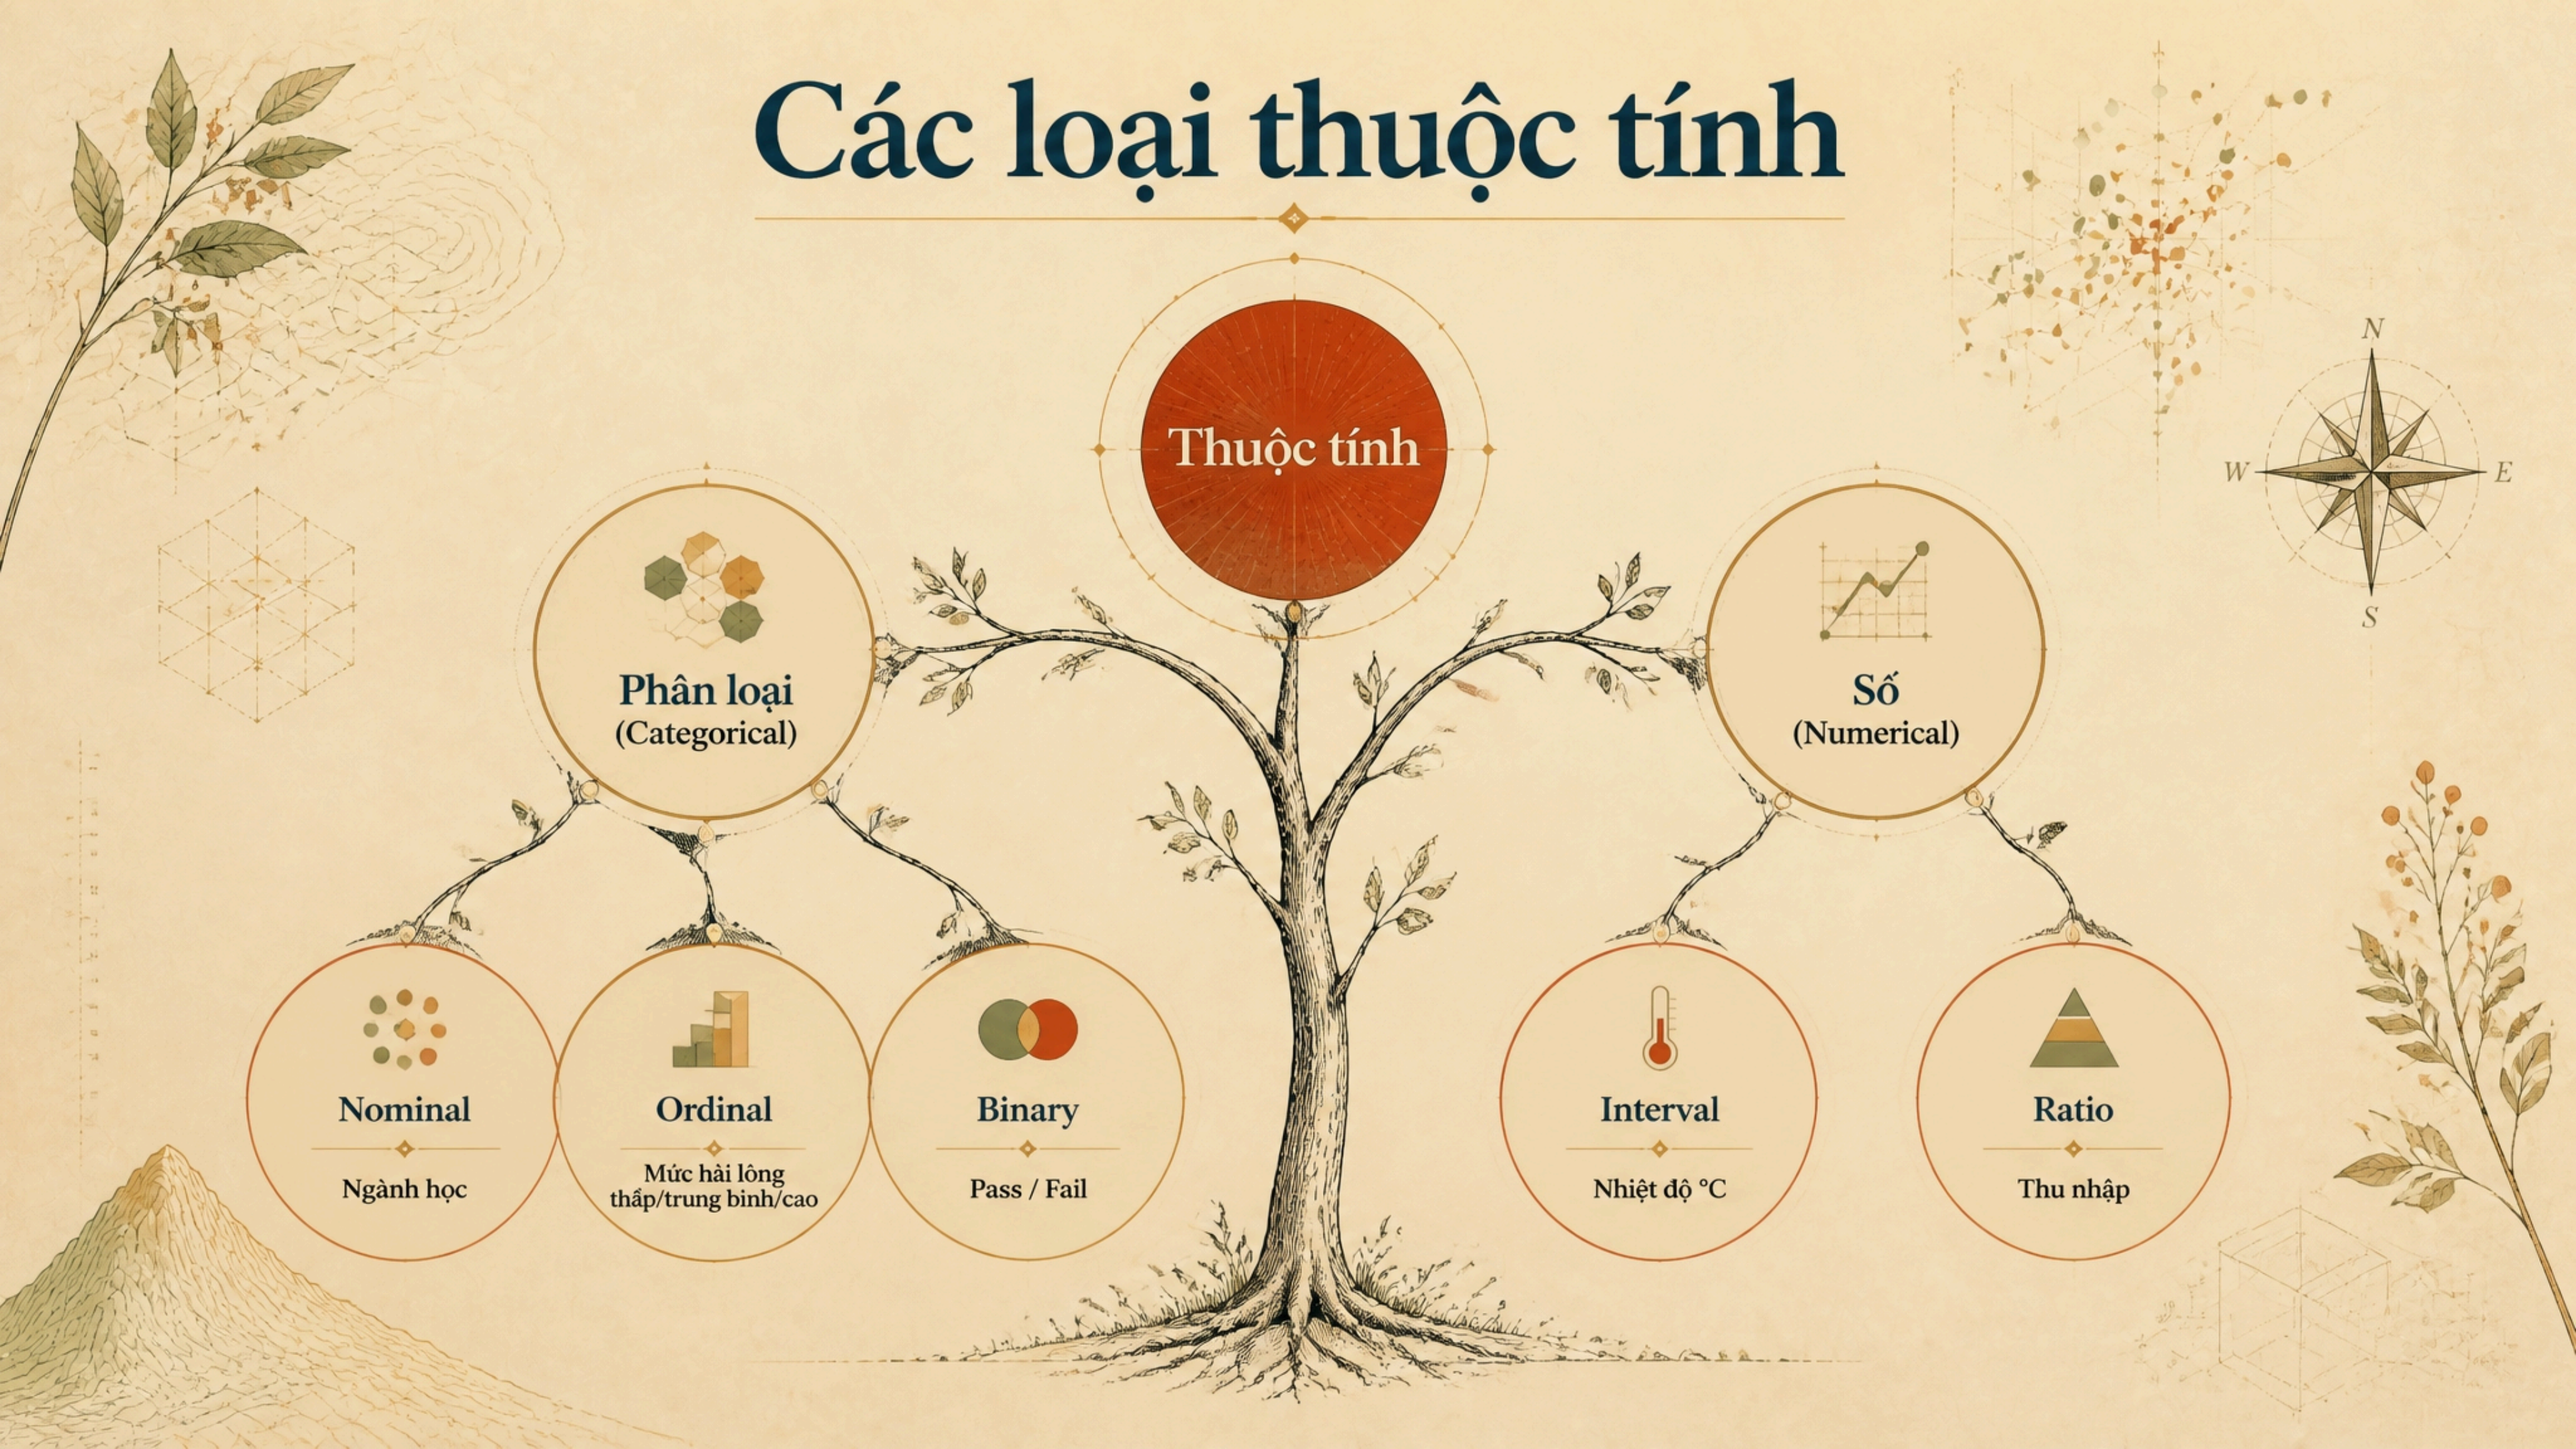

Nominal vs Ordinal

NOMINAL

Phân loại không có thứ tự

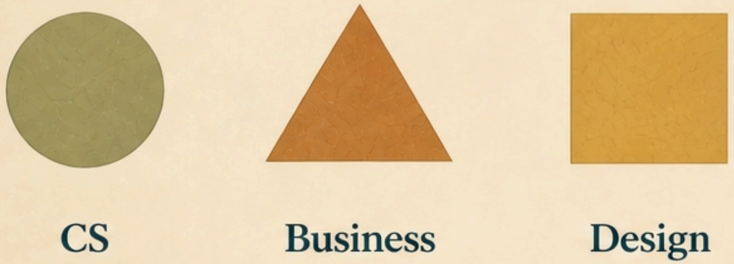

CS Business Design

Không thể nói CS > Business

ORDINAL

Có thứ tự, khoảng cách không xác định

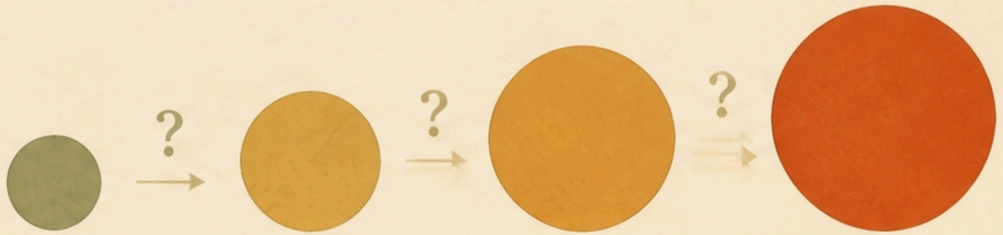

Poor Fair Good Excellent

Nominal dùng để phân loại các nhóm không có thứ tự.
Ordinal thể hiện thứ tự giữa các mức, nhưng không thể hiện khoảng cách cụ thể giữa chúng.

Đừng nhầm "số" với "dữ liệu định lượng"

1	2	3
= IT	= Business	= Tourism

Các giá trị 1, 2, 3 chỉ là mã category.
Không có nghĩa Tourism > Business > IT.

Satisfaction = 1..5

ordinal

Khoảng cách 1→2 chưa chắc giống 4→5

Data Mining làm việc với nhiều loại dữ liệu

Không chỉ có bảng Excel

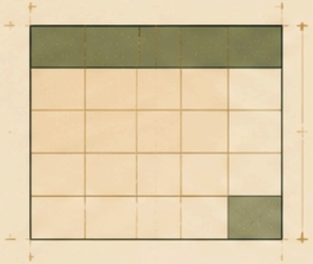

Quan hệ

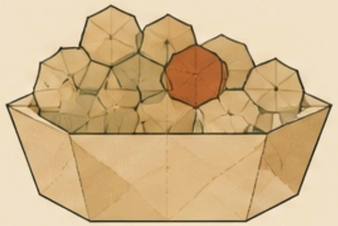

Giao dịch

Chuỗi

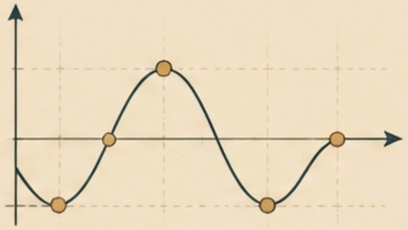

Chuỗi thời gian

Không gian

Văn bản

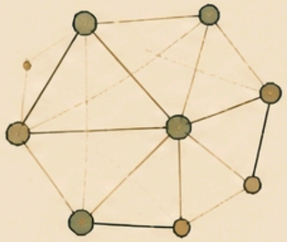

Web

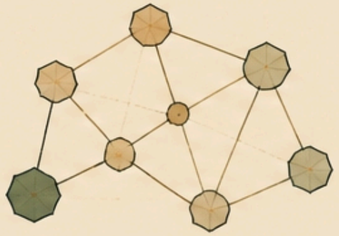

Đồ thị

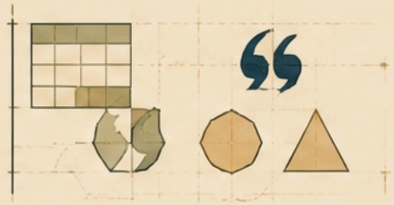

Hỗn hợp

Dòng

Việc nhận diện loại dữ liệu quyết định cách biểu diễn và thuật toán.

Relational data — dữ liệu quan hệ

STUDENT

MÃ SV	NGÀNH	GPA	TỶ LỆ HOÀN THÀNH
S01	IT	3.1	90%
S02	DS	2.5	65%
S03	IT	3.6	95%

COURSE

MÃ MH	TÊN MÔN HỌC	NGÀNH	SỐ TÍN CHỈ
C01	Cơ sở dữ liệu	IT	3
C02	Khai phá dữ liệu	DS	3
C03	Trí tuệ nhân tạo	DS	3
C04	Lập trình Python	IT	3

Data Mining đi xa hơn tìm record thỏa điều kiện — tìm pattern, correlation, groups và predictive relationships.

Sequence data — dữ liệu chuỗi

Home → Search → **Product** → Cart → Checkout

VÍ DỤ CHUỖI KHÁC:

- chuỗi click website
- GPS trajectory
- chuỗi protein
- lịch sử mua hàng
- chuỗi sự kiện máy móc

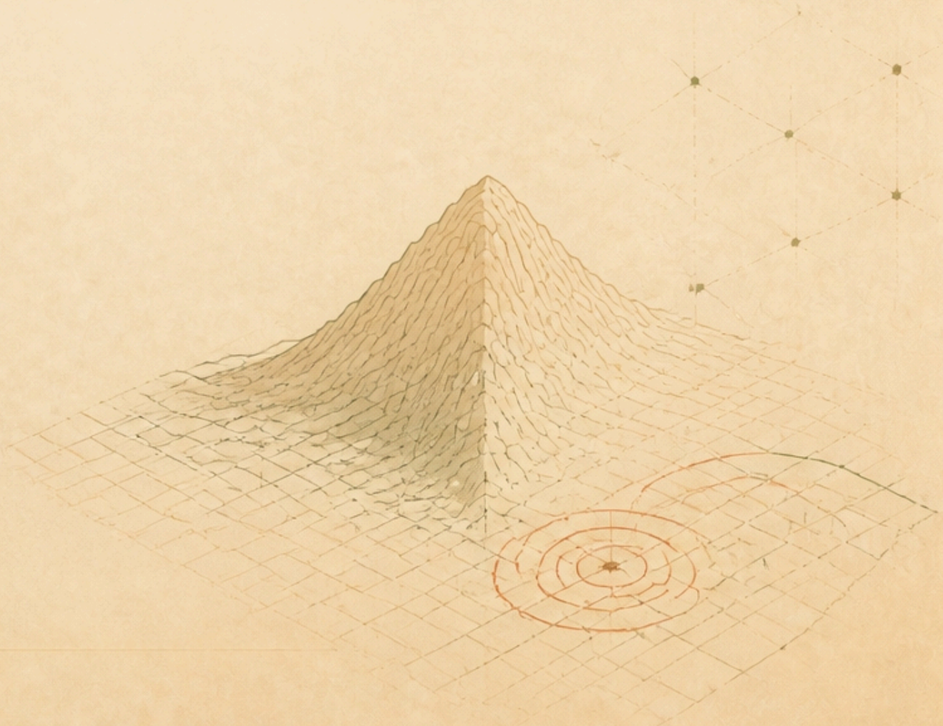

Với sequence, A → B → C khác C → B → A.

Sequence data — dữ liệu chuỗi

- chuỗi click website
- GPS trajectory
- chuỗi protein
- lịch sử mua hàng
- chuỗi sự kiện máy móc

Với sequence, A → B → C khác C → B → A.

Time series data — chuỗi thời gian

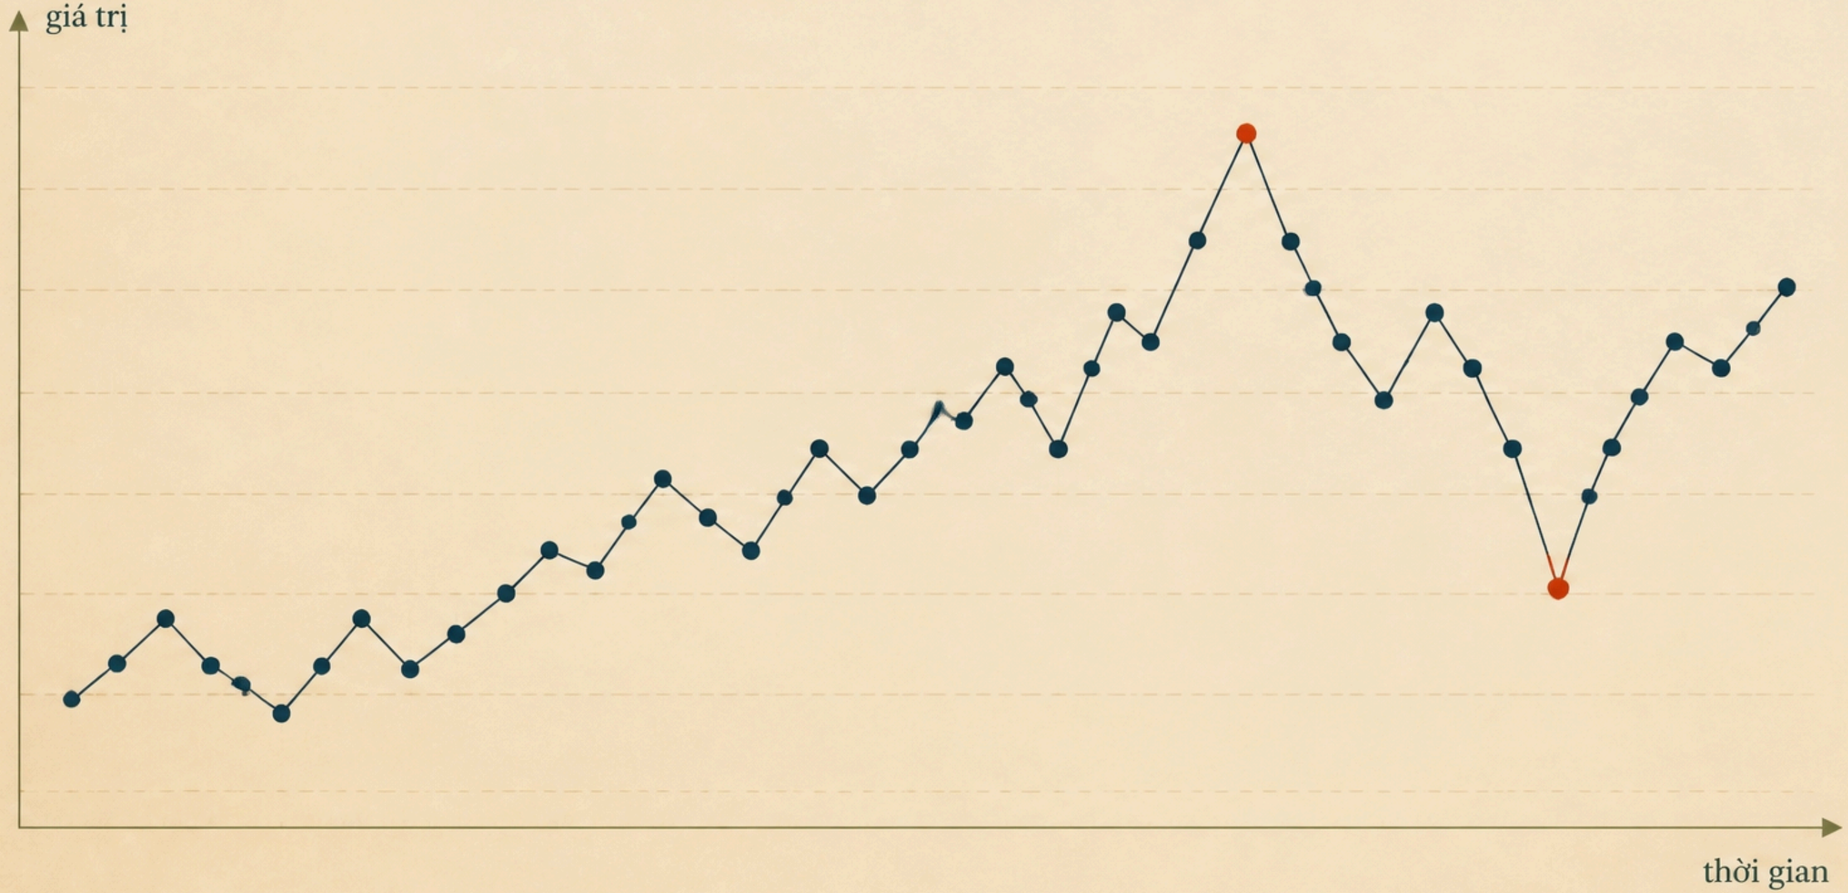

Ví dụ trong thực tế

- giá cổ phiếu
- nhiệt độ
- điện năng tiêu thụ
- EEG
- lưu lượng mạng
- doanh thu theo ngày

Các giá trị số, quan sát theo thời gian, thường ở khoảng đều.

Text — Web — Graph data

Văn bản

review, bài báo,
email, document

Web

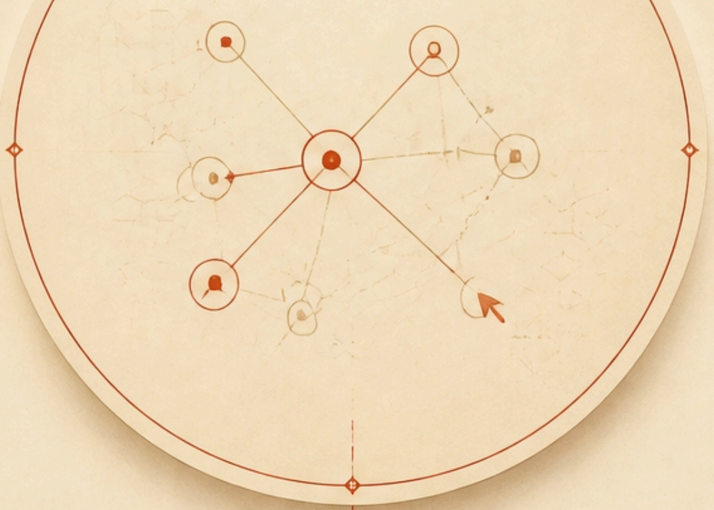

webpage, hyperlink,
clickstream

Đồ thị

social network, citation,
knowledge graph

Các dạng dữ liệu này thường cần biểu diễn đặc biệt trước khi mining.

Dữ liệu hỗn hợp & Dữ liệu dòng

Hỗn hợp

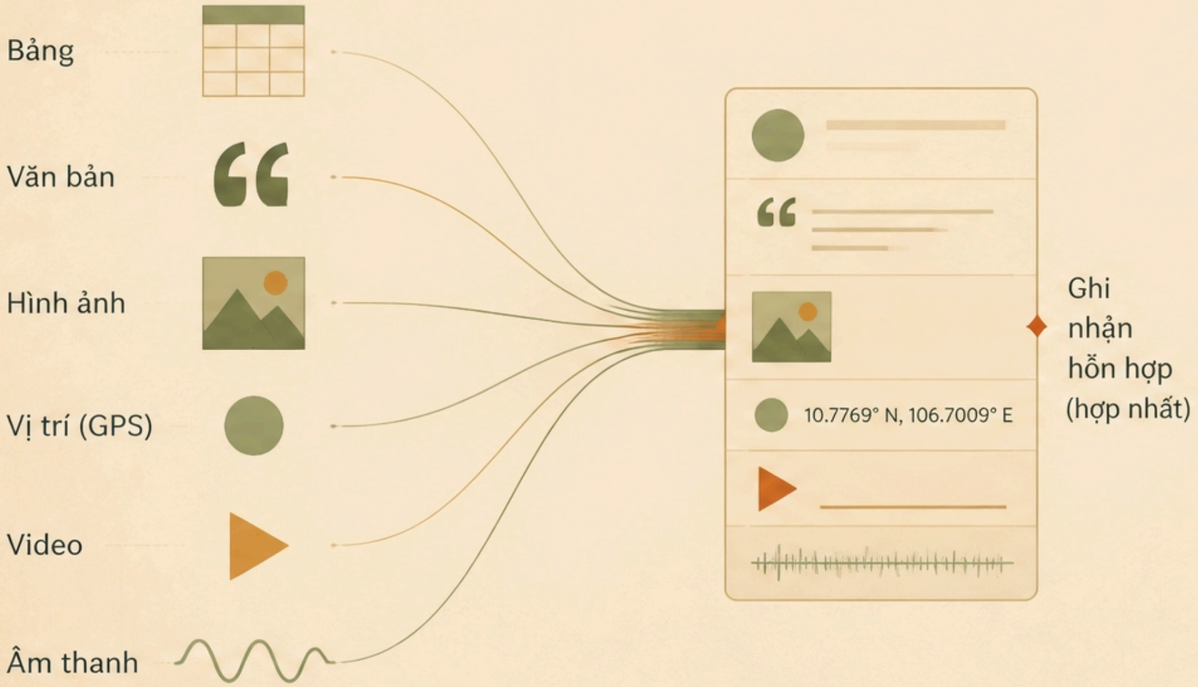

Dòng

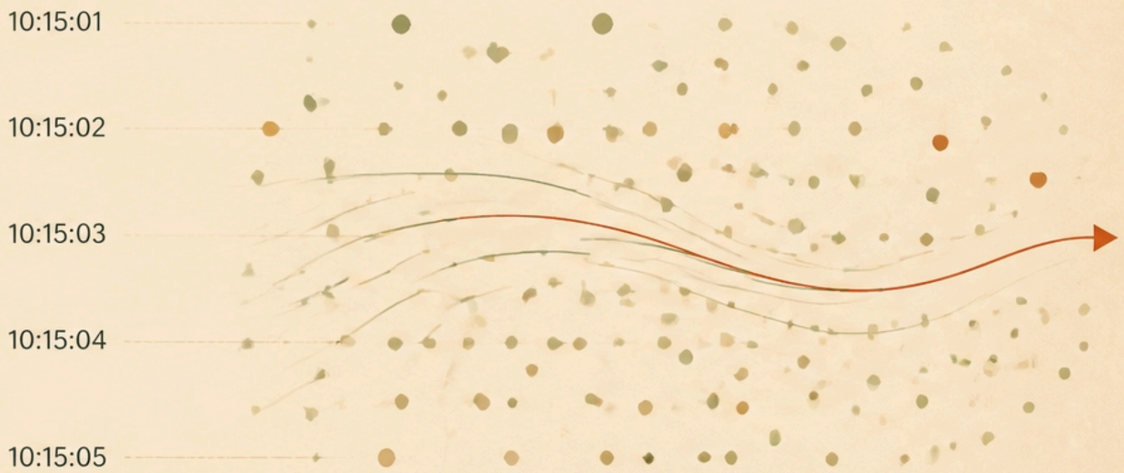

Dữ liệu đến liên tục, tốc độ cao, có thể vô hạn,
thường phải xử lý gần real-time.
Ví dụ: sensor, camera, network traffic.

EDA — Khám phá dữ liệu

Dữ liệu lớn bao nhiêu?

Distribution như thế nào?

Có missing không?

Có outlier không?

Có imbalance không?

Các feature liên hệ thế nào?

EDA không phải "vẽ thật nhiêu biểu đô"

01

Score có phân phối lệch không?

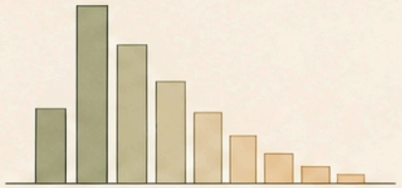

02

Có extreme values không?

03

Study time và score liên hệ không?

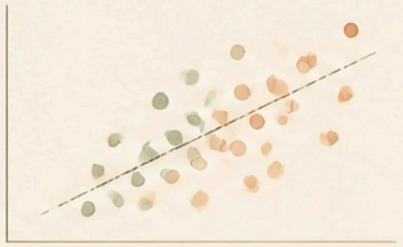

04

Các category mất cân bằng không?

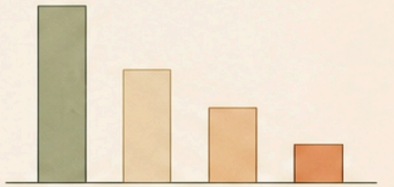

Question → Visualization → Interpretation.

Thống kê mô tả — Xu hướng trung tâm

01

Mean

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

02

Median

giá trị ở giữa sau khi sắp xếp

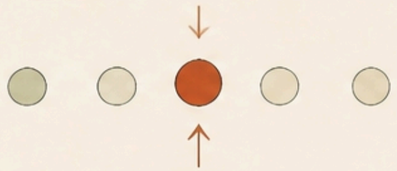

03

Mode

giá trị xuất hiện nhiều nhất

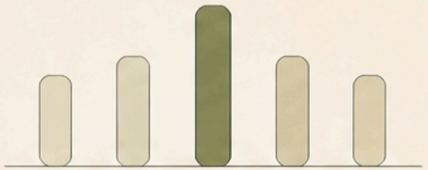

8, 9, 10, 11, 100

- Mean bị kéo mạnh bởi 100.
- Median thường phản ánh trung tâm tốt hơn trong dữ liệu lệch.

Độ phân tán của dữ liệu

Range

Variance

Standard deviation

IQR

A = 49, 50, 50, 50, 51

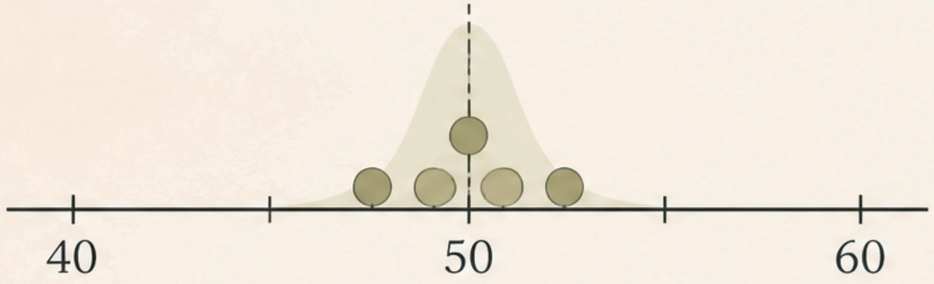

B = 10, 30, 50, 70, 90

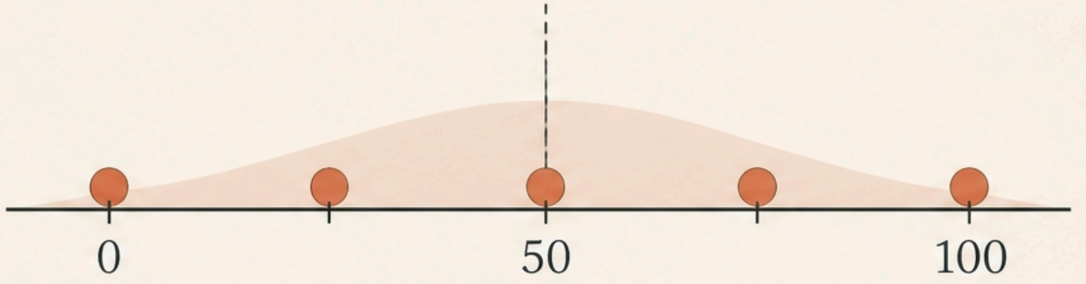

Cùng mean = 50, nhưng mức phân tán rất khác.

Thống kê cho biến phân loại

01

Frequency

Đếm số lần xuất hiện của mỗi danh mục.

02

Percentage

Tính tỷ lệ phần trăm của mỗi danh mục.

03

Mode

Xác định danh mục xuất hiện nhiều nhất.

04

Cross-tabulation

Bảng chéo giữa hai biến phân loại.

Ví dụ	Major — IT	Business	Tourism
Số lượng	150	70	30

- Có thể phát hiện class imbalance, category hiếm, lỗi nhập liệu, phân bố không đại diện.

Correlation ≠ Causation

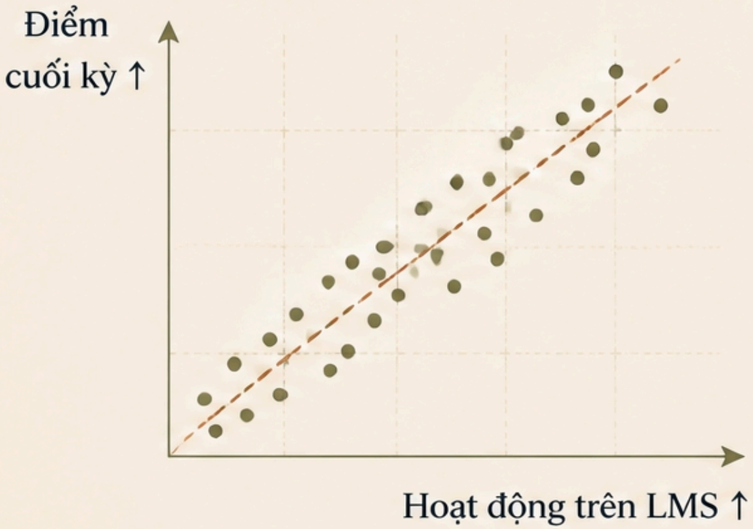

?

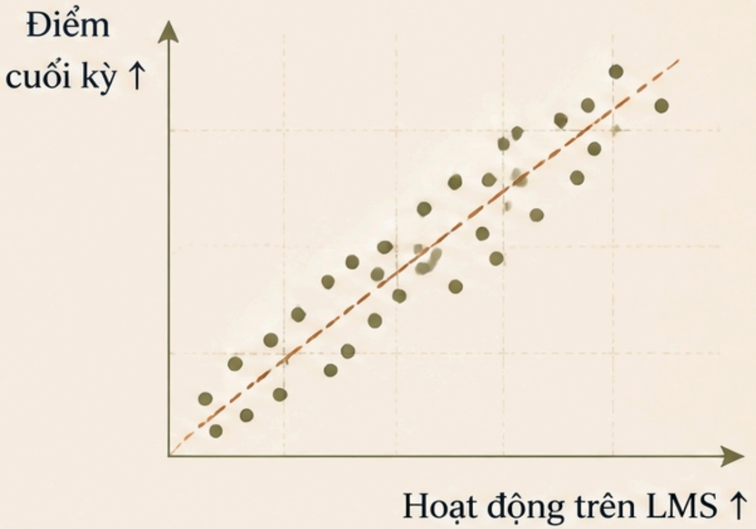

Có thể liên quan, nhưng chưa đủ để kết luận: tăng LMS activity sẽ làm điểm tăng.

- Trong Data Mining, correlation hữu ích cho khám phá, feature selection, redundancy analysis — nhưng không tự tạo bằng chứng nhân quả.

Trực quan hóa dữ liệu

Visualization giúp phát hiện

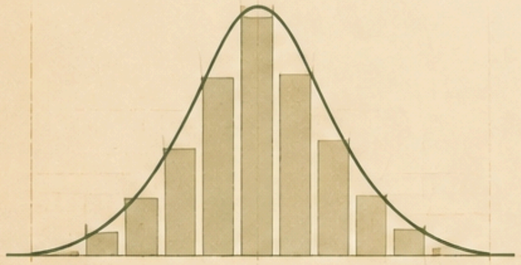

distribution

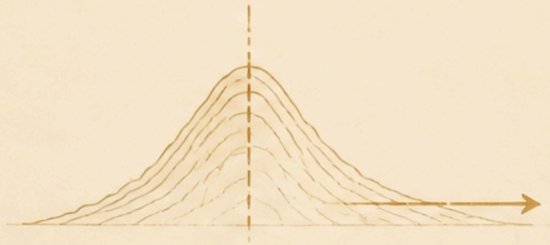

skewness

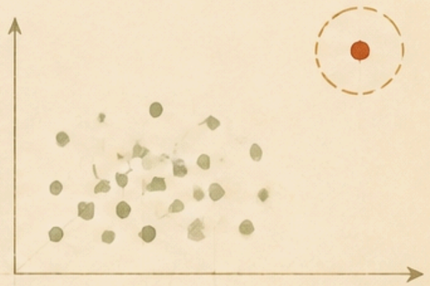

outlier

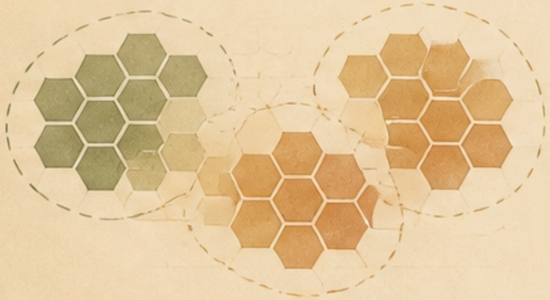

cluster

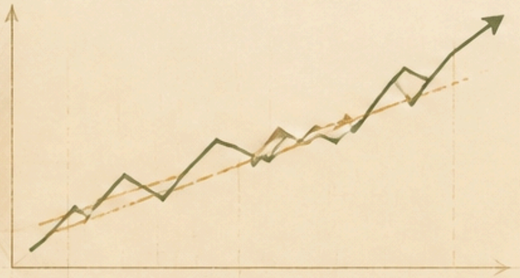

trend

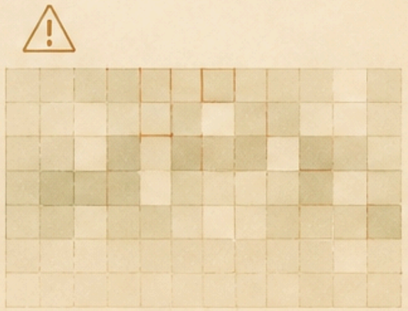

data quality problem

Data visualization vừa hỗ trợ Data Understanding, vừa hỗ trợ trình bày knowledge sau mining.

Chọn biểu đồ theo câu hỏi

1	Một biến số	→	Histogram / Boxplot
2	Một biến phân loại	→	Bar chart
3	Hai biến số	→	Scatter plot
4	Biến số + category	→	Boxplot theo nhóm
5	Nhiều biến	→	Correlation matrix hoặc parallel coordinates

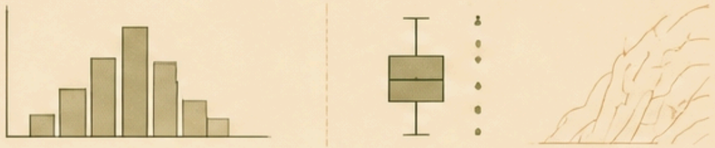

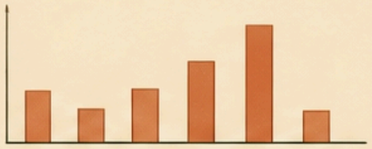

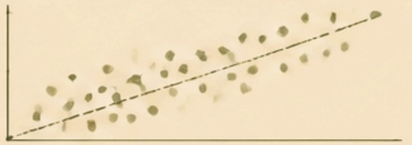

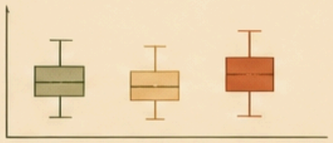

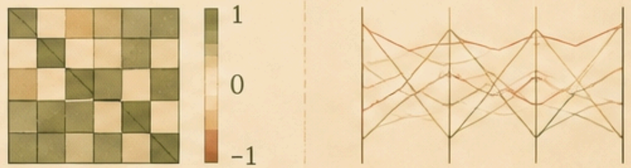

Không chọn biểu đồ chỉ vì đẹp.

Tại sao cần Similarity & Distance?

Hai đối tượng giống nhau đến mức nào?

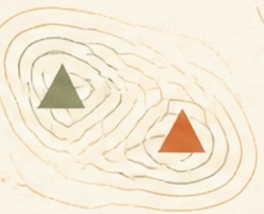

Clustering

Nearest Neighbor

Recommendation

Retrieval

Pattern matching

Nhưng "giống nhau" phụ thuộc vào loại dữ liệu, thang đo, mục tiêu bài toán.

Đề cương GCOS108 đặt "các độ đo tương tự" trong phần dữ liệu.

Euclidean distance

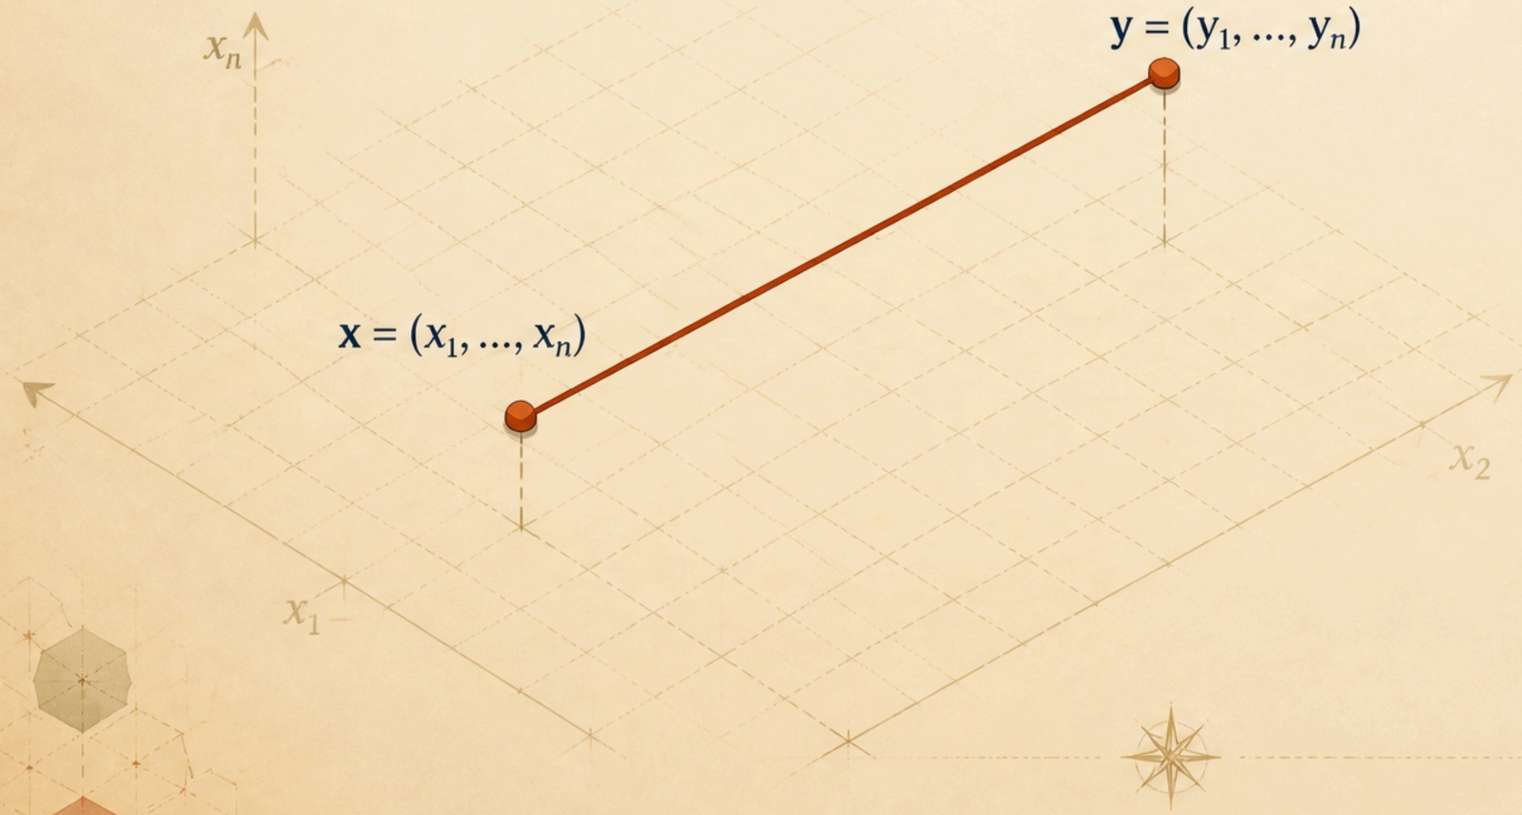

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Trực giác: khoảng cách đường thẳng giữa hai điểm.
Phù hợp với dữ liệu số, các feature có thang đo phù hợp.

Manhattan distance

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{n} |x_i - y_i|$$

$$|2 - 5| + |3 - 7| = 7$$

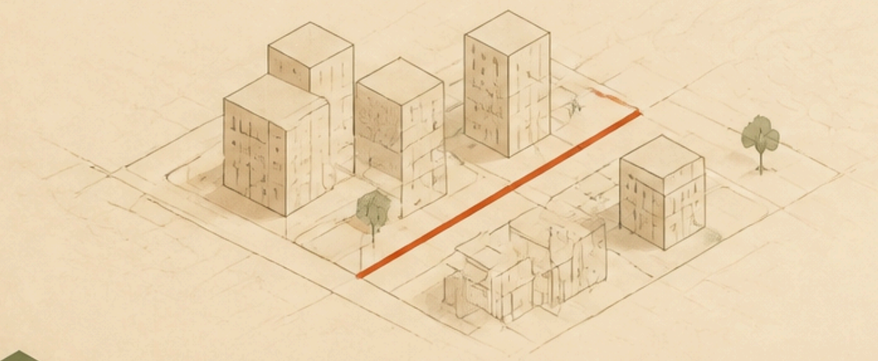

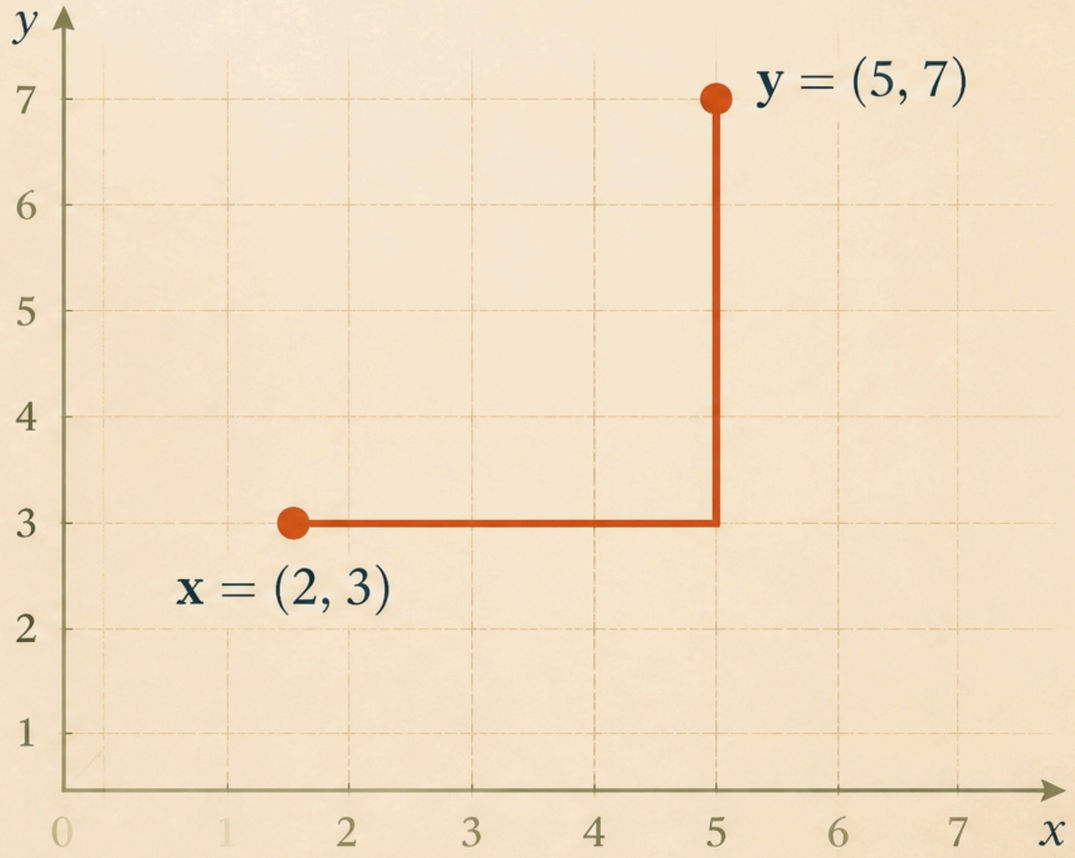

Tên gọi xuất phát tù di chuyển theo các block đường phố.
Có thể hữu ích với dữ liệu nhiều chiều hoặc khi muốn dùng sai khác tuyệt đối.

Cosine similarity

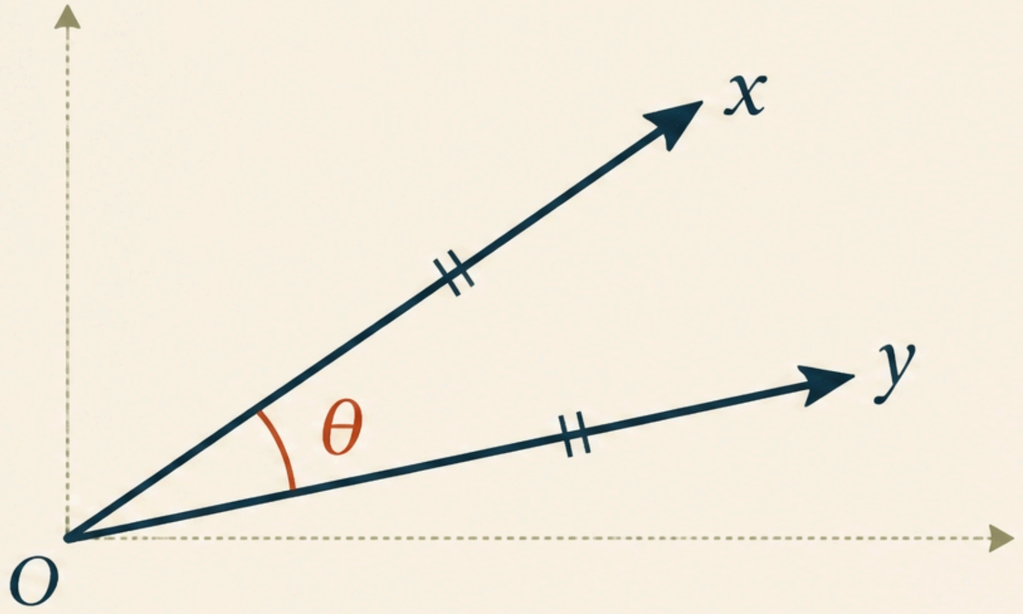

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \, \|y\|}$$

TEXT VECTOR

TF-IDF

SPARSE FEATURES

DOCUMENT SIMILARITY

Cosine tập trung vào hướng của vector hơn là độ lớn.
Hai tài liệu có nội dung giống nhau nhưng độ dài khác nhau vẫn có thể có cosine cao.

Jaccard simiarity

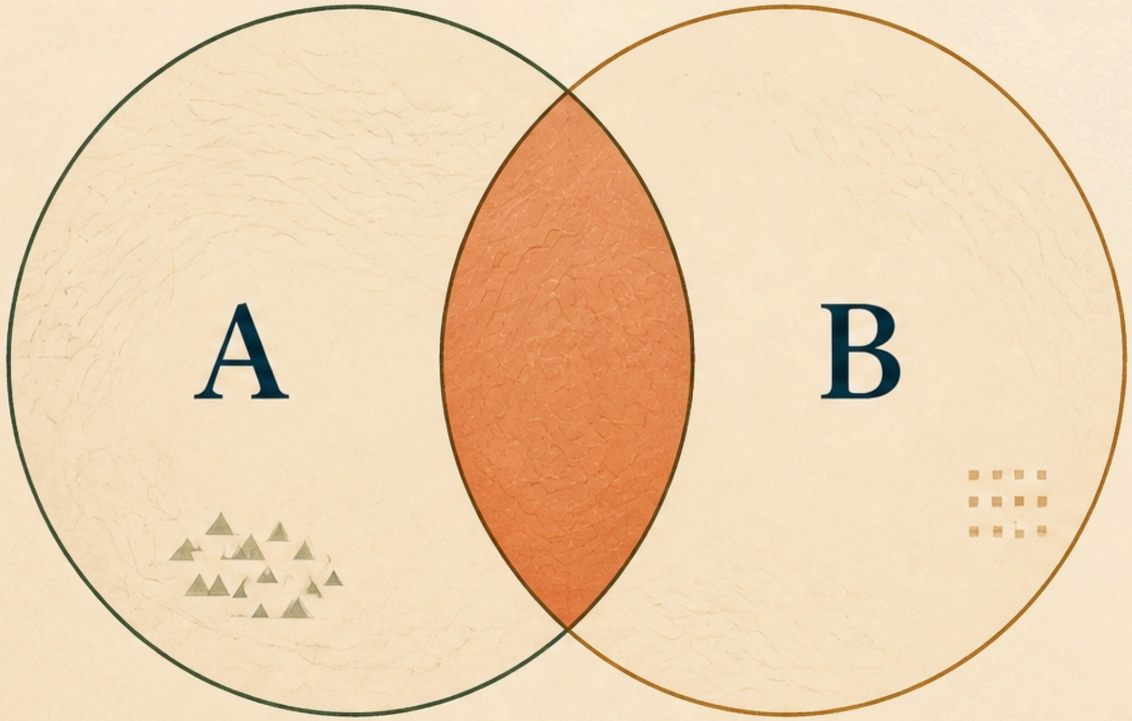

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

A = {Milk, Bread, Eggs}

B = {Milk, Bread, Coffee}

Giao (A ∩ B): {Milk, Bread}

Hợp (A ∪ B): {Milk, Bread, Eggs, Coffee}

J(A, B) = 2/4 = 0.5

Phù hợp với transaction và set data.

Scaling ảnh hưởng đến distance

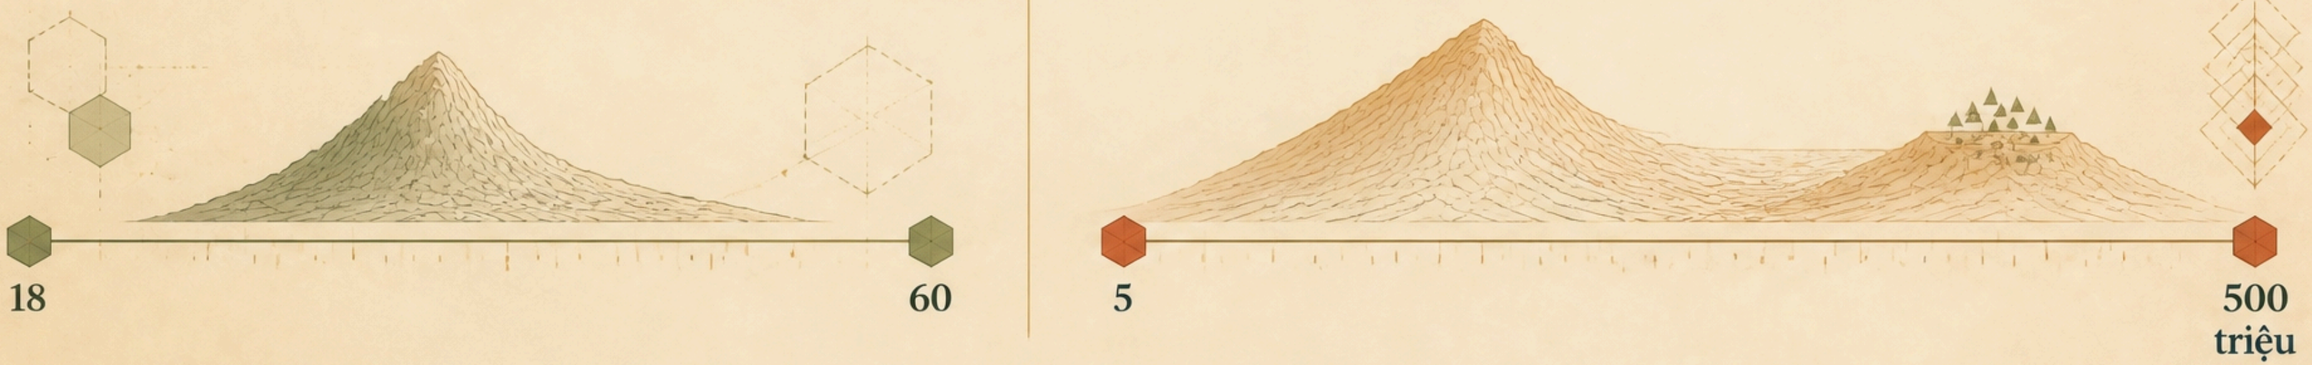

- Nếu dùng Euclidean trực tiếp, Income có thể thống trị distance.

Min-Max: $x' = \dfrac{x - \min}{\max - \min}$

Standardization: $z = \dfrac{x - \mu}{\sigma}$

Scaling đặc biệt quan trọng với thuật toán dựa trên khoảng cách.

Data quality — chất lượng dữ liệu

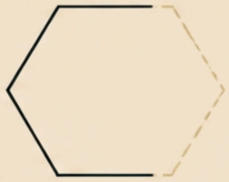

1. missing values

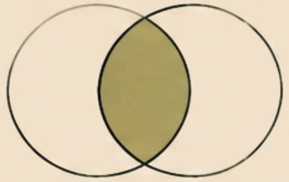

2. duplicate records

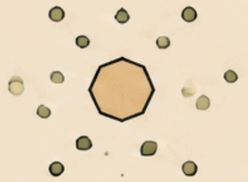

3. noise

4. outliers

5. sai kiểu dữ liệu

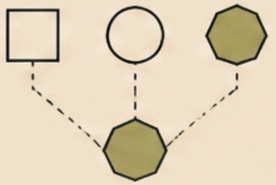

6. category không thống nhất

7. sai đơn vị

8. sai range

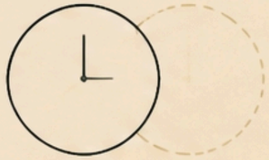

9. sai timestamp

HCMC, TP.HCM, Ho Chi Minh, Ho Chi Minh City — có thể cùng một category

Missing values

Age = ?

Income = NULL

Score = NaN

Không nên tự động thay tất cả missing bằng mean.

Cần hỏi:

- bao nhiêu % bị thiếu?
- thiếu ở nhóm nào?
- nguyên nhân?
- feature có quan trọng?
- missing có mang thông tin?

Các hướng xử lý:

- loại record
- loại feature
- imputation
- thêm missing indicator

Outliers

PHƯƠNG PHÁP PHÁT HIỆN

1. Quy tắc nghiệp vụ
2. Boxplot
3. IQR
4. Z-score
5. Phương pháp robust

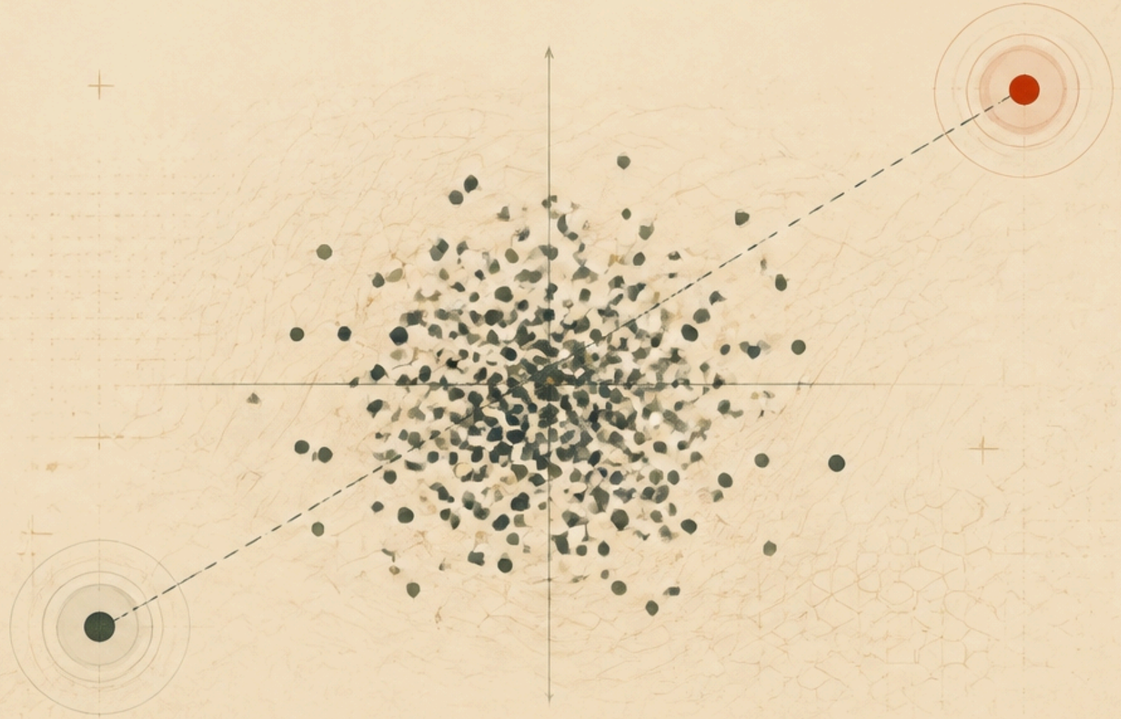

Outlier ≠ lỗi.

ỨNG DỤNG

- giao dich gian lận
- bệnh hiếm
- cyberattack
- sự cố thiết bị

Trong Anomaly Detection, outlier chính là đối tượng cần tìm.

Data cleaning không phải “xóa cái gì khác thường”

1

Detect —
phát hiện vấn đề

2

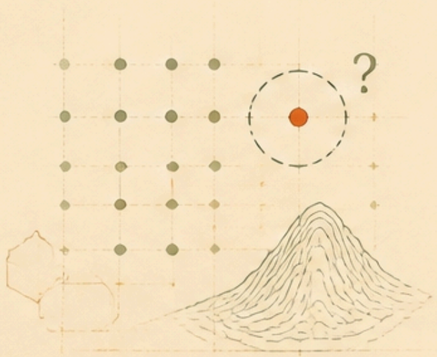

Verify —
lỗi hay hiện tượng thật?

3

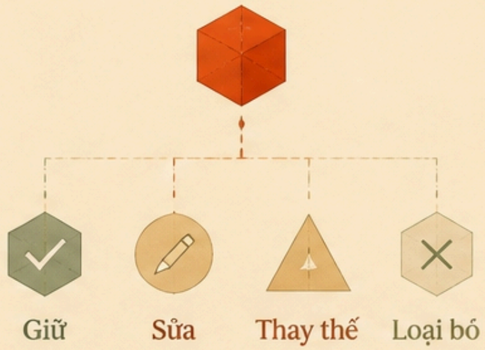

Decide —
giữ, sửa, thay thế
hay loại bỏ?

4

Document —
ghi lại lý do xử lý

Một preprocessing tốt phải có thể giải thích và tái lập.

Integration — Selection — Transformation

1

Tích hợp

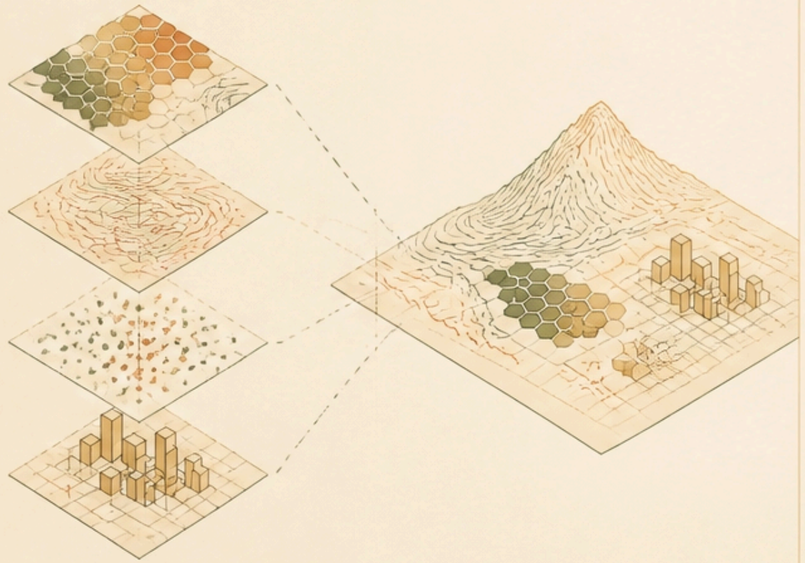

Kết hợp nhiều nguồn.
Vấn đề: schema khác, ID khác,
thời gian khác, đơn vị khác.

2

Lựa chọn

- population
- time window
- records
- features
- target

3

Biến đổi

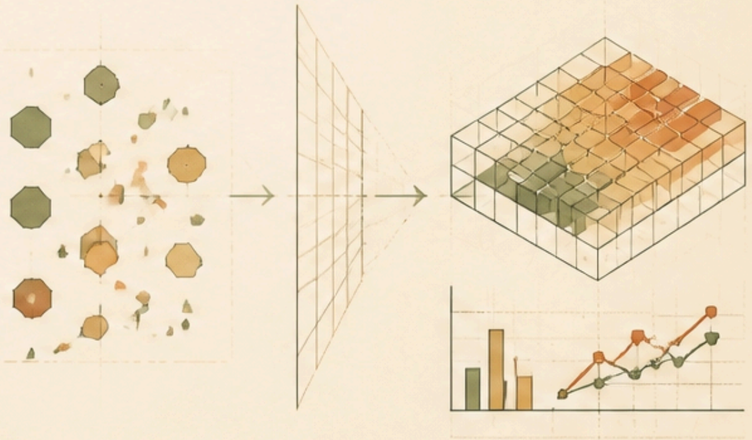

Chuyển dữ liệu sang
biểu diễn phù hợp.

Encoding — Feature Engineering — Reduction

ENCODING

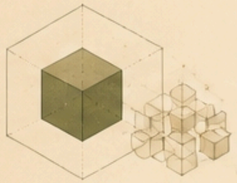

- **Nominal**
  → One-hot encoding

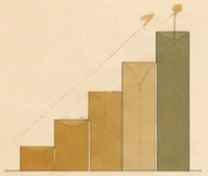

- **Ordinal**
  → Ordinal encoding
  nếu thứ tự có ý nghĩa

FEATURE ENGINEERING

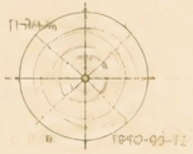

Date of birth
→ Age

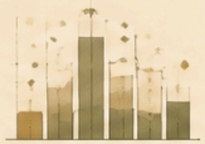

Transaction log
→ RFM

LMS logs
→ số ngày hoạt động

REDUCTION

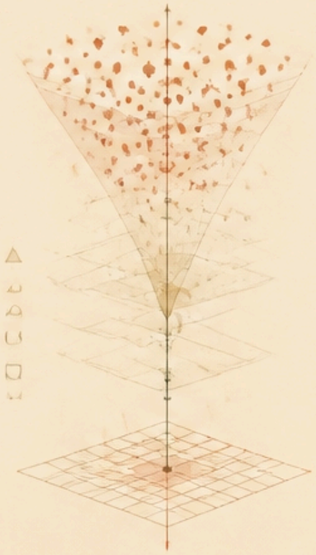

- **sampling**
- → feature selection
- → aggregation
- → dimensionality reduction

Giảm độ phức tạp nhưng giữ thông tin cần thiết.

Discretization & Data Leakage

Discretization

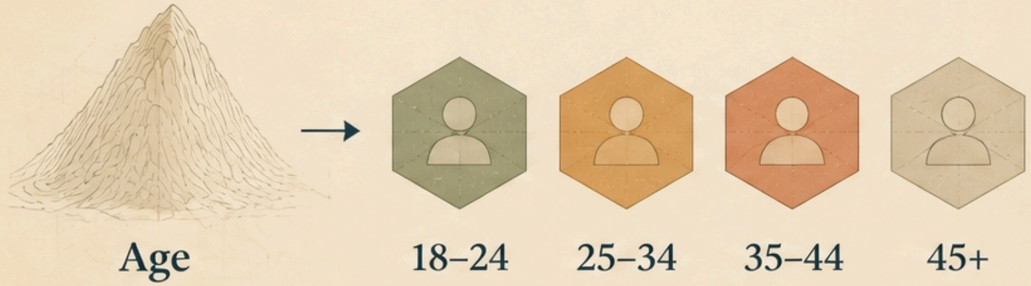

Có thể giúp dễ diễn giải, association rule mining,
một số pattern mining.

Nhưng chia khoảng tùy tiện có thể làm mất thông tin.

Data Leakage

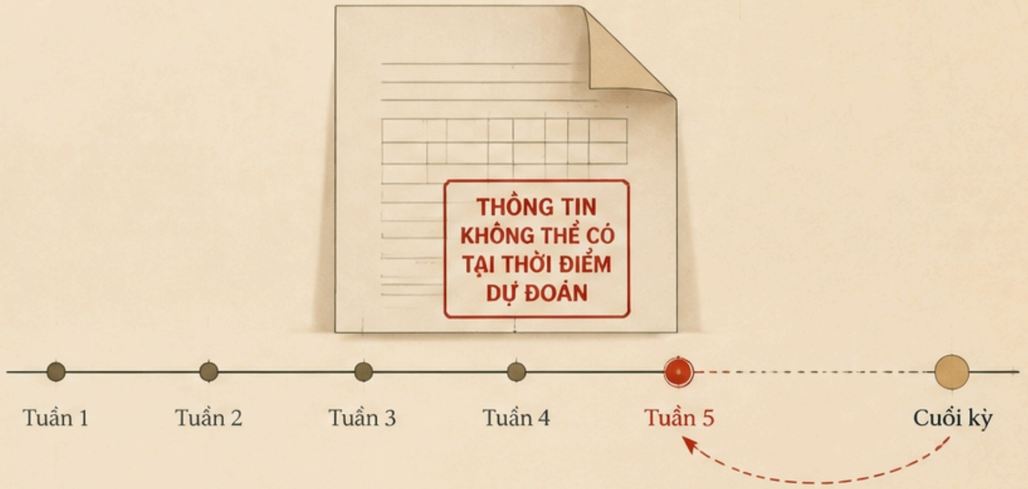

Xảy ra khi model sử dụng thông tin
mà tại thời điểm dự đoán thực tế không thể có.

Ví dụ:
dùng điểm cuối kỳ để dự báo rớt môn ở tuần 5.

Pipeline hoàn chỉnh của Bài 2

1 **Hiểu dữ liệu**
(problem → object → feature → target)

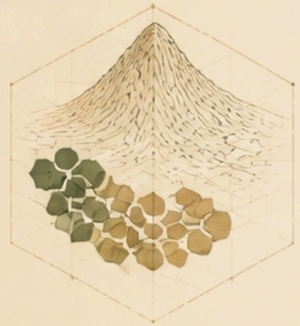

2 **EDA**
(thống kê, trực quan, quan hệ)

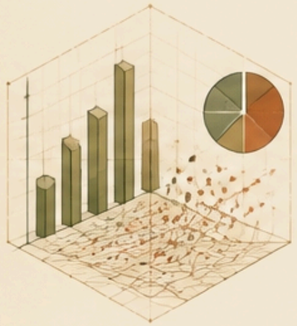

3 **Chất lượng dữ liêu**
(missing, duplicate, noise, outlier, nhất quán)

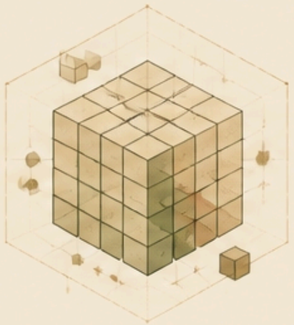

4 **Tiền xử lý**
(làm sạch, tích hợp, lựa chọn, biến đổi, giảm chiêu)

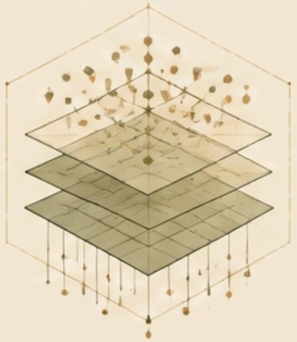

5 **Thiết kế thí nghiệm an toàn**
(train / val / test)

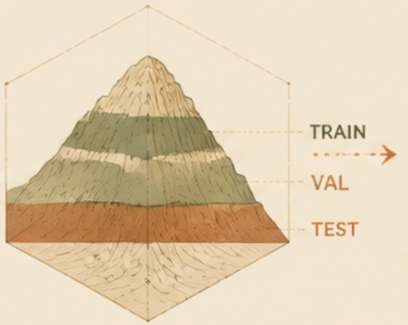

6 **Sẵn sàng cho Data Mining**

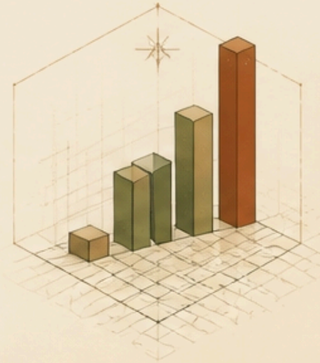

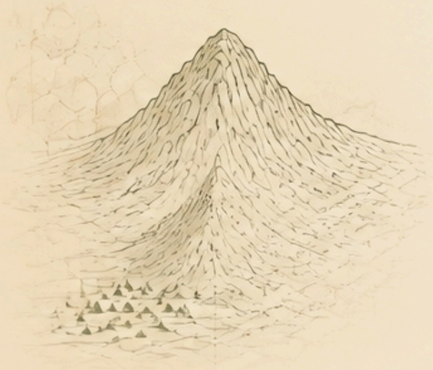

Bài toán: cảnh báo sớm sinh viên có nguy cơ không đạt học phần tại tuần 5.

Mỗi nhóm hãy trả lời:

- một record dại diện cho đối tượng nào?
- Feature nào thực sự có sẵn đến tuần 5?
- Có thế gặp những lỗi chất lượng dữ liệu nào?
- Cần cleaning và transformation nào?
- Feature nào có nguy cơ gảy data leakage?
- Dataset sau preprocessing cần được lưu như thế nào đế sử dụng tiếp ở Bài 5?

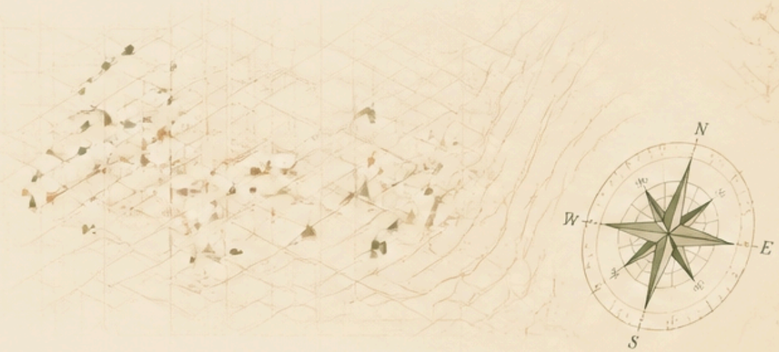

Chất lượng của Data Mining bị giới hạn bởi chất lượng và cách chúng ta hiểu dữ liệu đầu vào.
Đừng bắt đầu bằng model; hãy bắt đầu bằng dữ liệu.