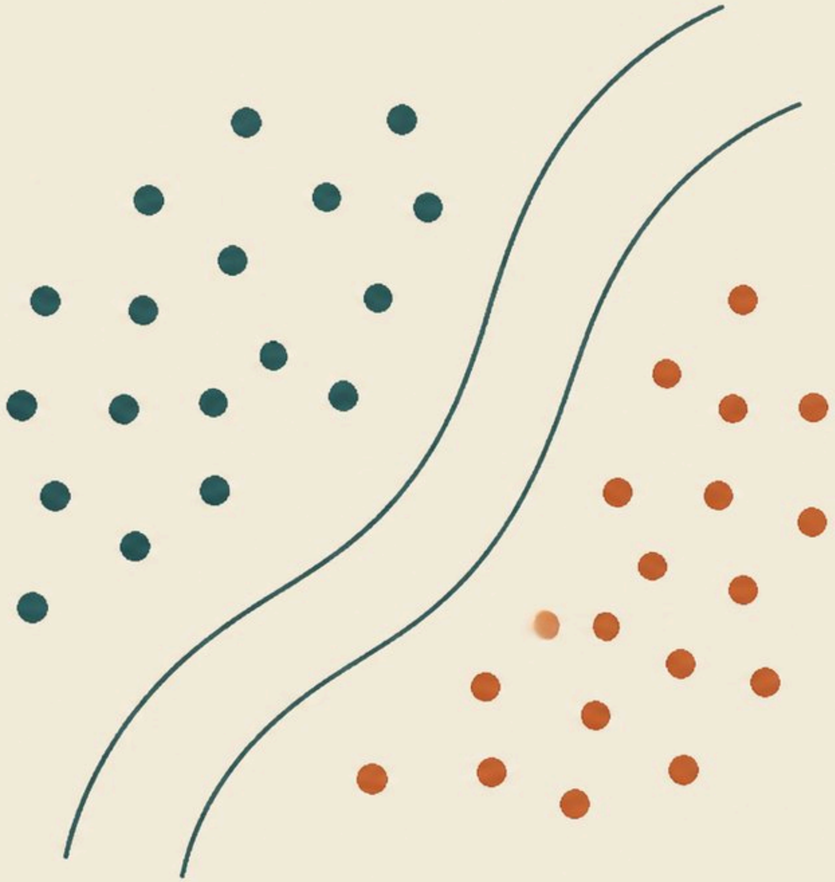
B5

PHÂN LOẠI VÀ MÔ HÌNH DỰ ĐOÁN

Classification & Predictive Modeling



DATA SCIENCE • LECTURE 05

MỤC TIÊU BÀI HỌC

Sau bài học, học viên có thể:

01



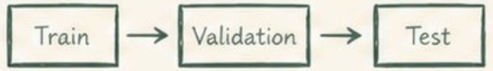
phát biểu đúng một bài toán Classification

02



xác định feature, target và prediction time

03



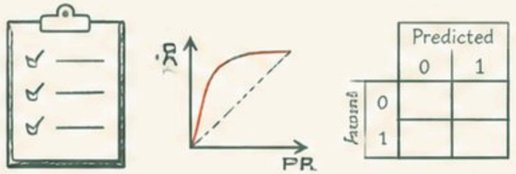
xây dựng quy trình train/validation/test đúng

04



giải thích nguyên lý một số thuật toán phân loại

05



đánh giá mô hình bằng các metric phù hợp

06



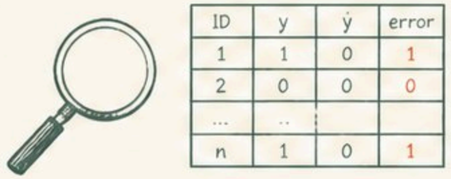
xử lý class imbalance ở mức cơ bản

07



nhận diện overfitting và data leakage

08



ID	y	ŷ	error
1	1	0	1
2	0	0	0
...	..		
n	1	0	1

thực hiện error analysis

09

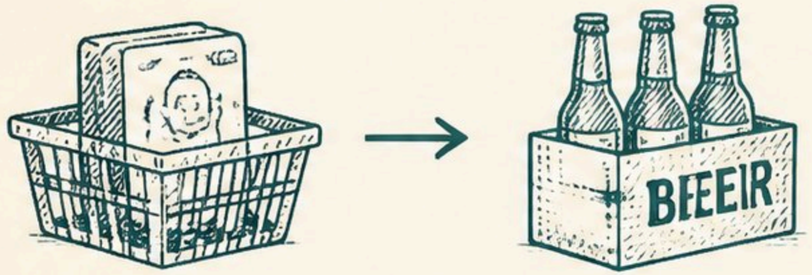


thiết kế thí nghiệm classification có khả năng phát triển thành research paper

Từ khám phá đến dự đoán

BÀI 4

pattern nào đang tồn tại trong dữ liệu?



$\{Diaper\} \rightarrow \{Beer\}$

BÀI 5

một đối tượng mới thuộc lớp nào?



$Student \rightarrow Pass\ /\ Fail$

Discover relationships

Learn model → Predict unseen

SECTION 04

Classification là gì?

Học một mô hình từ dữ liệu đã có nhãn để dự đoán lớp của các đối tượng mới.

$$X = (x_1, x_2, \ldots, x_p)$$

$$y \in \{C_1, C_2, \ldots, C_k\}$$

$$f(X) \rightarrow y$$

- Email → Spam / Normal
- Transaction → Fraud / Legitimate
- Student → Pass / Fail
- Patient → Disease / No Disease

Supervised Learning — Học có giám sát

Quan sát cả X và y trong quá trình huấn luyện.

Feature 1	Feature 2	...	Target
x_{11}	x_{12}	...	y_1
x_{21}	x_{22}	...	y_2
x_{31}	x_{32}	...	y_3



Sau huấn luyện — dự đoán một đối tượng mới.

SECTION 06

Classification vs Regression

Classification

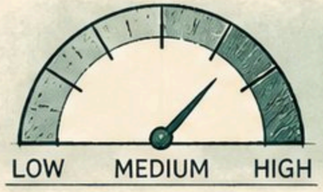
Target là category



Pass / Fail



Fraud / Normal



Low / Medium / High Risk

Regression

Target là giá trị liên tục



House Price = *4.2 billion*



Demand = *1245 units*



Score = *8.2*

Cùng supervised learning — output khác nhau.

Feature và Target

Dự đoán sinh viên có nguy cơ không đạt môn học

FEATURES — X

- attendance
- số lần login LMS
- assignment submission
- quiz score
- study activity

TARGET — y

1 = At Risk / Fail

0 = Pass

Cần xác định rõ target trước khi chọn thuật toán.

Section 08

Prediction Time — Khi nào dự đoán?

Một câu hỏi thường bị bỏ qua.



ĐƯỢC DÙNG

- ✓ attendance tuần 1–5
- ✓ login LMS
- ✓ quiz giữa kỳ

KHÔNG ĐƯỢC DÙNG

- ✗ final score
- ✗ điểm thi cuối kỳ
- ✗ dữ liệu tuần 10
- ✗ kết quả chính thức

Nếu dùng → Data Leakage.

Pipeline — Quy trình xây dựng mô hình



01 Define Problem

02 Define Target & Prediction Time

03 Prepare Features

04 Train / Validation / Test Split

05 Build Baseline

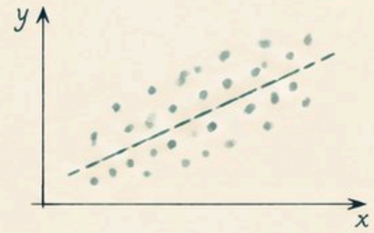
06 Train Models

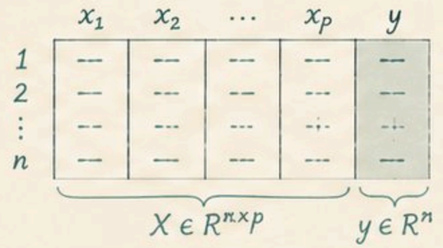
07 Tune

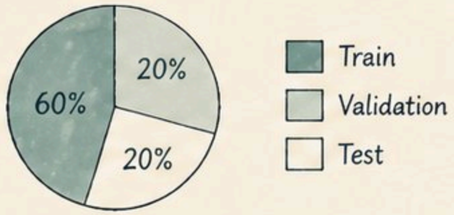
08 Final Evaluation

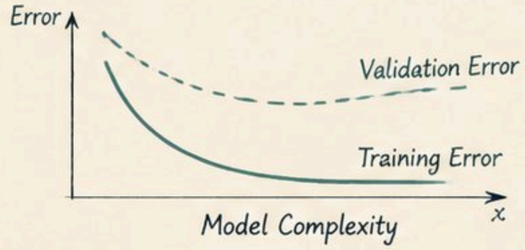
09 Error Analysis

10 Interpretation

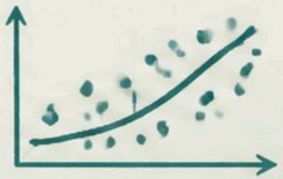




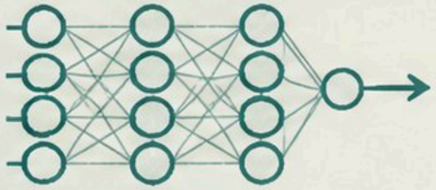




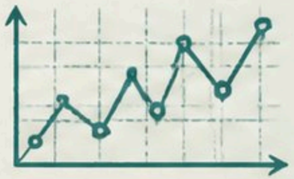
Train — Validation — Test



Training Set



học tham số mô hình



Validation Set

- chọn model
- chọn hyperparameter
- chọn threshold



Test Set

ước lượng generalization

— only used at the very end

⚠ *Không tuning bằng test set.*

Baseline — Điểm xuất phát bắt buộc

Tốt hơn cái gì?

✓ Majority Class

Luôn dự đoán lớp phổ biến nhất.

✓ Simple Rule

Ví dụ: midterm < 5 → At Risk.

✓ Simple Model

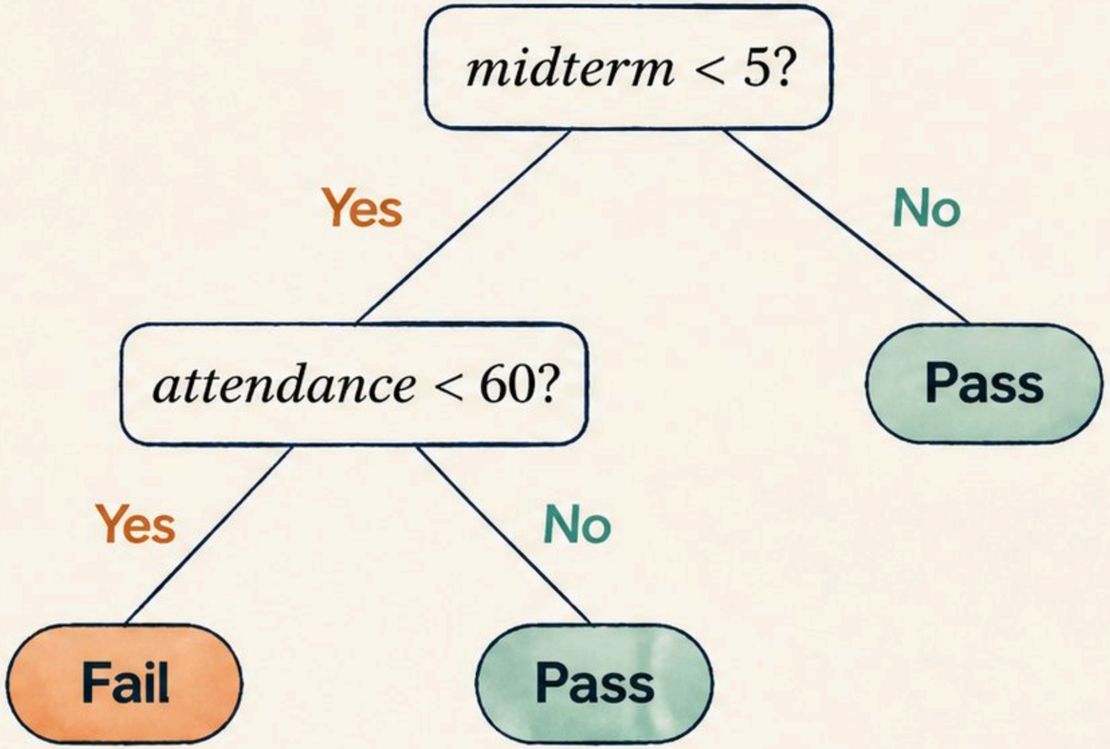
- Logistic Regression
- Naive Bayes
- Shallow Decision Tree

Một proposed model nên được so sánh với baseline hợp lý.

Section 12

Decision Tree — Cây quyết định

Phân loại bằng chuỗi câu hỏi.



Ưu điểm

- ✓ dễ hiểu
- ✓ dễ trực quan hóa
- ✓ xử lý quan hệ phi tuyến
- ✓ tạo decision rules tự nhiên

Split Criteria + Information Gain

Sau khi split, các node con càng thuần càng tốt.

1 Entropy

$$H(S) = -\sum p_i \log_2 p_i$$

2 Gini Impurity

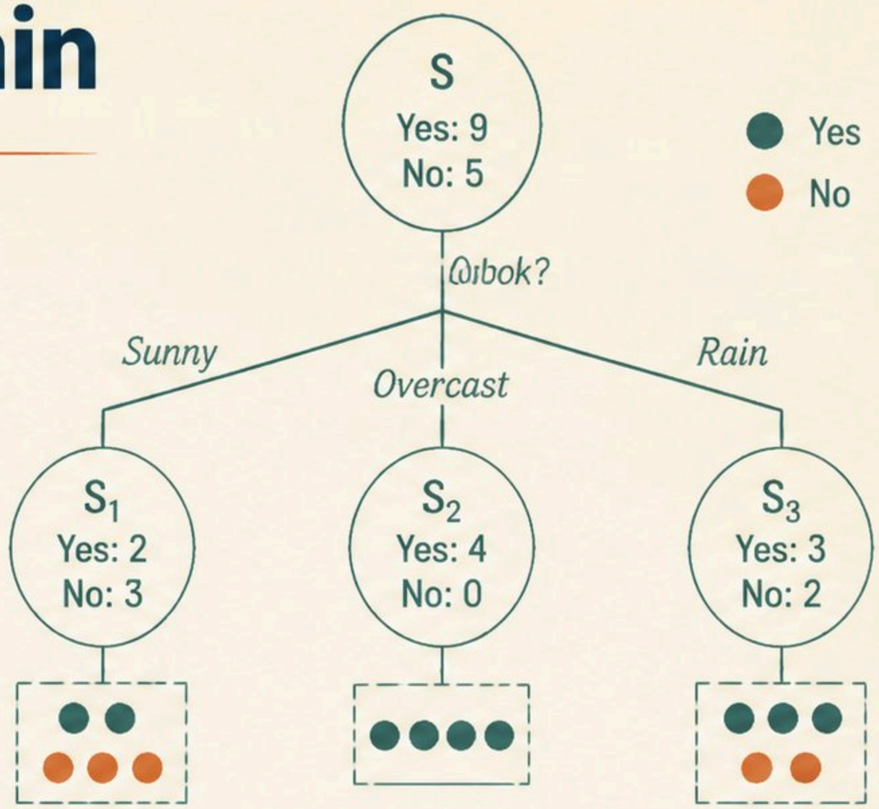
$$Gini(S) = 1 - \sum_{i} p_i^2$$

3 Information Gain

$$IG(S, A) = H(S) - \sum_{v} \frac{|S_v|}{|S|} H(S_v)$$

Chọn câu hỏi giúp phân tách các lớp rõ nhất.

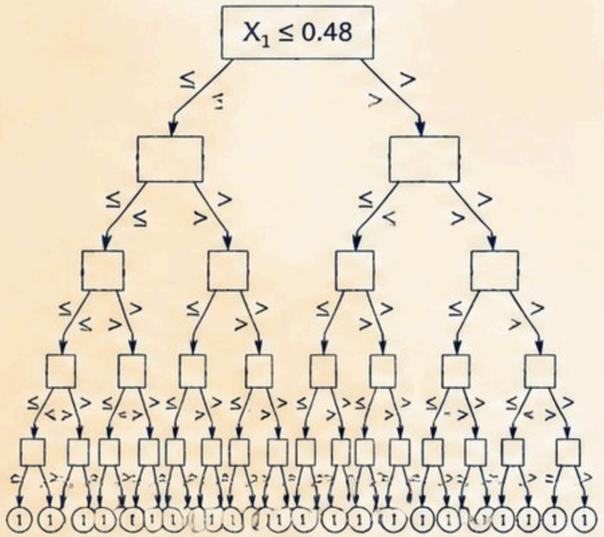
node hoàn toàn pure → Entropy = 0, Gini = 0.



Node	S	S_1 (Sunny)	S_2 (Overcast)	S_3 (Rain)
Entropy H	0.940	0.971	0.000	0.971
Gini G	0.469	0.480	0.000	0.480

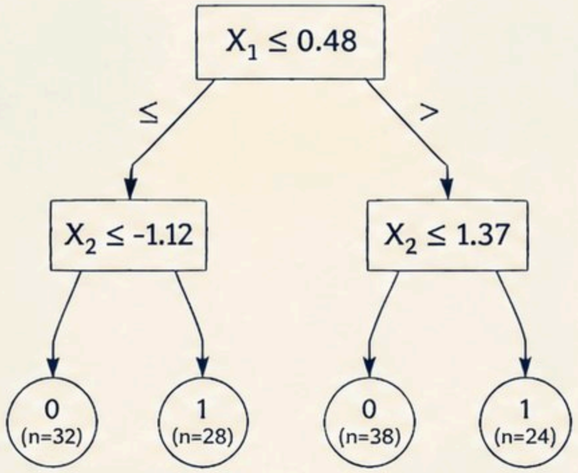
Decision Tree & Overfitting

Cây quá sâu



Lá chứa đúng 1 sample
(ghi nhớ hoàn toàn training data)

Cây generalize tốt



Ít lá, mỗi lá chứa nhiều sample
(khái quát tốt hơn)

Dấu hiệu của overfitting (cây quá sâu)

1. ghi nhớ training data
2. rule rất cụ thể
3. train accuracy rất cao
4. test performance thấp

Cách khắc phục (regularization cho cây)

max_depth · min_samples_leaf · min_samples_split · pruning

Không phải cây khớp training tốt nhất — mà là cây generalize tốt.

SECTION 15

Naive Bayes

$$P(C|X) = \frac{P(X|C)\ P(C)}{P(X)}$$

$$\hat{C} = \arg\max_{C}\ P(C|X)$$

Bayes theorem

- Dựa trên Bayes theorem
- Giả định naive — các feature độc lập có điều kiện khi biết class
- Dù giả định mạnh — thường là baseline hữu ích

Rule-Based Classification

IF

$attendance < 60\%$

AND

$assignment_missing > 3$

THEN

At_Risk

ƯU ĐIỂM

✓	dễ giải thích
✓	phù hợp hệ thống hỗ trợ quyết định
✓	dễ trao đổi với domain expert

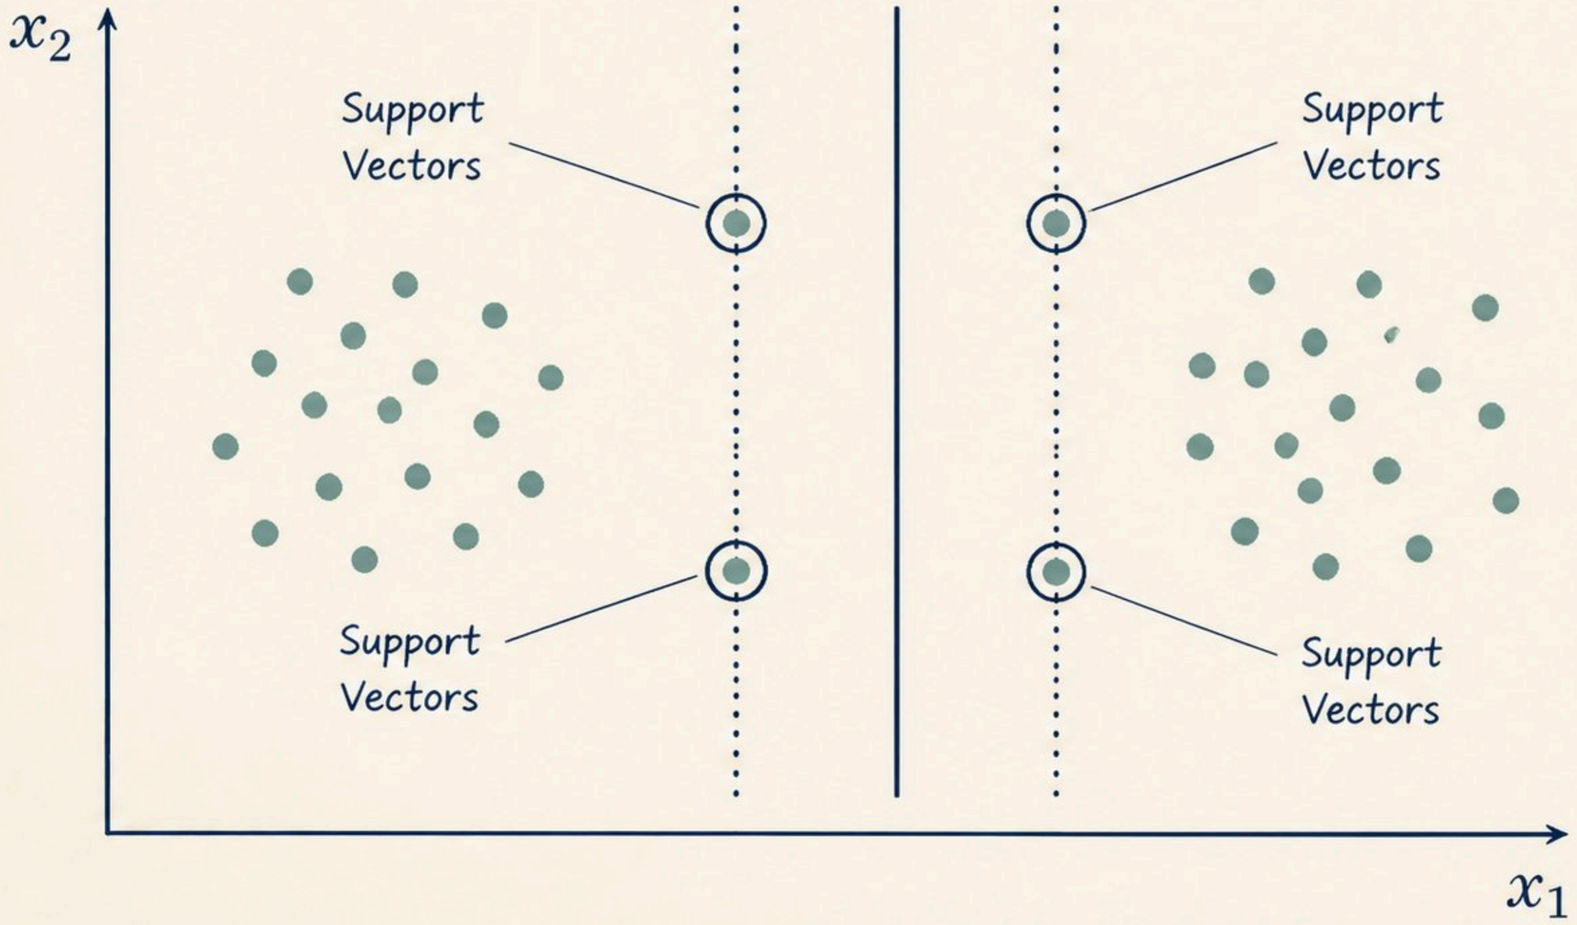
NÊN TRÁNH

✓	quá nhiều rule nhỏ
✓	phức tạp
✓	khó tổng quát

SECTION 17

SVM — Support Vector Machine

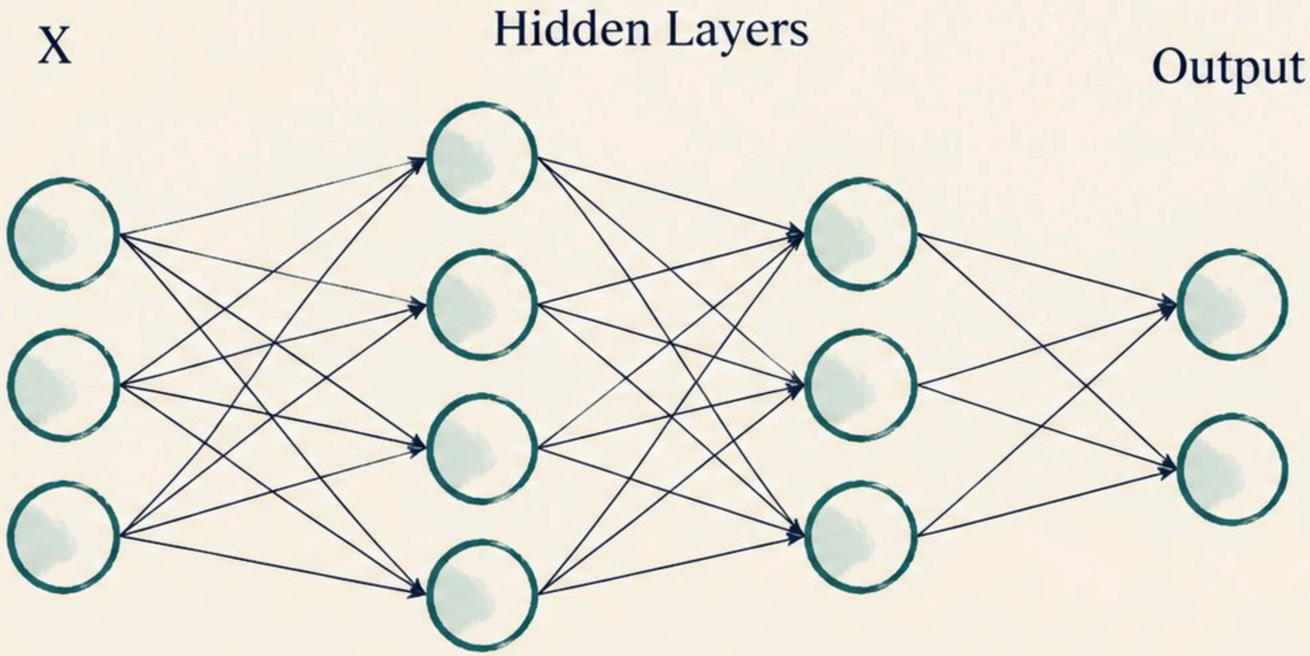
Tìm biên quyết định có khoảng cách lớn nhất với các điểm gần biên.



- **Maximum Margin** — khoảng cách lớn nhất
- **Support Vectors** — các điểm quan trọng nhất
- **Kernel** — tạo decision boundary phi tuyến

Neural Network

Gồm nhiều neuron / layer.



X → Hidden Layers → Output

ƯU ĐIỂM

- ✓ học quan hệ phức tạp

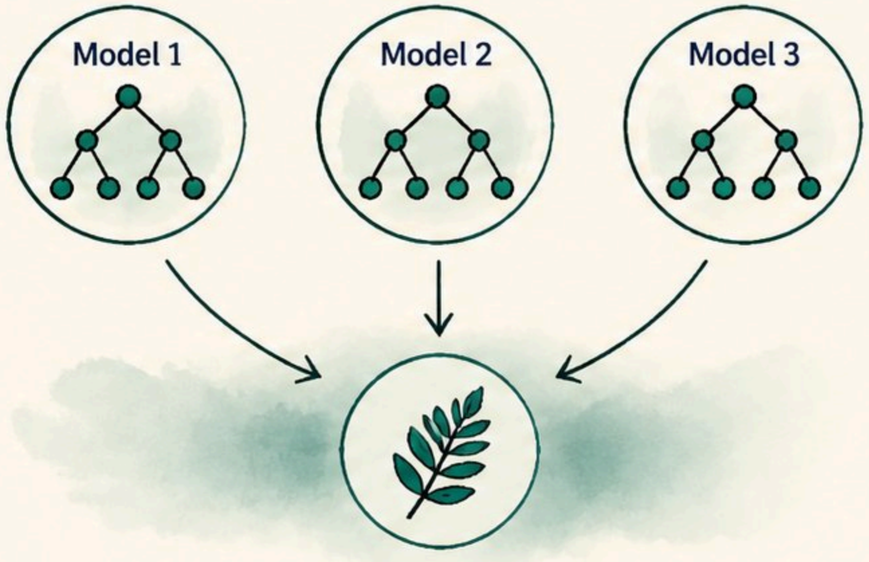
NHƯỢC ĐIỂM

- ✓ cần nhiều dữ liệu
- ✓ nhiều hyperparameter
- ✓ khó giải thích hơn

Ensemble Learning — Kết hợp nhiều model

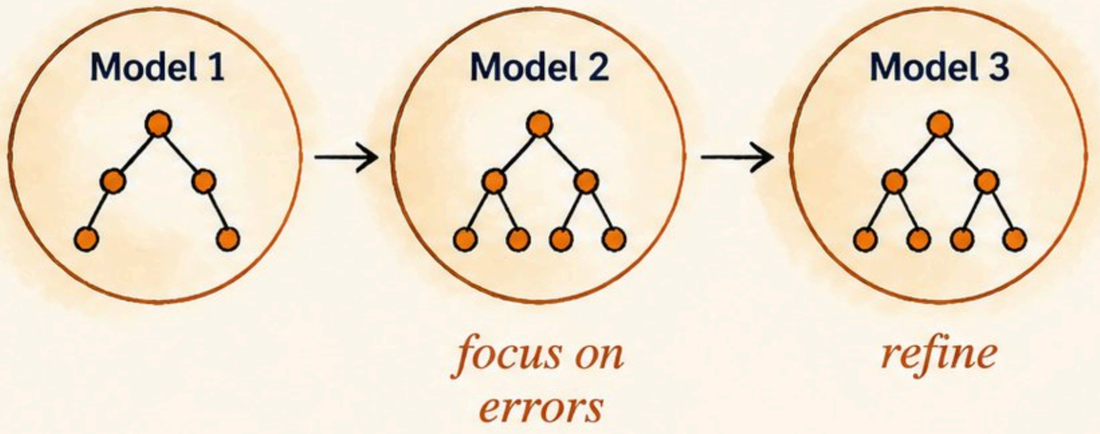
Many models → one stronger predictor

Bagging



Example: **Random Forest**

Boosting



Example: **AdaBoost · Gradient Boosting**

Mục tiêu — giảm variance hoặc giảm bias tùy phương pháp.

Confusion Matrix

	Predicted +	Predicted –
Actual +	*TP*	*FN*
Actual –	*FP*	*TN*

Trong bài toán At Risk:

TP — phát hiện đúng;

FN — sinh viên nguy cơ bị bỏ sót;

FP — cảnh báo nhầm;

TN — xác định đúng sinh viên bình thường.

Confusion Matrix là nền tảng của nhiều metric.

Accuracy và cái bẫy của nó

Accuracy

	Predicted Pass	Predicted Fail
Actual Pass	TP	FN
Actual Fail	FP	TN

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$



99 Pass + 1 Fail. Model luôn đoán Pass → Accuracy 99%



phát hiện sinh viên nguy cơ: 0% — Accuracy có thể gây hiểu nhầm khi class imbalance



Precision

$$Precision = \frac{TP}{TP + FP}$$



Recall

$$Recall = \frac{TP}{TP + FN}$$



F1

$$F1 = \frac{2 \cdot P \cdot R}{P + R}$$

Metric phụ thuộc vào bài toán

FN rất nguy hiểm → ưu tiên Recall



bệnh nghiêm trong



gian lận



sinh viên cần can thiệp sớm

FP gây chi phí lớn → Precision quan trọng



điều tra gian lận



khóa tài khoản

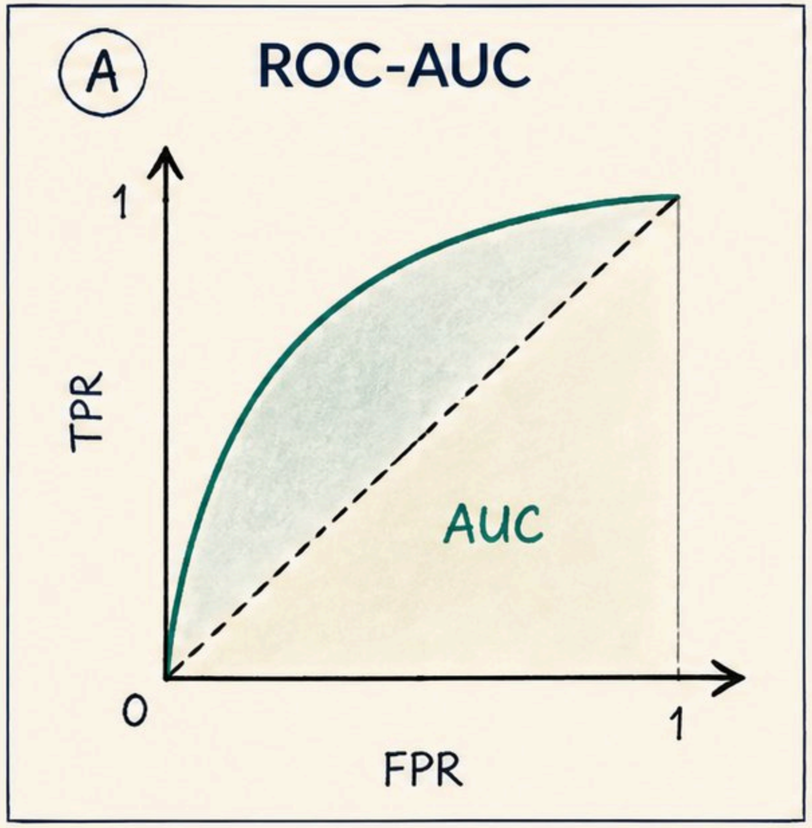


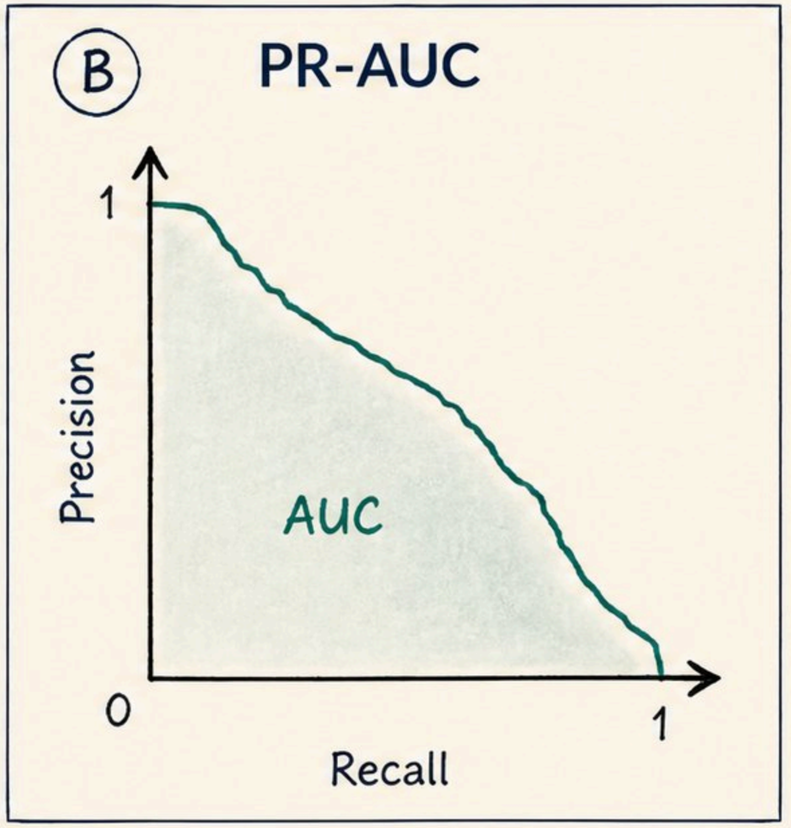
can thiệp tốn nguồn lực

Không tồn tại metric tốt nhất cho mọi bài toán.

ROC-AUC, PR-AUC và Threshold

Classifier thường sinh $P(y = 1|X)$ — threshold không bắt buộc là 0.5.



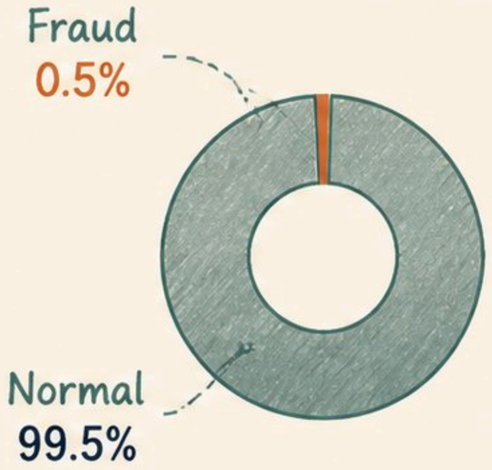


- ✓ ROC-AUC đánh giá khả năng xếp hạng qua nhiều threshold
- ✓ PR-AUC hữu ích khi positive class hiếm
- ✓ Threshold gắn với cost của FP và FN

Section 24

Class Imbalance

Fraud detection — ví dụ hay gặp.

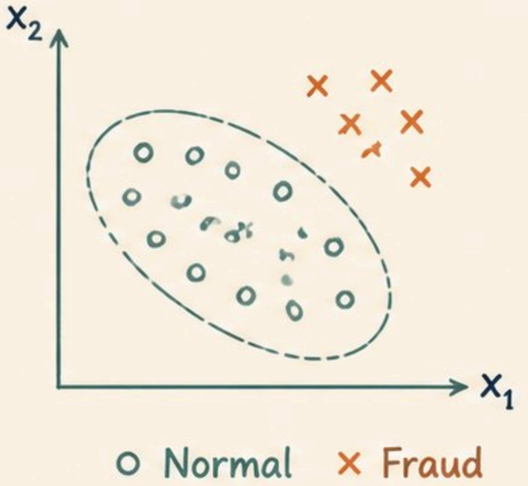


Normal

99.5%

Fraud

0.5%

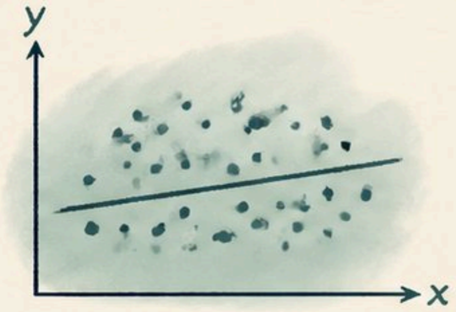


Giải pháp thường dùng

- class weights
- undersampling
- oversampling · SMOTE
- threshold tuning
- metric phù hợp

⚠ Resampling chỉ thực hiện trên *training data* — **không** oversample trước khi chia ***train/test***.

25 Cross-Validation và Tuning



Underfitting — model quá đơn giản

- Train performance thấp
- Test performance thấp



Overfitting

- Train rất tốt
- Test giảm mạnh

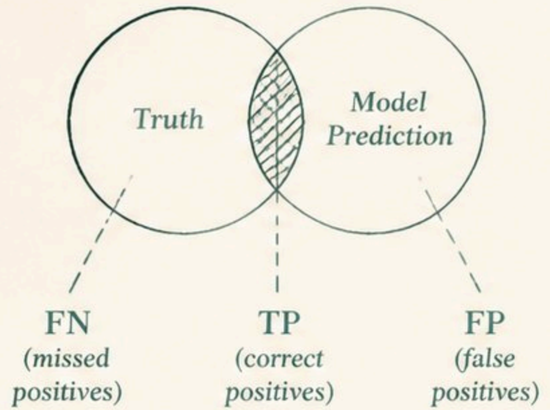
5-fold CV

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Run 1	Validation	Train	Train	Train	Train
Run 2	Train	Validation	Train	Train	Train
Run 3	Train	Train	Validation	Train	Train
Run 4	Train	Train	Train	Validation	Train
Run 5	Train	Train	Train	Train	Validation

Hyperparameter tuning nên thực hiện trên Training / CV — không trên Test.

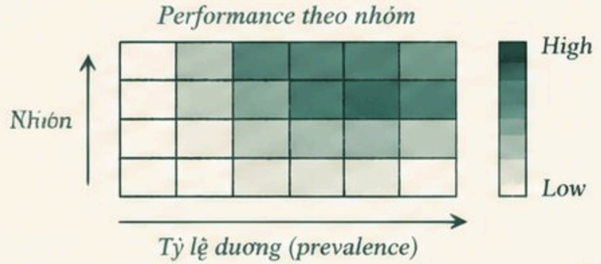
Section 26

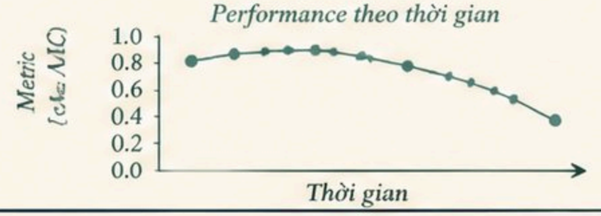
Error Analysis + Closing principle



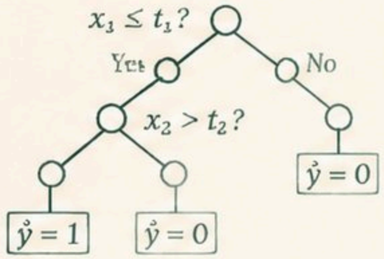
CÂU HỎI cho error analysis

1. *Model sai ở nhóm nào?*
2. *FN tập trung ở đối tượng nào?*
3. *Có khác biệt theo thời gian?*
4. *Performance trên nhóm hiếm?*
5. *Tại sao baseline thất bại?*

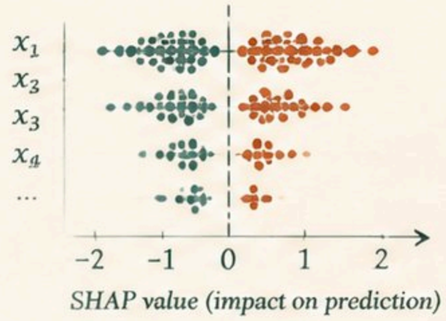




Explainability



- Decision Tree rules
- feature importance
- permutation importance
- SHAP



Feature importance ≠ causality.

Mục tiêu của Classification — không phải Accuracy cao nhất, mà là model đáng tin cậy, đánh giá đúng, giải thích được, phù hợp mục tiêu thực tế.